

Universidade Federal
de Campina Grande

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Departamento de Ciência da Computação

Isadora Beatriz Lucena de Medeiros

Jennifer Raysa Medeiros Cavalcanti

Oscar Rodrigues da Silva Neto

MODELAGEM DO NÚMERO DE CANDIDATURAS EM UNIVERSIDADES DOS ESTADOS UNIDOS POR REGRESSÃO LINEAR MÚLTIPLA

Relatório apresentado à disciplina de *Estatística Aplicada*, período 2026.1.

Profa. Dra. Amanda Gomes
Prof. Dr. Jerfson Bruno
Prof. Dr. Gilberto Matos

Campina Grande – PB
2026

RESUMO

Este trabalho aplica a metodologia de Regressão Linear Múltipla (MRLM) ao conjunto de dados `college`, com o objetivo de modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos a partir de características institucionais, acadêmicas e financeiras. Inicialmente, foi realizada uma análise exploratória univariada e bivariada, incluindo estatísticas descritivas, visualizações gráficas, análise de correlação e verificação da presença de dados ausentes. Em seguida, foi ajustado um modelo inicial contendo todas as variáveis explicativas disponíveis, sendo investigada a presença de multicolinearidade e comparadas especificações alternativas para seleção do modelo final. Os pressupostos da regressão linear foram avaliados por meio da análise dos resíduos, gráfico de envelope simulado e identificação de observações atípicas, de alavanca e influentes. Por fim, foi analisada a contribuição da variável categórica `Private` por meio de variáveis indicadoras (dummies) e foram construídos intervalos de confiança para o valor médio esperado da resposta e intervalos de predição para novas observações, acompanhados de suas interpretações práticas.

Áreas temáticas: estatística aplicada, ciência de dados

Palavras-chave: regressão linear múltipla, análise exploratória, seleção de modelos, multicolinearidade, diagnóstico de resíduos, variáveis dummy

Sumário

1 Introdução 3

2 Metodologia 3

3 Descrição e qualidade dos dados 3

4 Análise exploratória univariada e bivariada 4

4.1 Estatísticas descritivas 4

4.2 Distribuição de Apps e valores extremos 5

4.3 Comparação entre instituições públicas e privadas 6

4.4 Estrutura bivariada inicial 7

5 Modelo inicial 9

5.1 Formulação do modelo 9

5.2 Coeficientes e ajuste global 10

6 Correlação e multicolinearidade 11

7 Seleção do modelo final 13

7.1 Seleção dos modelos 13

7.2 Modelo final selecionado 13

8 Validação cruzada K-Fold 15

9 Interpretação dos coeficientes 15

10 Diagnóstico do modelo 15

11 QQ Plot e normalidade dos resíduos 15

12 Pontos atípicos, de alavanca e influentes 15

13 Previsões 15

14 Conclusão 15

Referências 15

1 Introdução

O número de candidaturas recebidas por uma instituição de ensino superior pode ser considerado um indicador de sua demanda e de sua atratividade entre potenciais estudantes. Esse volume pode estar associado a características como porte institucional, custos, perfil acadêmico dos ingressantes, qualificação do corpo docente e investimentos realizados pela universidade.

O objetivo deste estudo é investigar a associação entre essas características e o número de candidaturas recebidas por meio da Regressão Linear Múltipla (MRLM). Inicialmente, será ajustado um modelo contendo todas as variáveis explicativas disponíveis, que servirá de referência para as etapas posteriores de seleção, validação e diagnóstico [1].

2 Metodologia

O estudo utiliza dados secundários provenientes da base `College`, disponibilizada no pacote `ISLR` e compilada a partir de informações publicadas pelo *U.S. News & World Report* [2]. A análise foi realizada com os registros originais da base, sem coleta direta ou alteração dos dados brutos.

3 Descrição e qualidade dos dados

A base reúne dados de 777 instituições de ensino superior dos Estados Unidos e contém 18 atributos. A resposta analisada é `Apps`, que corresponde ao número de candidaturas recebidas. Entre os preditores, `Private` é o único categórico e distingue universidades públicas (`No`) e privadas (`Yes`), totalizando 212 e 565 casos, respectivamente. Os demais atributos são numéricos e abrangem informações sobre admissão, quantidade de estudantes, custos, perfil acadêmico, corpo docente e investimentos. A Tabela 1 apresenta a descrição e a unidade de cada campo.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
Private	Categoria	Natureza da instituição: No = pública; Yes = privada.
Apps	Contagem	Candidaturas recebidas; variável resposta.
Accept	Contagem	Candidaturas aceitas.
Enroll	Contagem	Novos alunos matriculados.
Top10perc	%	Ingressantes no top 10% da turma do ensino médio.
Top25perc	%	Ingressantes no top 25% da turma do ensino médio.
F.Undergrad	Contagem	Graduandos em tempo integral.
P.Undergrad	Contagem	Graduandos em tempo parcial.
Outstate	US$	Mensalidade para estudantes de fora do estado.
Room.Board	US$	Custo de moradia e alimentação.
Books	US$	Custo estimado com livros.
Personal	US$	Gasto pessoal estimado.
PhD	%	Corpo docente com doutorado.
Terminal	%	Corpo docente com grau terminal da área.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
S.F.Ratio	Razão	Número de estudantes por docente.
perc.alumni	%	Ex-alunos que realizam doações.
Expend	US$/aluno	Gasto institucional por aluno.
Grad.Rate	%	Taxa de graduação.

A Tabela 2 sintetiza as verificações de completude, duplicidade, faixas e relações lógicas entre as variáveis.

Tabela 2: Síntese das verificações de qualidade dos dados.

Verificação	Critério	Ocorrências
Valores ausentes	Nenhum	0
Linhas duplicadas	Nenhuma	0
Enroll > Accept	Nenhum caso esperado	0
Accept > Apps	Nenhum caso esperado	0
Top10perc > Top25perc	Nenhum caso esperado	0
Percentuais fora de [0, 100]	Requer conferência	2

Os resultados permitem utilizar todas as observações sem imputação ou correção prévia. As únicas ressalvas são `Grad.Rate = 118`, na observação 96, e `PhD = 103`, na observação 583; sem informação que confirme sua origem, ambos foram preservados para posterior análise de sensibilidade.

Tabela 3: Observações com percentuais superiores a 100.

Observação	Private	Apps	Accept	Enroll	PhD	Terminal	Grad.Rate
96	Privada	3847	3433	527	22	47	118
583	Pública	529	481	243	103	88	43

4 Análise exploratória univariada e bivariada

4.1 Estatísticas descritivas

As estatísticas da Tabela 4 mostram heterogeneidade entre as instituições e assimetria à direita nas principais medidas de demanda e porte. Em `Apps`, por exemplo, a média é quase o dobro da mediana, indicando que poucas instituições com demanda muito elevada deslocam a média para cima.

Tabela 4: Estatísticas descritivas das variáveis numéricas.

Variável	Média	DP	Mín.	Q1	Mediana	Q3	Máx.
Apps	3.001,6	3.870,2	81,0	776,0	1.558,0	3.624,0	48.094,0
Accept	2.018,8	2.451,1	72,0	604,0	1.110,0	2.424,0	26.330,0
Enroll	780,0	929,2	35,0	242,0	434,0	902,0	6.392,0
Top10perc	27,6	17,6	1,0	15,0	23,0	35,0	96,0
Top25perc	55,8	19,8	9,0	41,0	54,0	69,0	100,0
F.Undergrad	3.699,9	4.850,4	139,0	992,0	1.707,0	4.005,0	31.643,0
P.Undergrad	855,3	1.522,4	1,0	95,0	353,0	967,0	21.836,0
Outstate	10.440,7	4.023,0	2.340,0	7.320,0	9.990,0	12.925,0	21.700,0
Room.Board	4.357,5	1.096,7	1.780,0	3.597,0	4.200,0	5.050,0	8.124,0
Books	549,4	165,1	96,0	470,0	500,0	600,0	2.340,0
Personal	1.340,6	677,1	250,0	850,0	1.200,0	1.700,0	6.800,0
PhD	72,7	16,3	8,0	62,0	75,0	85,0	103,0
Terminal	79,7	14,7	24,0	71,0	82,0	92,0	100,0
S.F.Ratio	14,1	4,0	2,5	11,5	13,6	16,5	39,8
perc.alumni	22,7	12,4	0,0	13,0	21,0	31,0	64,0
Expend	9.660,2	5.221,8	3.186,0	6.751,0	8.377,0	10.830,0	56.233,0
Grad.Rate	65,5	17,2	10,0	53,0	65,0	78,0	118,0

4.2 Distribuição de Apps e valores extremos

`Apps` varia de 81 a 48.094 candidaturas, com média de 3.001,6, mediana de 1.558 e assimetria amostral de 3,72. A Figura 1 confirma a forte cauda à direita.

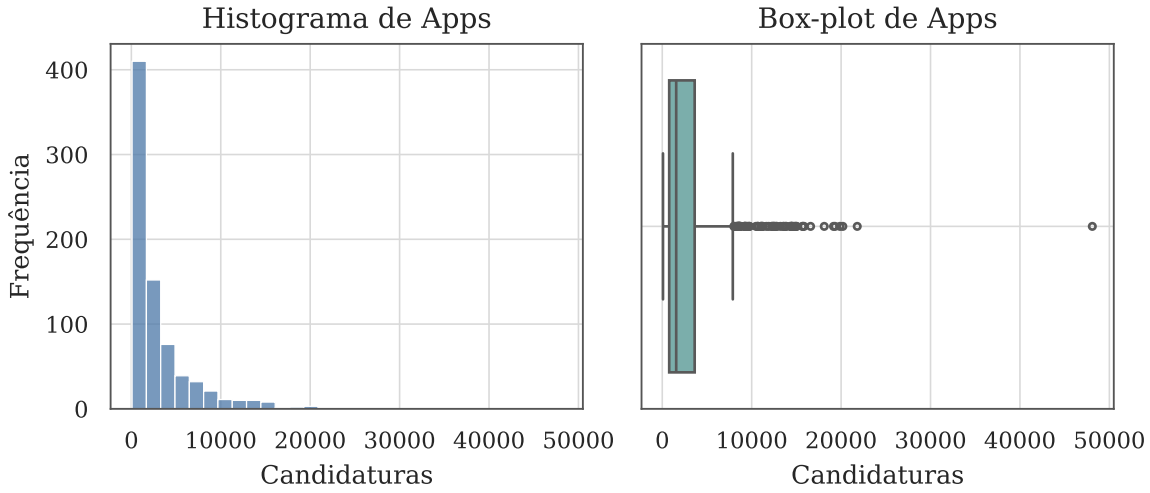


Figura 1. Histograma e box-plot do número de candidaturas recebidas.

Pela regra de $1{,}5\,AIQ$, 70 instituições, aproximadamente 9% da amostra, superam 7.896 candidaturas. Os cinco maiores valores constam na Tabela 5; eles caracterizam a heterogeneidade da base e não são tratados automaticamente como erros.

Tabela 5: Cinco observações com os maiores valores de Apps.

Observação	Private	Apps	Accept	Enroll	F.Undergrad	Grad.Rate
484	Pública	48094	26330	4520	21401	77
462	Pública	21804	18744	5874	26213	67
60	Privada	20192	13007	3810	14971	72
606	Pública	19873	8252	3215	19532	78
446	Pública	19315	10344	3450	28938	63

4.3 Comparação entre instituições públicas e privadas

As instituições públicas apresentam maior número típico de candidaturas: as medianas são 4.307 nas públicas e 1.133 nas privadas. A Tabela 6 amplia a comparação para medidas de admissão, porte, mensalidade e investimento.

Tabela 6: Média e desvio-padrão de variáveis selecionadas, por natureza da instituição.

Instituição	Variável	Média	DP
Pública	Apps	5.729,9	5.370,7
Privada	Apps	1.977,9	2.443,3
Pública	Accept	3.919,3	3.477,3
Privada	Accept	1.305,7	1.369,5
Pública	Enroll	1.640,9	1.261,6
Privada	Enroll	456,9	457,5
Pública	F.Undergrad	8.571,0	6.467,7
Privada	F.Undergrad	1.872,2	2.110,7
Pública	Outstate	6.813,4	2.145,2
Privada	Outstate	11.801,7	3.707,5
Pública	Expend	7.458,3	2.695,5
Privada	Expend	10.486,4	5.682,6

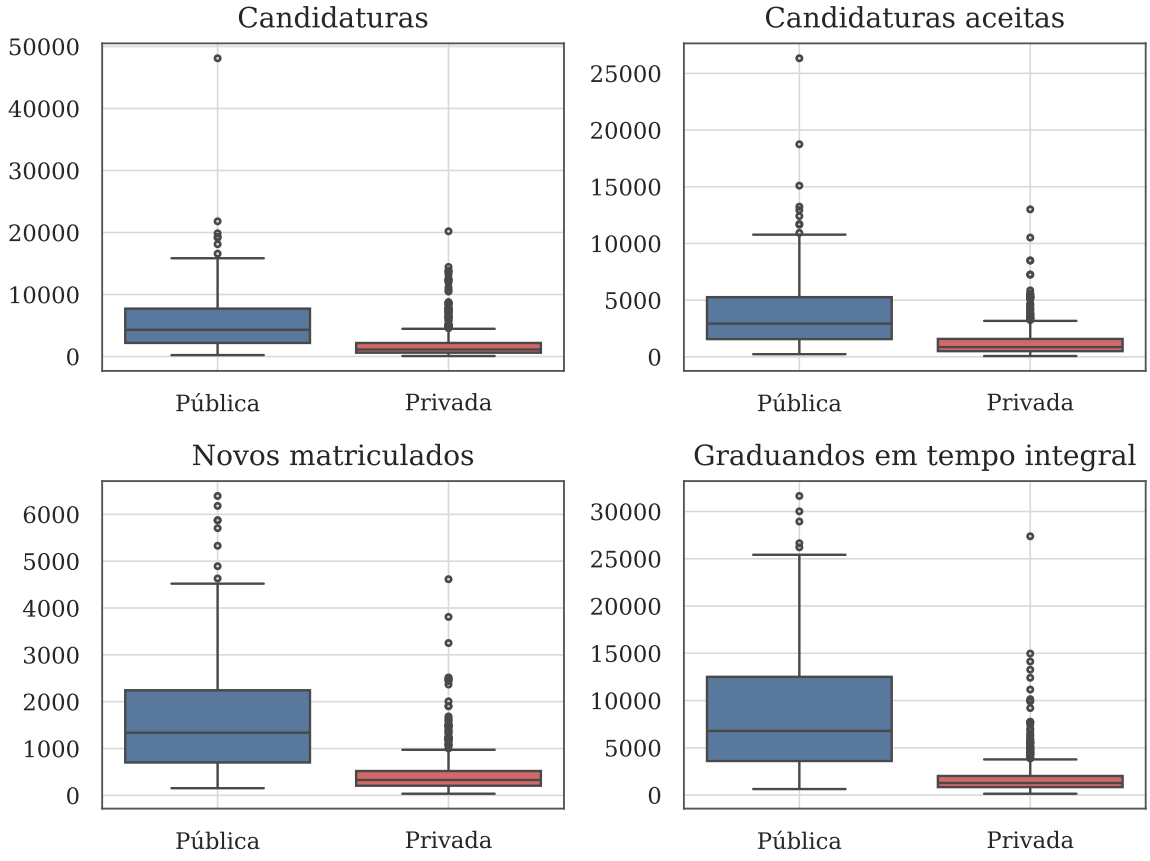


Figura 2. Box-plots de medidas de demanda e porte, por natureza da instituição.

As públicas apresentam maiores médias de demanda e porte, enquanto as privadas possuem maiores médias de `Outstate` e `Expend`. Esse contraste sugere perfis institucionais distintos e indica que a diferença bruta em `Apps` também pode refletir porte, custos e investimento; trata-se, portanto, de comparação descritiva, sem interpretação causal.

4.4 Estrutura bivariada inicial

A Figura 3 resume as associações lineares iniciais. `Apps` apresenta relações positivas mais intensas com `Accept`, `Enroll` e `F.Undergrad`, variáveis ligadas ao processo de admissão e ao porte da instituição.

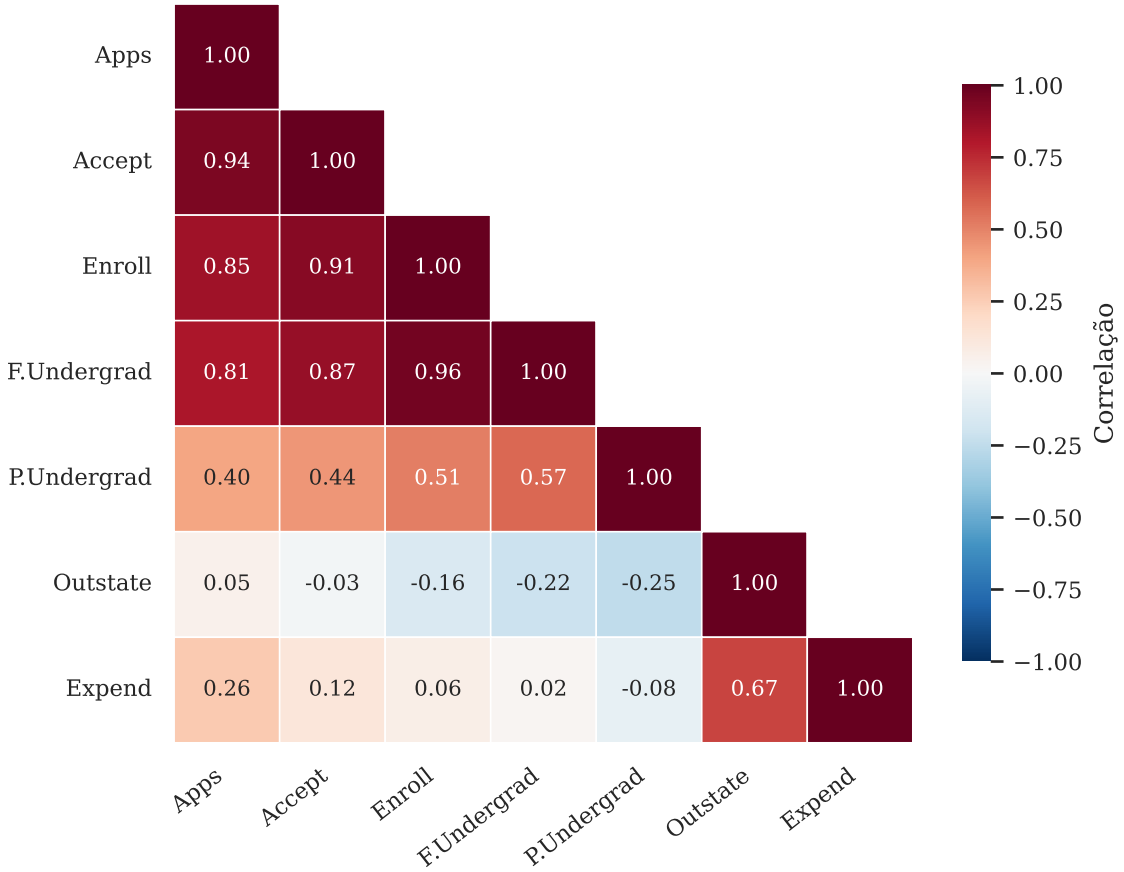


Figura 3. Matriz exploratória de correlações entre Apps e variáveis selecionadas.

A Figura 4 complementa o resumo ao mostrar a forma das relações, as distribuições marginais e os grupos público e privado. As tendências são predominantemente crescentes, mas a variabilidade de `Apps` aumenta nos níveis mais altos dos preditores.

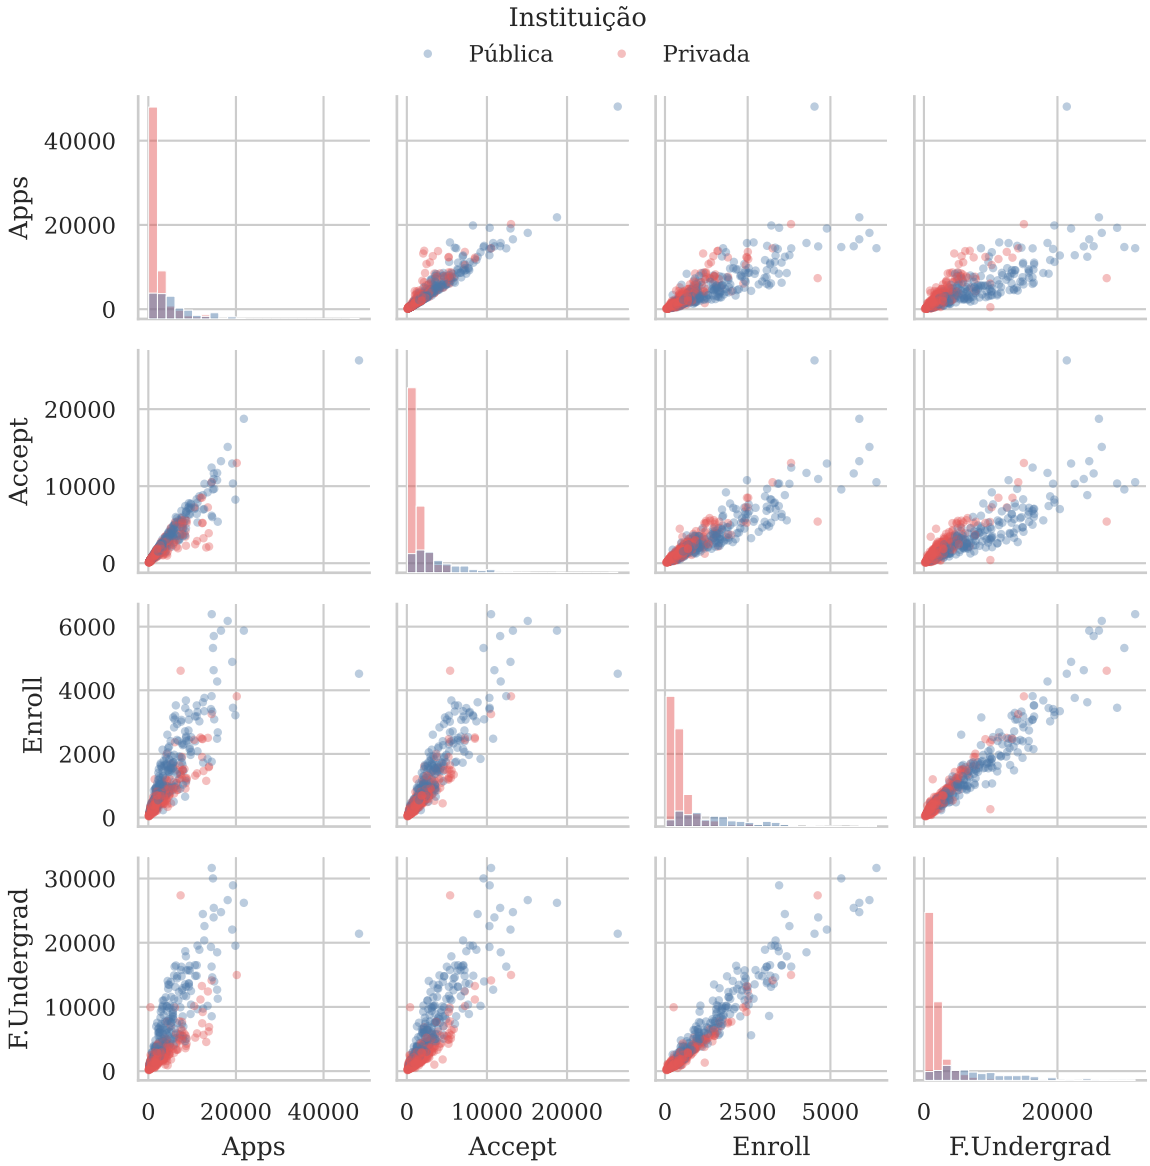


Figura 4. Matriz de dispersão de medidas de demanda e porte, por natureza da instituição.

Esses gráficos constituem apenas uma triagem; a avaliação formal permanece reservada à seção de correlação e multicolinearidade.

5 Modelo inicial

O modelo inicial inclui os 16 preditores numéricos e a variável categórica `Private`. Para sua incorporação, foi definida `Private_Yes = 1` para instituições privadas e 0 para públicas, tornando as instituições públicas a categoria de referência. O ajuste foi realizado por mínimos quadrados ordinários com as 777 observações, sem seleção ou remoção de variáveis.

5.1 Formulação do modelo

Seja x_{ij} o valor do j-ésimo preditor numérico para a instituição i. A forma geral do modelo completo é:

$$\text{Apps}_i = \beta_0 + \beta_1 \text{Private_Yes}_i + \sum_{j=2}^{17} \beta_j x_{ij} + \varepsilon_i.$$

Nessa expressão, cada β_j representa uma associação parcial com `Apps`, mantidos os demais preditores constantes, e ε_i reúne a variação não explicada pelo modelo.

5.2 Coeficientes e ajuste global

As estimativas dos coeficientes, erros-padrão, estatísticas de teste e intervalos de confiança são apresentadas na Tabela 7.

Tabela 7: Estimativas do modelo linear inicial com todos os preditores.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-445,084	408,329	-1,090	0,276	-1.246,672	356,503
Accept	1,586	0,041	38,924	< 0,001	1,506	1,666
Enroll	-0,881	0,186	-4,736	< 0,001	-1,246	-0,516
Top10perc	49,926	5,578	8,950	< 0,001	38,976	60,877
Top25perc	-14,234	4,479	-3,178	0,002	-23,027	-5,441
F.Undergrad	0,057	0,033	1,754	0,080	-0,007	0,122
P.Undergrad	0,044	0,032	1,383	0,167	-0,019	0,108
Outstate	-0,086	0,019	-4,506	< 0,001	-0,123	-0,048
Room.Board	0,151	0,048	3,127	0,002	0,056	0,246
Books	0,021	0,238	0,088	0,930	-0,447	0,489
Personal	0,031	0,063	0,493	0,622	-0,093	0,155
PhD	-8,678	4,638	-1,871	0,062	-17,784	0,427
Terminal	-3,331	5,095	-0,654	0,513	-13,333	6,671
S.F.Ratio	15,390	13,006	1,183	0,237	-10,143	40,922
perc.alumni	0,179	4,102	0,044	0,965	-7,875	8,232
Expend	0,078	0,012	6,308	< 0,001	0,054	0,102
Grad.Rate	8,668	2,949	2,939	0,003	2,879	14,457
Privada (Yes versus No)	-494,149	137,812	-3,586	< 0,001	-764,687	-223,611

O R^2 ajustado de 0,9276 indica que o conjunto de preditores descreve 92,76% da variação amostral de `Apps`; o teste global confirma que o modelo possui contribuição explicativa ($F = 585{,}86$; $p < 0{,}001$). Ao nível de 5%, `Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `Expend`, `Grad.Rate` e `Private_Yes` apresentam coeficientes significativos.

Mantidos os demais preditores constantes, o coeficiente de `Private_Yes` associa instituições privadas a cerca de 494 candidaturas a menos que instituições públicas. Essa interpretação é preliminar: a proximidade entre variáveis de admissão e porte pode afetar sinais e erros-padrão, razão pela qual nenhum preditor é removido nesta etapa.

6 Correlação e multicolinearidade

Embora o modelo inicial apresente elevado poder explicativo, coeficientes individuais podem tornar-se instáveis quando existem preditores fortemente correlacionados entre si. Assim, antes da seleção do modelo final, investigou-se a presença de multicolinearidade por meio da matriz de correlação entre os preditores e do Fator de Inflação da Variância (VIF).

Inicialmente foi construída a matriz de correlação de Pearson para as variáveis numéricas. Em seguida, calculou-se o VIF para cada variável do modelo inicial, adotando como referência o valor 10 como indicativo de multicolinearidade severa.

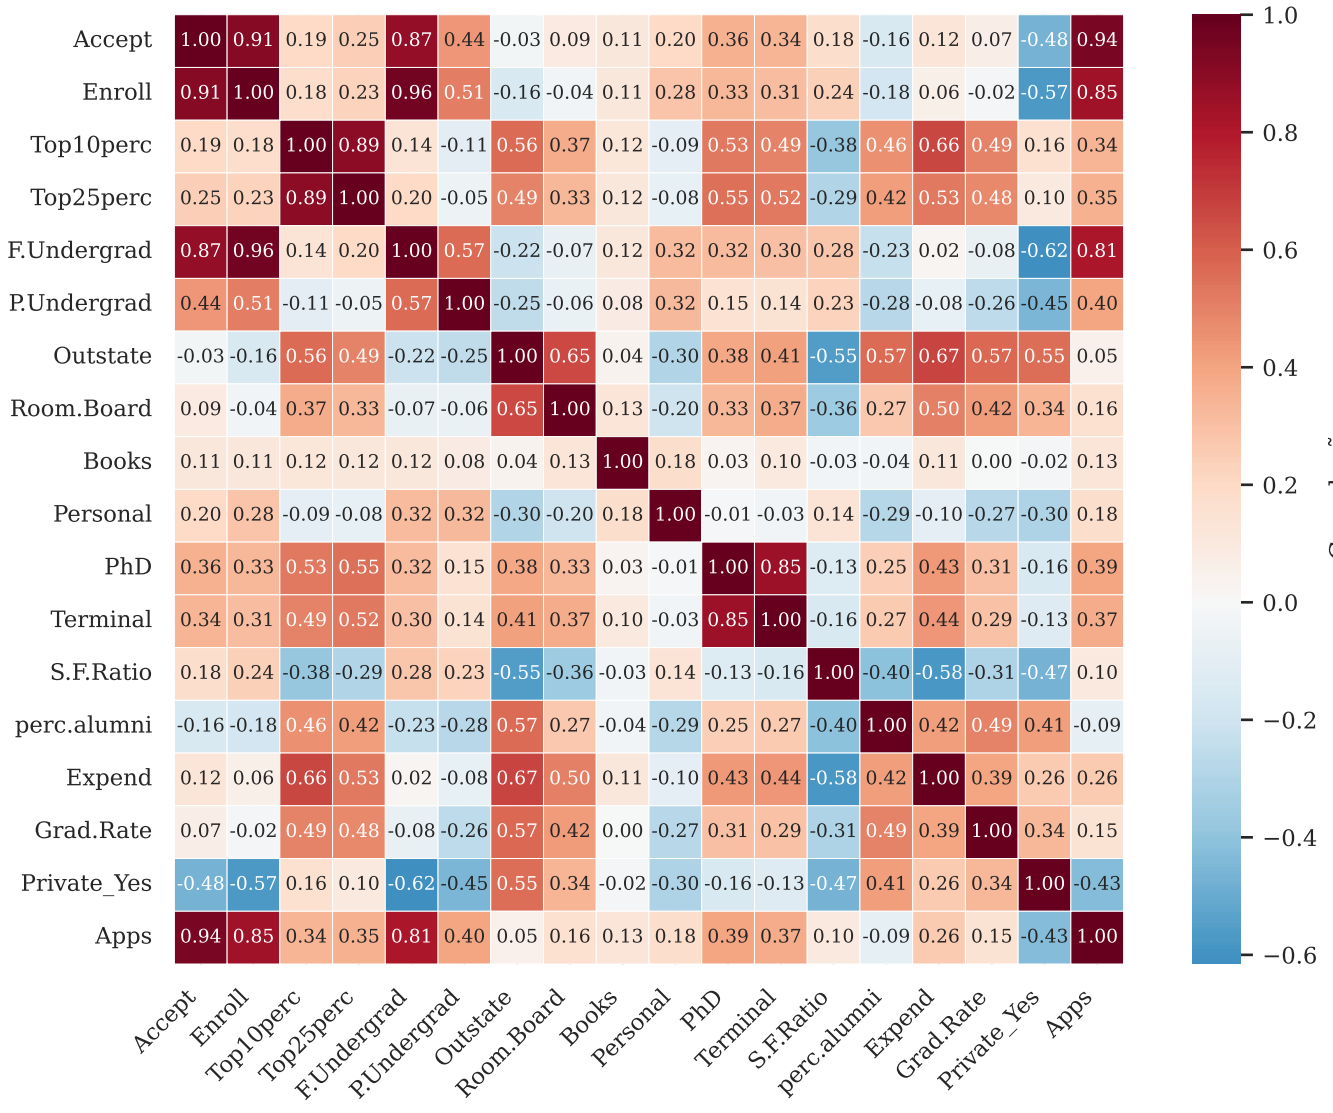


Figura 5. Matriz de correlação de Pearson entre as variáveis numéricas.

A Figura 5 apresenta a matriz de correlação de Pearson entre as variáveis do modelo inicial. Observam-se correlações elevadas entre variáveis relacionadas ao processo de admissão, ao porte institucional e ao perfil acadêmico das universidades. Destacam-se as associações entre Accept e Enroll ($r = 0,91$), Enroll e F.Undergrad ($r = 0,96$), Accept e F.Undergrad ($r = 0,87$), Top10perc e Top25perc ($r = 0,89$), além de PhD e Terminal ($r = 0,85$). Também se observa forte correlação entre Apps e Accept ($r = 0,94$), resultado esperado,

uma vez que universidades que recebem mais candidaturas tendem a aceitar maior número de estudantes. Esses padrões sugerem a possibilidade de multicolinearidade entre alguns preditores, justificando sua avaliação formal por meio do Fator de Inflação da Variância (VIF).

Fator de Inflação da Variância (VIF)

Para complementar a análise da matriz de correlação, calculou-se o Fator de Inflação da Variância (VIF) para cada preditor do modelo inicial. O VIF mede o quanto a variância do estimador de um coeficiente é inflacionada em decorrência da dependência linear entre as variáveis explicativas. Como referência , valores superiores a 5 indicam multicolinearidade moderada, enquanto valores acima de 10 são usualmente considerados evidência de multicolinearidade severa.

Tabela 8: Fator de Inflação da Variância (VIF) para os preditores do modelo inicial.

Variável	VIF
Enroll	21,37
F.Undergrad	18,02
Accept	7,14
Top10perc	6,93
Top25perc	5,63
Outstate	4,21
PhD	4,10
Terminal	4,03
Expend	2,98
Private_Yes	2,70
Room.Board	2,01
S.F.Ratio	1,90
perc.alumni	1,85
Grad.Rate	1,84
P.Undergrad	1,71
Personal	1,31
Books	1,11

A Tabela 8 apresenta os fatores de inflação da variância (VIF) dos preditores do modelo inicial. Os maiores valores foram observados para Enroll (VIF = 21,37) e F.Undergrad (VIF = 18,02), ambos superiores ao limite de referência igual a 10, indicando multicolinearidade severa. Esses resultados são consistentes com a matriz de correlação, na qual essas variáveis apresentam elevada associação entre si ($r = 0,96$) e também com Accept ($r = 0,91$ e $r = 0,87$, respectivamente).

Também foram observados valores relativamente elevados para Accept (7,14), Top10perc (6,93) e Top25perc (5,63). Embora inferiores ao limite de 10, esses resultados sugerem correlação moderada entre esses preditores, o que pode aumentar a variabilidade das estimativas dos coeficientes.

Os demais preditores apresentaram valores de VIF inferiores a 5, indicando ausência de problemas relevantes de multicolinearidade. Em conjunto, os resultados mostram que a principal fonte de colinearidade do modelo está associada às variáveis que representam diferentes dimensões do porte institucional e do processo de admissão.

Dessa forma, a seleção do modelo final deverá considerar não apenas critérios de ajuste, como AIC e BIC, mas também a redução da multicolinearidade, buscando um modelo mais parcimonioso e com coeficientes mais estáveis.

7 Seleção do modelo final

7.1 Seleção dos modelos

Embora o modelo inicial apresente elevado poder explicativo, ele contém um número relativamente grande de preditores, alguns dos quais apresentam multicolinearidade elevada. Assim, buscou-se uma especificação mais parcimoniosa, capaz de manter o desempenho preditivo ao mesmo tempo em que reduz a complexidade do modelo.

Para isso, foram comparados diferentes modelos utilizando critérios estatísticos de seleção, incluindo o Critério de Informação de Akaike (AIC), o Critério de Informação Bayesiano (BIC), o coeficiente de determinação ajustado (R^2_{aj}) e o procedimento de eliminação retroativa (backward). Posteriormente, os modelos foram avaliados por validação cruzada K-Fold.

Tabela 9: Comparação dos modelos obtidos pelos diferentes critérios de seleção.

Modelo	Variáveis	AIC	BIC	R^2	R^2_{ajustado}
Completo	17	13.020,429	13.104,227	0,929	0,928
Backward	11	13.012,670	13.068,536	0,929	0,928
AIC	12	13.012,557	13.073,077	0,929	0,928
BIC	10	13.016,008	13.067,218	0,928	0,927

A Tabela 9 sintetiza as métricas de ajuste para as quatro especificações avaliadas. O modelo Completo (17 preditores) apresenta AIC de $13.020,429$, enquanto o procedimento de eliminação retroativa (Backward) reduz o conjunto para 11 preditores com AIC de $13.012,670$. O procedimento Stepwise (AIC) retém 12 variáveis, ao passo que o Stepwise (BIC) seleciona uma estrutura mais concisa contendo 10 preditores. O modelo parcimonioso obtido pelo critério BIC penaliza com maior rigor a inclusão de parâmetros adicionais, alcançando $13.067,218$ no BIC e $R^2_{\text{ajustado}} = 0,927$. A perda no coeficiente de determinação ajustado é inferior a $0,1\%$ em relação ao modelo completo ($0,928$), com a vantagem decisiva de eliminar a variável F.Undergrad, principal fonte de multicolinearidade severa (VIF $= 18,02$).

7.2 Modelo final selecionado

Para definir o modelo final, além dos critérios de ajuste apresentados anteriormente, a multicolinearidade dos modelos selecionados também foi reavaliada por meio do Fator de Inflação da Variância (VIF).

Tabela 10: Maior valor do Fator de Inflação da Variância (VIF) em cada modelo avaliado.

Modelo	Maior VIF
Backward	21,05
Stepwise (AIC)	21,15
Stepwise (BIC)	7,58

A Tabela 10 mostra que os modelos **Backward** e **Stepwise (AIC)** mantêm simultaneamente as variáveis `Enroll` e `F.Undergrad`, preservando a multicolinearidade severa observada no modelo completo. Em ambos os casos, os maiores VIFs permanecem próximos de 21 e 17, respectivamente. Já no modelo **Stepwise (BIC)**, a remoção de `F.Undergrad` reduz o maior VIF do conjunto (`Enroll`) para aproximadamente **7,6**, valor inferior ao limite de referência igual a 10. Embora ainda exista alguma correlação entre as variáveis explicativas, a multicolinearidade deixa de ser considerada severa.

Diante desses resultados, o modelo **Stepwise (BIC)** foi escolhido como modelo final. Esse modelo possui 10 variáveis explicativas (`Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `PhD`, `Expend`, `Grad.Rate` e `Private_Yes`) e apresentou o melhor equilíbrio entre qualidade do ajuste, simplicidade e estabilidade dos coeficientes.

A escolha baseia-se em três fatores principais. Primeiro, o modelo é o mais parcimonioso entre os avaliados e apresenta perda praticamente desprezível de capacidade explicativa. Seu (R^2) ajustado é igual a **0,927**, apenas **0,001** inferior ao obtido pelos modelos Completo, Backward e Stepwise (AIC), todos com (R^2) ajustado igual a **0,928**. Segundo, é o único modelo que elimina a multicolinearidade severa identificada no modelo inicial, reduzindo todos os VIFs para valores inferiores a 10. Por fim, embora seu AIC seja ligeiramente superior ao dos modelos Backward e Stepwise (AIC), a diferença é inferior a quatro unidades e considerada pequena. Em contrapartida, esse modelo apresenta o menor BIC entre todas as especificações avaliadas. Como o BIC penaliza de forma mais intensa a inclusão de parâmetros desnecessários, ele favorece modelos mais simples sem comprometer a qualidade do ajuste.

Os demais modelos não foram selecionados pelos seguintes motivos. O modelo **Completo** mantém todas as 17 variáveis explicativas, incluindo preditores sem significância estatística (`Books`, `Personal`, `Terminal`, `perc.alumni`, `F.Undergrad` e `P.Undergrad`), além da forte multicolinearidade entre `Enroll` e `F.Undergrad`. O modelo **Backward** elimina parte dessas variáveis, porém mantém `F.Undergrad`, preservando o problema de colinearidade. Já o modelo **Stepwise (AIC)** apresenta o menor AIC entre os modelos comparados, mas continua incluindo `F.Undergrad` e `P.Undergrad`, tornando o modelo mais complexo sem eliminar a principal fonte de instabilidade dos coeficientes.

É importante destacar uma limitação presente em todas as especificações avaliadas. As variáveis `Accept` e `Enroll` representam etapas posteriores ao recebimento das candidaturas (`Apps`), correspondendo ao número de candidatos aceitos e ao número de alunos efetivamente matriculados. Dessa forma, essas variáveis não representam características institucionais anteriores ao processo de candidatura, limitando uma interpretação estritamente causal do modelo. Entretanto, como essa característica está presente em todos os modelos comparados, ela não interfere na escolha entre eles e, por isso, não foi utilizada como critério de seleção.

Assim, o modelo **Stepwise (BIC)** foi adotado como modelo final deste trabalho e será utilizado nas próximas etapas da análise, incluindo a validação cruzada, a interpretação dos coeficientes, o diagnóstico dos pressupostos e a realização das previsões.

8 Validação cruzada K-Fold

Esta seção avaliará o desempenho preditivo e a estabilidade do modelo selecionado.

9 Interpretação dos coeficientes

Esta seção interpretará os coeficientes do modelo final no contexto das características institucionais.

10 Diagnóstico do modelo

Esta seção verificará a adequação do modelo selecionado aos pressupostos da regressão linear.

11 QQ Plot e normalidade dos resíduos

Esta seção avaliará graficamente a normalidade dos resíduos do modelo.

12 Pontos atípicos, de alavanca e influentes

Esta seção investigará observações atípicas, de alavanca e influentes.

13 Previsões

Esta seção apresentará previsões e respectivos intervalos para perfis plausíveis de instituições.

14 Conclusão

Esta seção sintetizará os principais resultados e retomará a pergunta de pesquisa.

Referências

[1] Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.

[2] James G, Witten D, Hastie T, Tibshirani R. 2021 *An Introduction to Statistical Learning: with Applications in R*. New York: Springer 2 edition.