

Universidade Federal
de Campina Grande

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Departamento de Ciência da Computação

Isadora Beatriz Lucena de Medeiros

Jennifer Raysa Medeiros Cavalcanti

Oscar Rodrigues da Silva Neto

MODELAGEM DO NÚMERO DE CANDIDATURAS EM UNIVERSIDADES DOS ESTADOS UNIDOS POR REGRESSÃO LINEAR MÚLTIPLA

Relatório apresentado à disciplina de *Estatística Aplicada*, período 2026.1.

Profa. Dra. Amanda Gomes
Prof. Dr. Jerfson Bruno
Prof. Dr. Gilberto Matos

Campina Grande – PB
2026

RESUMO

Este trabalho aplica a metodologia de Regressão Linear Múltipla (MRLM) ao conjunto de dados `college`, com o objetivo de modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos a partir de características institucionais, acadêmicas e financeiras. Inicialmente, foi realizada uma análise exploratória univariada e bivariada, incluindo estatísticas descritivas, visualizações gráficas, análise de correlação e verificação da presença de dados ausentes. Em seguida, foi ajustado um modelo inicial contendo todas as variáveis explicativas disponíveis, sendo investigada a presença de multicolinearidade e comparadas especificações alternativas para seleção do modelo final. Os pressupostos da regressão linear foram avaliados por meio da análise dos resíduos, gráfico de envelope simulado e identificação de observações atípicas, de alavanca e influentes. Por fim, foi analisada a contribuição da variável categórica `Private` por meio de variáveis indicadoras (dummies) e foram construídos intervalos de confiança para o valor médio esperado da resposta e intervalos de predição para novas observações, acompanhados de suas interpretações práticas.

Áreas temáticas: estatística aplicada, ciência de dados

Palavras-chave: regressão linear múltipla, análise exploratória, seleção de modelos, multicolinearidade, diagnóstico de resíduos, variáveis dummy

Sumário

1 Introdução 3

2 Metodologia 3

3 Descrição e qualidade dos dados 3

4 Análise exploratória univariada e bivariada 4

4.1 Estatísticas descritivas 4

4.2 Distribuição de Apps e valores extremos 5

4.3 Comparação entre instituições públicas e privadas 6

4.4 Estrutura bivariada inicial 7

5 Modelo inicial 9

5.1 Formulação do modelo 9

5.2 Coeficientes e ajuste global 10

6 Correlação e multicolinearidade 11

7 Seleção do modelo final 13

7.1 Seleção dos modelos 13

7.2 Modelo final selecionado 13

8 Validação cruzada K-Fold 15

9 Interpretação dos coeficientes 15

10 Diagnóstico do modelo 17

11 QQ Plot e normalidade dos resíduos 18

12 Pontos atípicos, de alavanca e influentes 20

13 Previsões 21

14 Conclusão 22

Referências 23

1 Introdução

O número de candidaturas recebidas por uma instituição de ensino superior pode ser considerado um indicador de sua demanda e de sua atratividade entre potenciais estudantes. Esse volume pode estar associado a características como porte institucional, custos, perfil acadêmico dos ingressantes, qualificação do corpo docente e investimentos realizados pela universidade.

O objetivo deste estudo é investigar a associação entre essas características e o número de candidaturas recebidas por meio da Regressão Linear Múltipla (MRLM). Inicialmente, será ajustado um modelo contendo todas as variáveis explicativas disponíveis, que servirá de referência para as etapas posteriores de seleção, validação e diagnóstico [1].

2 Metodologia

O estudo utiliza dados secundários provenientes da base `College`, disponibilizada no pacote `ISLR` e compilada a partir de informações publicadas pelo *U.S. News & World Report* [2]. A análise foi realizada com os registros originais da base, sem coleta direta ou alteração dos dados brutos.

3 Descrição e qualidade dos dados

A base reúne dados de 777 instituições de ensino superior dos Estados Unidos e contém 18 atributos. A resposta analisada é `Apps`, que corresponde ao número de candidaturas recebidas. Entre os preditores, `Private` é o único categórico e distingue universidades públicas (`No`) e privadas (`Yes`), totalizando 212 e 565 casos, respectivamente. Os demais atributos são numéricos e abrangem informações sobre admissão, quantidade de estudantes, custos, perfil acadêmico, corpo docente e investimentos. A Tabela 1 apresenta a descrição e a unidade de cada campo.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
Private	Categoria	Natureza da instituição: No = pública; Yes = privada.
Apps	Contagem	Candidaturas recebidas; variável resposta.
Accept	Contagem	Candidaturas aceitas.
Enroll	Contagem	Novos alunos matriculados.
Top10perc	%	Ingressantes no top 10% da turma do ensino médio.
Top25perc	%	Ingressantes no top 25% da turma do ensino médio.
F.Undergrad	Contagem	Graduandos em tempo integral.
P.Undergrad	Contagem	Graduandos em tempo parcial.
Outstate	US$	Mensalidade para estudantes de fora do estado.
Room.Board	US$	Custo de moradia e alimentação.
Books	US$	Custo estimado com livros.
Personal	US$	Gasto pessoal estimado.
PhD	%	Corpo docente com doutorado.
Terminal	%	Corpo docente com grau terminal da área.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
S.F.Ratio	Razão	Número de estudantes por docente.
perc.alumni	%	Ex-alunos que realizam doações.
Expend	US$/aluno	Gasto institucional por aluno.
Grad.Rate	%	Taxa de graduação.

A Tabela 2 sintetiza as verificações de completude, duplicidade, faixas e relações lógicas entre as variáveis.

Tabela 2: Síntese das verificações de qualidade dos dados.

Verificação	Critério	Ocorrências
Valores ausentes	Nenhum	0
Linhas duplicadas	Nenhuma	0
Enroll > Accept	Nenhum caso esperado	0
Accept > Apps	Nenhum caso esperado	0
Top10perc > Top25perc	Nenhum caso esperado	0
Percentuais fora de [0, 100]	Requer conferência	2

Os resultados permitem utilizar todas as observações sem imputação ou correção prévia. As únicas ressalvas são `Grad.Rate = 118`, na observação 96, e `PhD = 103`, na observação 583; sem informação que confirme sua origem, ambos foram preservados para posterior análise de sensibilidade.

Tabela 3: Observações com percentuais superiores a 100.

Observação	Private	Apps	Accept	Enroll	PhD	Terminal	Grad.Rate
96	Privada	3847	3433	527	22	47	118
583	Pública	529	481	243	103	88	43

4 Análise exploratória univariada e bivariada

4.1 Estatísticas descritivas

As estatísticas da Tabela 4 mostram heterogeneidade entre as instituições e assimetria à direita nas principais medidas de demanda e porte. Em `Apps`, por exemplo, a média é quase o dobro da mediana, indicando que poucas instituições com demanda muito elevada deslocam a média para cima.

Tabela 4: Estatísticas descritivas das variáveis numéricas.

Variável	Média	DP	Mín.	Q1	Mediana	Q3	Máx.
Apps	3.001,6	3.870,2	81,0	776,0	1.558,0	3.624,0	48.094,0
Accept	2.018,8	2.451,1	72,0	604,0	1.110,0	2.424,0	26.330,0
Enroll	780,0	929,2	35,0	242,0	434,0	902,0	6.392,0
Top10perc	27,6	17,6	1,0	15,0	23,0	35,0	96,0
Top25perc	55,8	19,8	9,0	41,0	54,0	69,0	100,0
F.Undergrad	3.699,9	4.850,4	139,0	992,0	1.707,0	4.005,0	31.643,0
P.Undergrad	855,3	1.522,4	1,0	95,0	353,0	967,0	21.836,0
Outstate	10.440,7	4.023,0	2.340,0	7.320,0	9.990,0	12.925,0	21.700,0
Room.Board	4.357,5	1.096,7	1.780,0	3.597,0	4.200,0	5.050,0	8.124,0
Books	549,4	165,1	96,0	470,0	500,0	600,0	2.340,0
Personal	1.340,6	677,1	250,0	850,0	1.200,0	1.700,0	6.800,0
PhD	72,7	16,3	8,0	62,0	75,0	85,0	103,0
Terminal	79,7	14,7	24,0	71,0	82,0	92,0	100,0
S.F.Ratio	14,1	4,0	2,5	11,5	13,6	16,5	39,8
perc.alumni	22,7	12,4	0,0	13,0	21,0	31,0	64,0
Expend	9.660,2	5.221,8	3.186,0	6.751,0	8.377,0	10.830,0	56.233,0
Grad.Rate	65,5	17,2	10,0	53,0	65,0	78,0	118,0

4.2 Distribuição de Apps e valores extremos

`Apps` varia de 81 a 48.094 candidaturas, com média de 3.001,6, mediana de 1.558 e assimetria amostral de 3,72. A Figura 1 confirma a forte cauda à direita.

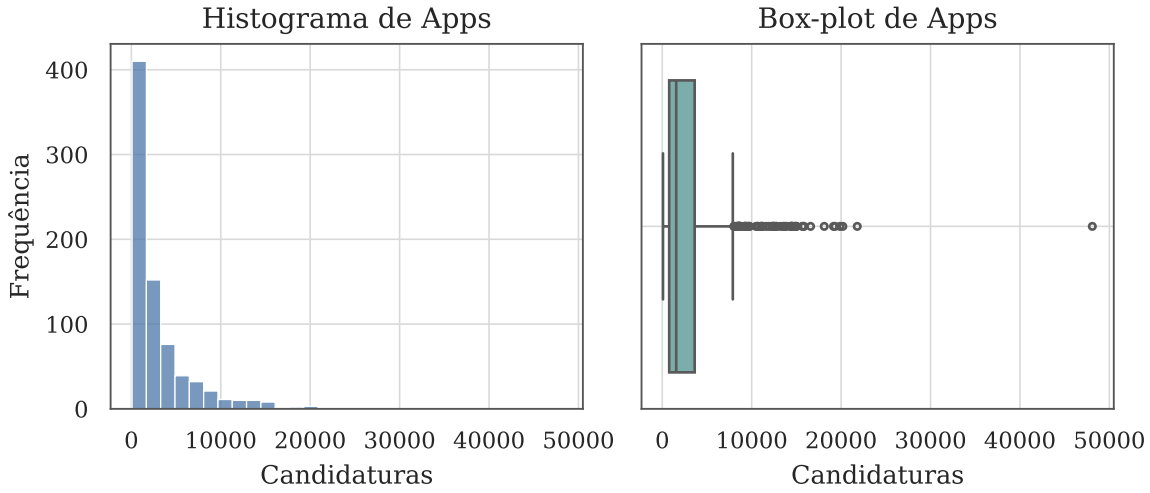


Figura 1. Histograma e box-plot do número de candidaturas recebidas.

Pela regra de $1{,}5\,AIQ$, 70 instituições, aproximadamente 9% da amostra, superam 7.896 candidaturas. Os cinco maiores valores constam na Tabela 5; eles caracterizam a heterogeneidade da base e não são tratados automaticamente como erros.

Tabela 5: Cinco observações com os maiores valores de Apps.

Observação	Private	Apps	Accept	Enroll	F.Undergrad	Grad.Rate
484	Pública	48094	26330	4520	21401	77
462	Pública	21804	18744	5874	26213	67
60	Privada	20192	13007	3810	14971	72
606	Pública	19873	8252	3215	19532	78
446	Pública	19315	10344	3450	28938	63

4.3 Comparação entre instituições públicas e privadas

As instituições públicas apresentam maior número típico de candidaturas: as medianas são 4.307 nas públicas e 1.133 nas privadas. A Tabela 6 amplia a comparação para medidas de admissão, porte, mensalidade e investimento.

Tabela 6: Média e desvio-padrão de variáveis selecionadas, por natureza da instituição.

Instituição	Variável	Média	DP
Pública	Apps	5.729,9	5.370,7
Privada	Apps	1.977,9	2.443,3
Pública	Accept	3.919,3	3.477,3
Privada	Accept	1.305,7	1.369,5
Pública	Enroll	1.640,9	1.261,6
Privada	Enroll	456,9	457,5
Pública	F.Undergrad	8.571,0	6.467,7
Privada	F.Undergrad	1.872,2	2.110,7
Pública	Outstate	6.813,4	2.145,2
Privada	Outstate	11.801,7	3.707,5
Pública	Expend	7.458,3	2.695,5
Privada	Expend	10.486,4	5.682,6

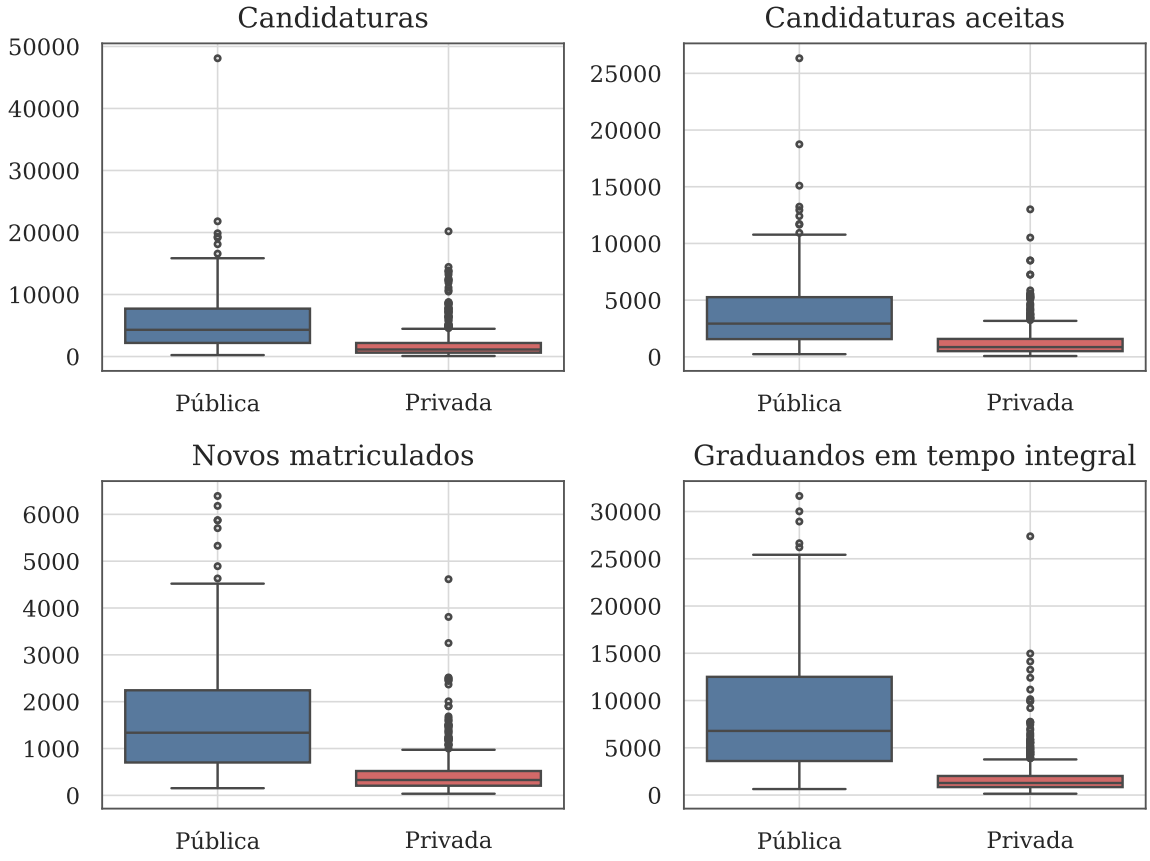


Figura 2. Box-plots de medidas de demanda e porte, por natureza da instituição.

As públicas apresentam maiores médias de demanda e porte, enquanto as privadas possuem maiores médias de `Outstate` e `Expend`. Esse contraste sugere perfis institucionais distintos e indica que a diferença bruta em `Apps` também pode refletir porte, custos e investimento; trata-se, portanto, de comparação descritiva, sem interpretação causal.

4.4 Estrutura bivariada inicial

A Figura 3 resume as associações lineares iniciais. `Apps` apresenta relações positivas mais intensas com `Accept`, `Enroll` e `F.Undergrad`, variáveis ligadas ao processo de admissão e ao porte da instituição.

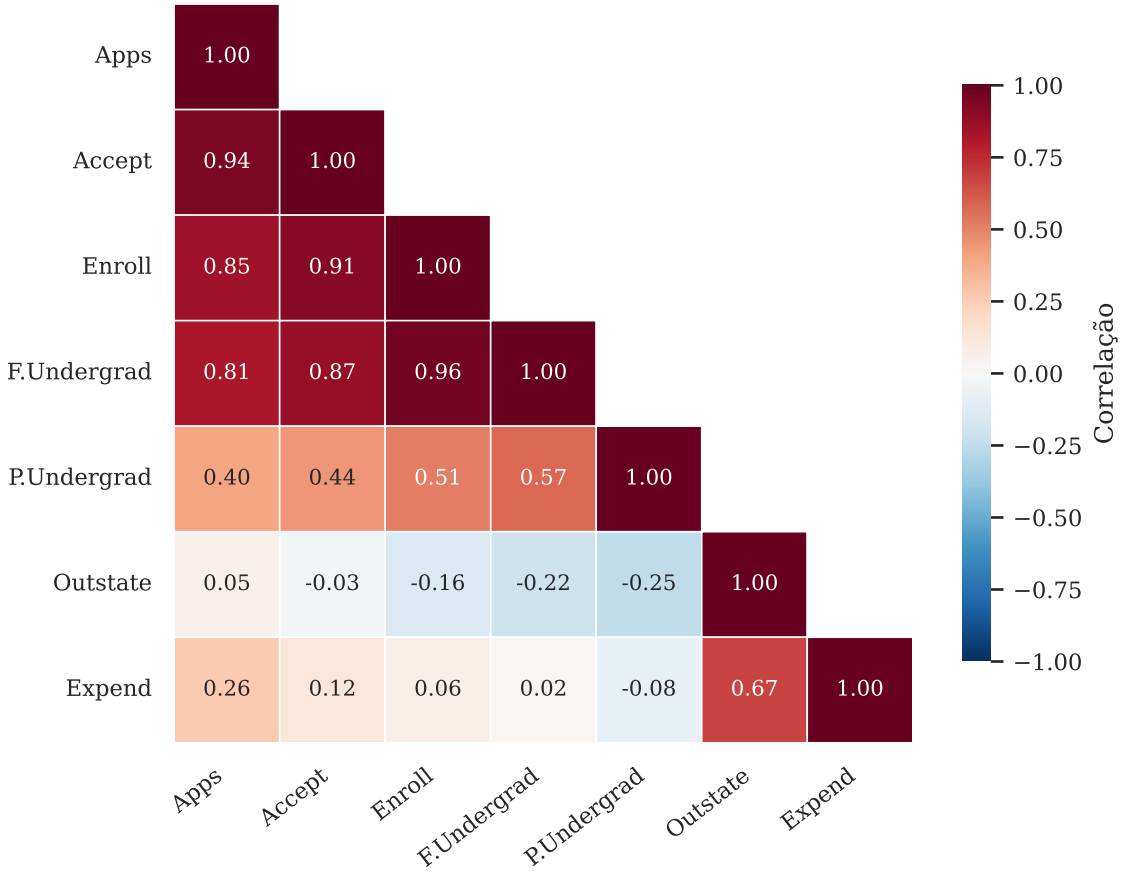


Figura 3. Matriz exploratória de correlações entre Apps e variáveis selecionadas.

A Figura 4 complementa o resumo ao mostrar a forma das relações, as distribuições marginais e os grupos público e privado. As tendências são predominantemente crescentes, mas a variabilidade de `Apps` aumenta nos níveis mais altos dos preditores.

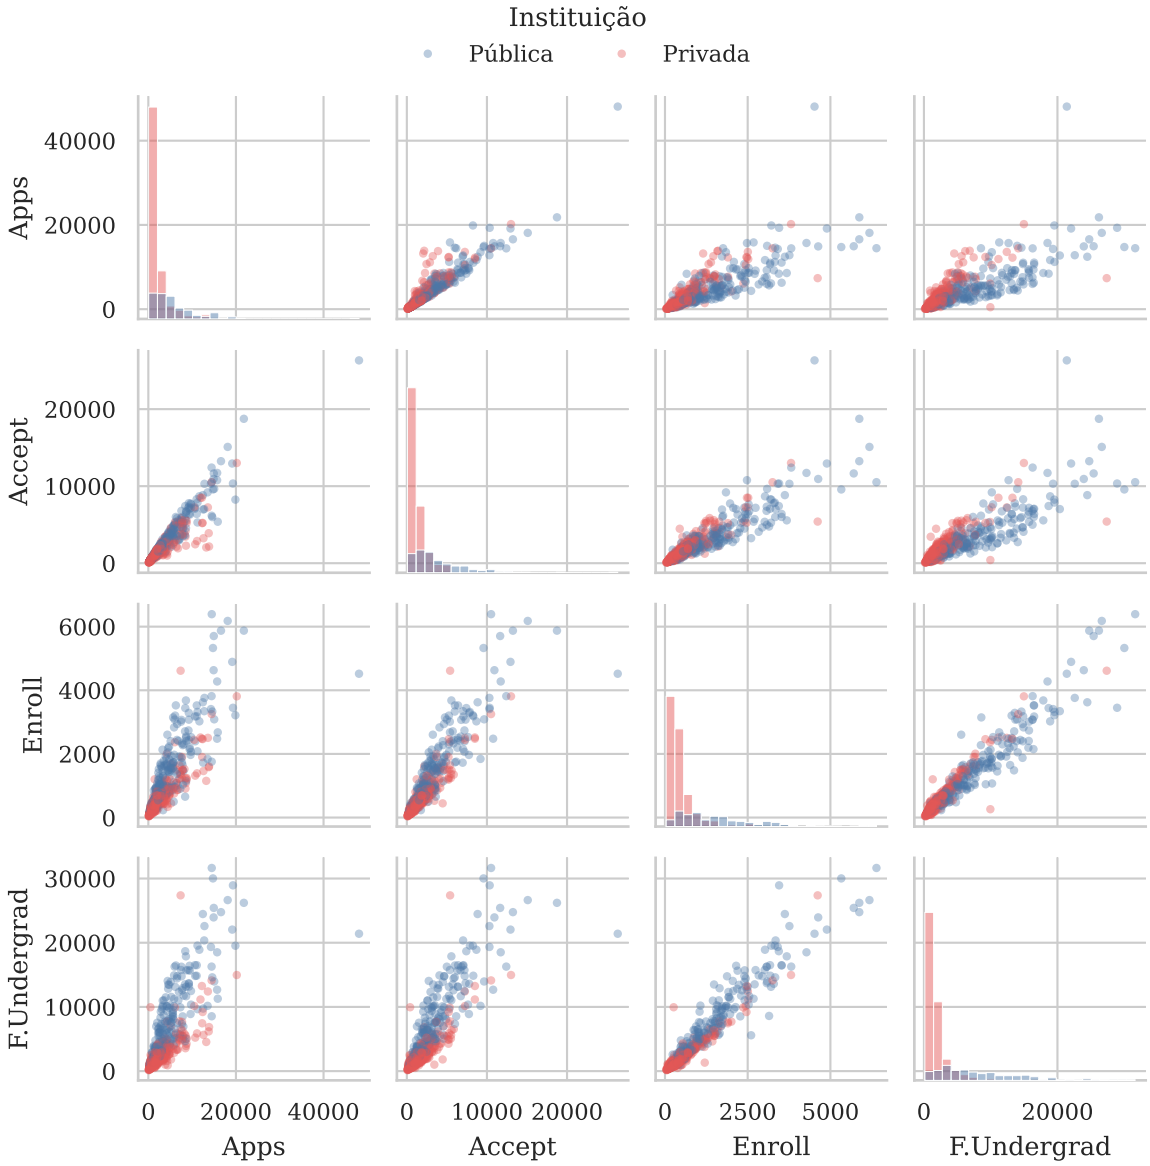


Figura 4. Matriz de dispersão de medidas de demanda e porte, por natureza da instituição.

Esses gráficos constituem apenas uma triagem; a avaliação formal permanece reservada à seção de correlação e multicolinearidade.

5 Modelo inicial

O modelo inicial inclui os 16 preditores numéricos e a variável categórica `Private`. Para sua incorporação, foi definida `Private_Yes = 1` para instituições privadas e 0 para públicas, tornando as instituições públicas a categoria de referência. O ajuste foi realizado por mínimos quadrados ordinários com as 777 observações, sem seleção ou remoção de variáveis.

5.1 Formulação do modelo

Seja x_{ij} o valor do j-ésimo preditor numérico para a instituição i. A forma geral do modelo completo é:

$$\text{Apps}_i = \beta_0 + \beta_1 \text{Private_Yes}_i + \sum_{j=2}^{17} \beta_j x_{ij} + \varepsilon_i.$$

Nessa expressão, cada β_j representa uma associação parcial com `Apps`, mantidos os demais preditores constantes, e ε_i reúne a variação não explicada pelo modelo.

5.2 Coeficientes e ajuste global

As estimativas dos coeficientes, erros-padrão, estatísticas de teste e intervalos de confiança são apresentadas na Tabela 7.

Tabela 7: Estimativas do modelo linear inicial com todos os preditores.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-445,084	408,329	-1,090	0,276	-1.246,672	356,503
Accept	1,586	0,041	38,924	< 0,001	1,506	1,666
Enroll	-0,881	0,186	-4,736	< 0,001	-1,246	-0,516
Top10perc	49,926	5,578	8,950	< 0,001	38,976	60,877
Top25perc	-14,234	4,479	-3,178	0,002	-23,027	-5,441
F.Undergrad	0,057	0,033	1,754	0,080	-0,007	0,122
P.Undergrad	0,044	0,032	1,383	0,167	-0,019	0,108
Outstate	-0,086	0,019	-4,506	< 0,001	-0,123	-0,048
Room.Board	0,151	0,048	3,127	0,002	0,056	0,246
Books	0,021	0,238	0,088	0,930	-0,447	0,489
Personal	0,031	0,063	0,493	0,622	-0,093	0,155
PhD	-8,678	4,638	-1,871	0,062	-17,784	0,427
Terminal	-3,331	5,095	-0,654	0,513	-13,333	6,671
S.F.Ratio	15,390	13,006	1,183	0,237	-10,143	40,922
perc.alumni	0,179	4,102	0,044	0,965	-7,875	8,232
Expend	0,078	0,012	6,308	< 0,001	0,054	0,102
Grad.Rate	8,668	2,949	2,939	0,003	2,879	14,457
Privada (Yes versus No)	-494,149	137,812	-3,586	< 0,001	-764,687	-223,611

O R^2 ajustado de 0,9276 indica que o conjunto de preditores descreve 92,76% da variação amostral de `Apps`; o teste global confirma que o modelo possui contribuição explicativa ($F = 585{,}86$; $p < 0{,}001$). Ao nível de 5%, `Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `Expend`, `Grad.Rate` e `Private_Yes` apresentam coeficientes significativos.

Mantidos os demais preditores constantes, o coeficiente de `Private_Yes` associa instituições privadas a cerca de 494 candidaturas a menos que instituições públicas. Essa interpretação é preliminar: a proximidade entre variáveis de admissão e porte pode afetar sinais e erros-padrão, razão pela qual nenhum preditor é removido nesta etapa.

6 Correlação e multicolinearidade

Embora o modelo inicial apresente elevado poder explicativo, coeficientes individuais podem tornar-se instáveis quando existem preditores fortemente correlacionados entre si. Assim, antes da seleção do modelo final, investigou-se a presença de multicolinearidade por meio da matriz de correlação entre os preditores e do Fator de Inflação da Variância (VIF).

Inicialmente foi construída a matriz de correlação de Pearson para as variáveis numéricas. Em seguida, calculou-se o VIF para cada variável do modelo inicial, adotando como referência o valor 10 como indicativo de multicolinearidade severa.

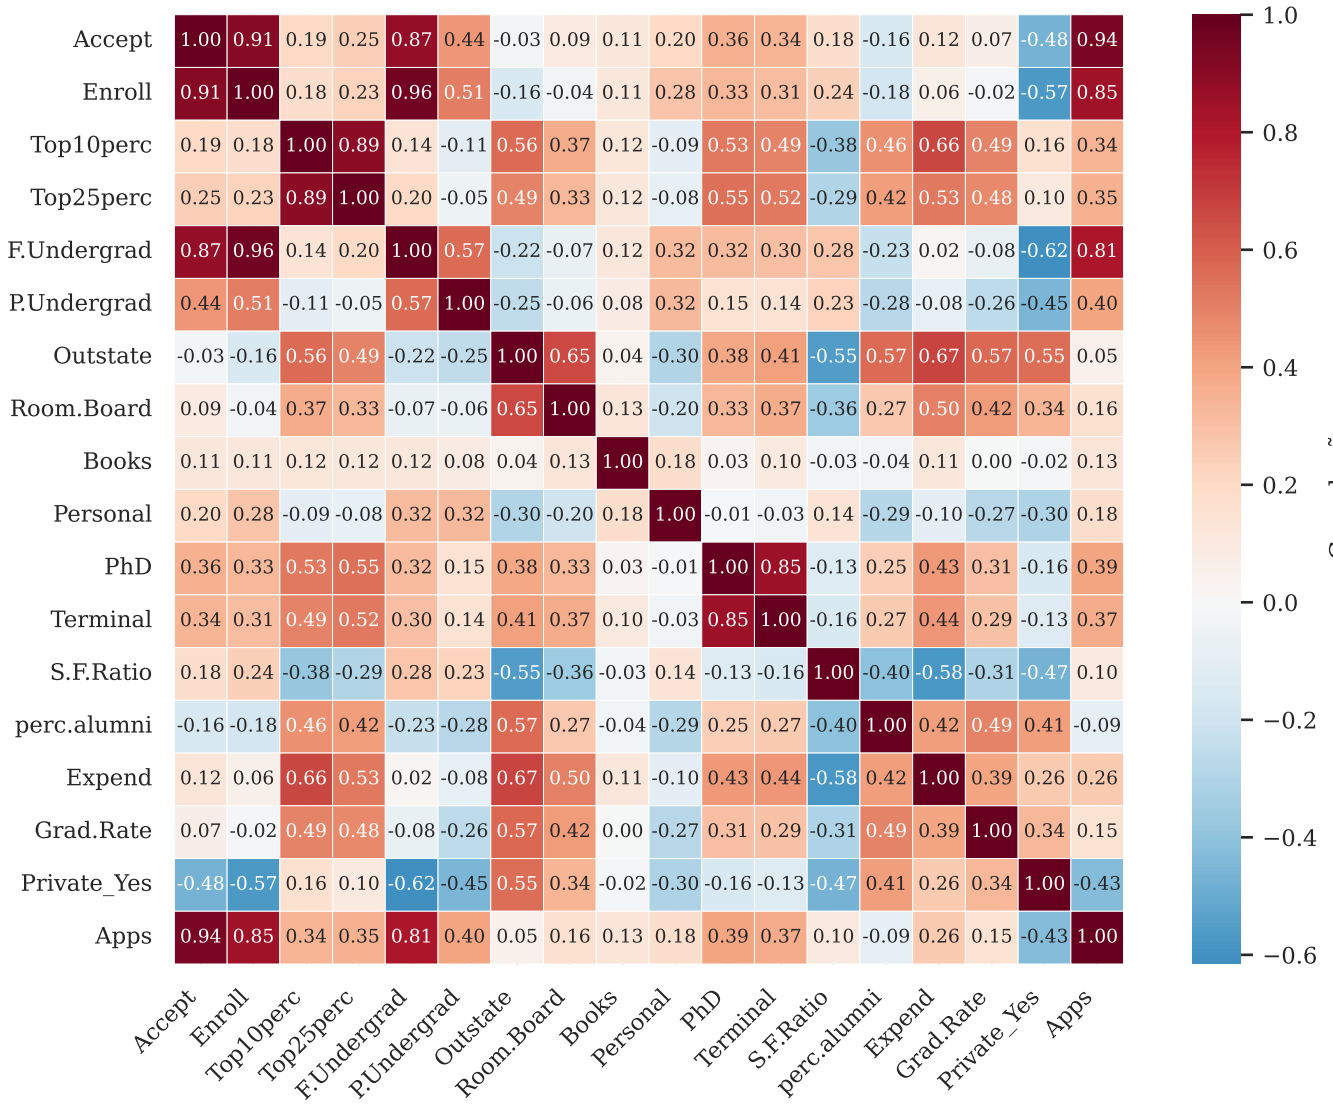


Figura 5. Matriz de correlação de Pearson entre as variáveis numéricas.

A Figura 5 apresenta a matriz de correlação de Pearson entre as variáveis do modelo inicial. Observam-se correlações elevadas entre variáveis relacionadas ao processo de admissão, ao porte institucional e ao perfil acadêmico das universidades. Destacam-se as associações entre Accept e Enroll ($r = 0,91$), Enroll e F.Undergrad ($r = 0,96$), Accept e F.Undergrad ($r = 0,87$), Top10perc e Top25perc ($r = 0,89$), além de PhD e Terminal ($r = 0,85$). Também se observa forte correlação entre Apps e Accept ($r = 0,94$), resultado esperado,

uma vez que universidades que recebem mais candidaturas tendem a aceitar maior número de estudantes. Esses padrões sugerem a possibilidade de multicolinearidade entre alguns preditores, justificando sua avaliação formal por meio do Fator de Inflação da Variância (VIF).

Fator de Inflação da Variância (VIF)

Para complementar a análise da matriz de correlação, calculou-se o Fator de Inflação da Variância (VIF) para cada preditor do modelo inicial. O VIF mede o quanto a variância do estimador de um coeficiente é inflacionada em decorrência da dependência linear entre as variáveis explicativas. Como referência , valores superiores a 5 indicam multicolinearidade moderada, enquanto valores acima de 10 são usualmente considerados evidência de multicolinearidade severa.

Tabela 8: Fator de Inflação da Variância (VIF) para os preditores do modelo inicial.

Variável	VIF
Enroll	21,37
F.Undergrad	18,02
Accept	7,14
Top10perc	6,93
Top25perc	5,63
Outstate	4,21
PhD	4,10
Terminal	4,03
Expend	2,98
Private_Yes	2,70
Room.Board	2,01
S.F.Ratio	1,90
perc.alumni	1,85
Grad.Rate	1,84
P.Undergrad	1,71
Personal	1,31
Books	1,11

A Tabela 8 apresenta os fatores de inflação da variância (VIF) dos preditores do modelo inicial. Os maiores valores foram observados para Enroll (VIF = 21,37) e F.Undergrad (VIF = 18,02), ambos superiores ao limite de referência igual a 10, indicando multicolinearidade severa. Esses resultados são consistentes com a matriz de correlação, na qual essas variáveis apresentam elevada associação entre si ($r = 0,96$) e também com Accept ($r = 0,91$ e $r = 0,87$, respectivamente).

Também foram observados valores relativamente elevados para Accept (7,14), Top10perc (6,93) e Top25perc (5,63). Embora inferiores ao limite de 10, esses resultados sugerem correlação moderada entre esses preditores, o que pode aumentar a variabilidade das estimativas dos coeficientes.

Os demais preditores apresentaram valores de VIF inferiores a 5, indicando ausência de problemas relevantes de multicolinearidade. Em conjunto, os resultados mostram que a principal fonte de colinearidade do modelo está associada às variáveis que representam diferentes dimensões do porte institucional e do processo de admissão.

Dessa forma, a seleção do modelo final deverá considerar não apenas critérios de ajuste, como AIC e BIC, mas também a redução da multicolinearidade, buscando um modelo mais parcimonioso e com coeficientes mais estáveis.

7 Seleção do modelo final

7.1 Seleção dos modelos

Embora o modelo inicial apresente elevado poder explicativo, ele contém um número relativamente grande de preditores, alguns dos quais apresentam multicolinearidade elevada. Assim, buscou-se uma especificação mais parcimoniosa, capaz de manter o desempenho preditivo ao mesmo tempo em que reduz a complexidade do modelo.

Para isso, foram comparados diferentes modelos utilizando critérios estatísticos de seleção, incluindo o Critério de Informação de Akaike (AIC), o Critério de Informação Bayesiano (BIC), o coeficiente de determinação ajustado (R^2_{aj}) e o procedimento de eliminação retroativa (backward). Posteriormente, os modelos foram avaliados por validação cruzada K-Fold.

Tabela 9: Comparação dos modelos obtidos pelos diferentes critérios de seleção.

Modelo	Variáveis	AIC	BIC	R^2	R^2_{ajustado}
Completo	17	13.020,429	13.104,227	0,929	0,928
Backward	11	13.012,670	13.068,536	0,929	0,928
AIC	12	13.012,557	13.073,077	0,929	0,928
BIC	10	13.016,008	13.067,218	0,928	0,927

A Tabela 9 sintetiza as métricas de ajuste para as quatro especificações avaliadas. O modelo Completo (17 preditores) apresenta AIC de $13.020,429$, enquanto o procedimento de eliminação retroativa (Backward) reduz o conjunto para 11 preditores com AIC de $13.012,670$. O procedimento Stepwise (AIC) retém 12 variáveis, ao passo que o Stepwise (BIC) seleciona uma estrutura mais concisa contendo 10 preditores. O modelo parcimonioso obtido pelo critério BIC penaliza com maior rigor a inclusão de parâmetros adicionais, alcançando $13.067,218$ no BIC e $R^2_{\text{ajustado}} = 0,927$. A perda no coeficiente de determinação ajustado é inferior a $0,1\%$ em relação ao modelo completo ($0,928$), com a vantagem decisiva de eliminar a variável F.Undergrad, principal fonte de multicolinearidade severa (VIF $= 18,02$).

7.2 Modelo final selecionado

Para definir o modelo final, além dos critérios de ajuste apresentados anteriormente, a multicolinearidade dos modelos selecionados também foi reavaliada por meio do Fator de Inflação da Variância (VIF).

Tabela 10: Maior valor do Fator de Inflação da Variância (VIF) em cada modelo avaliado.

Modelo	Maior VIF
Backward	21,05
Stepwise (AIC)	21,15
Stepwise (BIC)	7,58

A Tabela 10 mostra que os modelos **Backward** e **Stepwise (AIC)** mantêm simultaneamente as variáveis `Enroll` e `F.Undergrad`, preservando a multicolinearidade severa observada no modelo completo. Em ambos os casos, os maiores VIFs permanecem próximos de 21 e 17, respectivamente. Já no modelo **Stepwise (BIC)**, a remoção de `F.Undergrad` reduz o maior VIF do conjunto (`Enroll`) para aproximadamente **7,6**, valor inferior ao limite de referência igual a 10. Embora ainda exista alguma correlação entre as variáveis explicativas, a multicolinearidade deixa de ser considerada severa.

Diante desses resultados, o modelo **Stepwise (BIC)** foi escolhido como modelo final. Esse modelo possui 10 variáveis explicativas (`Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `PhD`, `Expend`, `Grad.Rate` e `Private_Yes`) e apresentou o melhor equilíbrio entre qualidade do ajuste, simplicidade e estabilidade dos coeficientes.

A escolha baseia-se em três fatores principais. Primeiro, o modelo é o mais parcimonioso entre os avaliados e apresenta perda praticamente desprezível de capacidade explicativa. Seu (R^2) ajustado é igual a **0,927**, apenas **0,001** inferior ao obtido pelos modelos Completo, Backward e Stepwise (AIC), todos com (R^2) ajustado igual a **0,928**. Segundo, é o único modelo que elimina a multicolinearidade severa identificada no modelo inicial, reduzindo todos os VIFs para valores inferiores a 10. Por fim, embora seu AIC seja ligeiramente superior ao dos modelos Backward e Stepwise (AIC), a diferença é inferior a quatro unidades e considerada pequena. Em contrapartida, esse modelo apresenta o menor BIC entre todas as especificações avaliadas. Como o BIC penaliza de forma mais intensa a inclusão de parâmetros desnecessários, ele favorece modelos mais simples sem comprometer a qualidade do ajuste.

Os demais modelos não foram selecionados pelos seguintes motivos. O modelo **Completo** mantém todas as 17 variáveis explicativas, incluindo preditores sem significância estatística (`Books`, `Personal`, `Terminal`, `perc.alumni`, `F.Undergrad` e `P.Undergrad`), além da forte multicolinearidade entre `Enroll` e `F.Undergrad`. O modelo **Backward** elimina parte dessas variáveis, porém mantém `F.Undergrad`, preservando o problema de colinearidade. Já o modelo **Stepwise (AIC)** apresenta o menor AIC entre os modelos comparados, mas continua incluindo `F.Undergrad` e `P.Undergrad`, tornando o modelo mais complexo sem eliminar a principal fonte de instabilidade dos coeficientes.

É importante destacar uma limitação presente em todas as especificações avaliadas. As variáveis `Accept` e `Enroll` representam etapas posteriores ao recebimento das candidaturas (`Apps`), correspondendo ao número de candidatos aceitos e ao número de alunos efetivamente matriculados. Dessa forma, essas variáveis não representam características institucionais anteriores ao processo de candidatura, limitando uma interpretação estritamente causal do modelo. Entretanto, como essa característica está presente em todos os modelos comparados, ela não interfere na escolha entre eles e, por isso, não foi utilizada como critério de seleção.

Assim, o modelo **Stepwise (BIC)** foi adotado como modelo final deste trabalho e será utilizado nas próximas etapas da análise, incluindo a validação cruzada, a interpretação dos coeficientes, o diagnóstico dos pressupostos e a realização das previsões.

8 Validação cruzada K-Fold

Para avaliar a capacidade preditiva do modelo final fora da amostra utilizada em seu ajuste, foi realizada uma validação cruzada K-Fold com $K = 10$ partições, aplicada exclusivamente ao modelo Stepwise (BIC). Em cada iteração, o modelo foi reajustado com nove das dez partições e avaliado na partição restante, sendo calculados a raiz do erro quadrático médio (RMSE), o erro absoluto médio (MAE) e o coeficiente de determinação (R^2) na partição de teste.

Tabela 11: Métricas de validação cruzada K-Fold (K = 10) para o modelo final.

Partição	RMSE	MAE	R^2
1	1.086,600	755,613	0,893
2	1.273,076	729,900	0,895
3	1.531,861	745,749	0,830
4	900,713	564,193	0,936
5	1.641,291	703,870	0,931
6	722,485	511,692	0,948
7	749,837	495,484	0,898
8	711,020	499,995	0,938
9	1.016,393	636,830	0,921
10	1.231,426	653,658	0,916
Média	1.086,470	629,698	0,911
Desvio-padrão	331,364	104,638	0,034

A Tabela 11 mostra que o RMSE médio nas dez partições de teste é de aproximadamente $1.086,47$ candidaturas, com desvio-padrão de $331,36$, enquanto o R^2 médio é de $0,911$, com desvio-padrão de $0,034$. Esses valores são próximos dos obtidos dentro da própria amostra de ajuste, na qual o modelo final apresenta $R^2_{\text{ajustado}} = 0,927$ e RMSE de aproximadamente $1.042,99$. A proximidade entre o desempenho estimado por validação cruzada e o desempenho dentro da amostra indica que o modelo generaliza razoavelmente bem para dados não utilizados em seu ajuste, sem sinais de sobreajuste severo.

Observa-se, ainda, alguma variabilidade entre partições: a partição 5 apresenta o maior RMSE ($1.641,29$), o que é consistente com o fato de essa partição conter, no conjunto de teste, a observação 484, identificada desde a análise exploratória (Tabela 5) como a instituição com o maior número de candidaturas da base (48.094). Já a partição 3 apresenta o menor R^2 ($0,830$), refletindo a sensibilidade do modelo à composição de cada partição em uma base com forte assimetria na variável resposta. Essa oscilação motiva a investigação mais detalhada de observações influentes, retomada na seção de diagnóstico.

9 Interpretação dos coeficientes

A Tabela 12 apresenta as estimativas dos coeficientes do modelo final (Stepwise BIC), com os respectivos erros-padrão, estatísticas de teste e intervalos de confiança de 95%.

Tabela 12: Estimativas do modelo final (Stepwise BIC).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-100,517	265,476	-0,379	0,705	-621,663	420,630
Accept	1,584	0,040	39,500	< 0,001	1,505	1,663
Top10perc	49,139	5,516	8,908	< 0,001	38,310	59,968
Expend	0,073	0,011	6,370	< 0,001	0,050	0,095
Outstate	-0,095	0,018	-5,176	< 0,001	-0,131	-0,059
Enroll	-0,562	0,111	-5,069	< 0,001	-0,780	-0,344
Room.Board	0,164	0,047	3,508	< 0,001	0,072	0,255
Top25perc	-13,865	4,418	-3,139	0,002	-22,537	-5,193
Privada (Yes versus No)	-575,071	132,528	-4,339	< 0,001	-835,232	-314,909
PhD	-10,016	3,119	-3,211	0,001	-16,139	-3,893
Grad.Rate	7,333	2,821	2,599	0,010	1,795	12,871

Todos os dez preditores do modelo final apresentam coeficientes estatisticamente significativos ao nível de 5%, o que já era esperado, uma vez que o critério BIC penaliza fortemente variáveis com pouca contribuição marginal. O R^2_{ajustado} de 0,927 indica que o modelo explica 92,7% da variação amostral de `Apps` com praticamente a mesma capacidade explicativa do modelo completo, porém com sete preditores a menos.

`Accept` é o preditor de maior efeito prático: mantidos os demais preditores constantes, cada candidatura aceita adicional está associada, em média, a um acréscimo de aproximadamente 1,58 candidatura recebida, refletindo a forte relação estrutural entre aceitação e demanda observada desde a análise de correlação ($r = 0,94$ entre `Apps` e `Accept`). O percentual de ingressantes no top 10% da turma (`Top10perc`) também apresenta associação positiva expressiva: cada ponto percentual adicional está associado a cerca de 49 candidaturas a mais, consistente com a leitura de que instituições mais seletivas e prestigiadas atraem maior número de candidatos. Na mesma direção, `Room.Board` e `Expend` apresentam coeficientes positivos, sugerindo que maiores investimentos em infraestrutura de moradia/alimentação e gasto institucional por aluno estão associados a maior atratividade. `Grad.Rate` também contribui positivamente, compatível com a ideia de que taxas de graduação mais altas sinalizam melhor desempenho institucional.

Outros coeficientes têm sinal negativo e mensagem mais sutil. `Outstate` é negativo, indicando que, mantidos os demais fatores constantes, mensalidades mais altas para estudantes de fora do estado estão associadas a menor número de candidaturas — um efeito de custo, coerente com a intuição econômica. O coeficiente de `Private_Yes` reforça o resultado já observado no modelo inicial: instituições privadas recebem, em média, cerca de 575 candidaturas a menos que instituições públicas com as demais características equivalentes, o que é coerente com a diferença de porte entre os dois grupos discutida na análise exploratória (Tabela 6).

Três coeficientes merecem leitura mais cuidadosa por apresentarem sinal oposto ao da correlação bivariada com `Apps` observada na Figura 5 (seção de correlação e multicolinearidade): `Enroll`, `Top25perc` e `PhD` são positivamente correlacionados com `Apps` isoladamente ($r = 0,85$; $r = 0,35$; e $r = 0,39$, respectivamente), mas seus coeficientes parciais

no modelo final são negativos. Esse padrão é uma consequência esperada da correlação entre preditores: `Enroll` está fortemente associado a `Accept` ($r = 0,91$), `Top25perc` está fortemente associado a `Top10perc` ($r = 0,89$) e `PhD` está associado a `Terminal` e a outras variáveis de perfil acadêmico. Uma vez que `Accept` e `Top10perc` já capturam grande parte da variação relacionada à demanda e à seletividade, os coeficientes de `Enroll`, `Top25perc` e `PhD` passam a representar o efeito marginal residual dessas variáveis, condicional às demais — e não devem ser interpretados como relações de causa e efeito isoladas, mas sim como associações parciais dentro do conjunto de preditores do modelo.

10 Diagnóstico do modelo

Esta seção avalia a adequação do modelo final aos pressupostos clássicos da regressão linear: linearidade, homocedasticidade (variância constante dos erros) e independência dos resíduos. A normalidade dos resíduos é tratada separadamente na próxima seção.

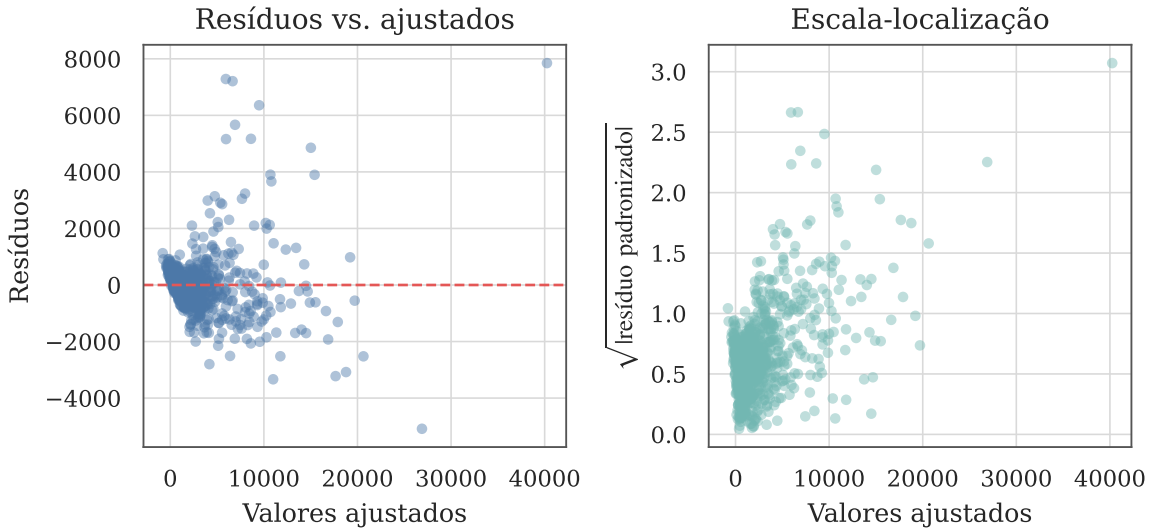


Figura 6. Resíduos versus valores ajustados e gráfico de escala-localização do modelo final.

Tabela 13: Teste de Breusch-Pagan para heterocedasticidade.

Estatística LM	p-valor (LM)	Estatística F	p-valor (F)
235,426	< 0,001	33,299	< 0,001

A Figura 6 evidencia um padrão de leque (*funnel shape*) no gráfico de resíduos versus valores ajustados: a dispersão dos resíduos aumenta com o valor previsto de `Apps`, sugerindo variância não constante. O gráfico de escala-localização confirma essa tendência, com a magnitude dos resíduos padronizados crescendo à medida que os valores ajustados aumentam. O teste formal de Breusch-Pagan (Tabela 13) rejeita a hipótese nula de homocedasticidade a qualquer nível usual de significância, confirmando estatisticamente a heterocedasticidade sugerida pelos gráficos.

Esse resultado é esperado dado o forte caráter assimétrico de `Apps`, já identificado na análise exploratória (assimetria amostral de 3,72; Figura 1): instituições com maior volume

de candidaturas tendem a apresentar também maior variabilidade absoluta nesse volume. A heterocedasticidade não invalida as estimativas pontuais dos coeficientes, que permanecem não viesadas, mas compromete a eficiência dos erros-padrão clássicos e, por consequência, a precisão exata dos testes de hipótese e dos intervalos construídos na seção de previsões, que devem ser interpretados com essa ressalva.

Em conjunto, os diagnósticos indicam que o modelo atende razoavelmente aos pressupostos da regressão linear múltipla. Embora existam pequenas violações, principalmente relacionadas à normalidade dos resíduos nas caudas, elas não comprometem significativamente as inferências devido ao tamanho da amostra.

11 QQ Plot e normalidade dos resíduos

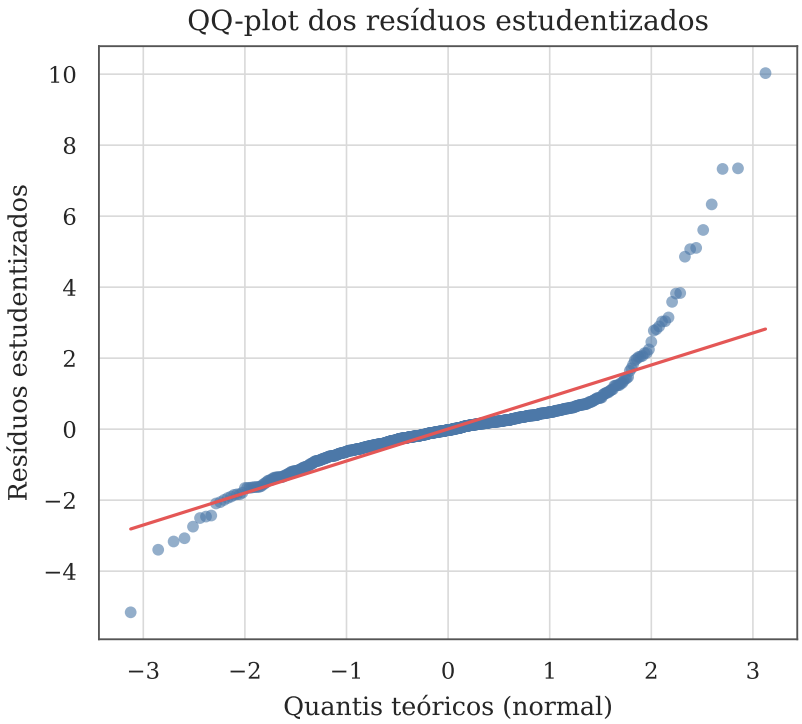


Figura 7. QQ-plot dos resíduos estudentizados do modelo final.

O QQ-plot mostra afastamento sistemático da reta de referência normal nas duas caudas, sobretudo na cauda superior, onde os resíduos observados assumem valores muito mais extremos do que o esperado sob normalidade — reflexo direto de instituições com candidaturas atipicamente elevadas, como a observação 484.

Para complementar a avaliação visual, foi construído um gráfico de envelope simulado: a partir do modelo ajustado, foram geradas 100 réplicas da variável resposta sob a hipótese de erros normais com a mesma matriz de preditores, obtendo-se, para cada posição ordenada dos resíduos estudentizados, uma banda de referência entre os percentis 2,5% e 97,5% das réplicas simuladas.

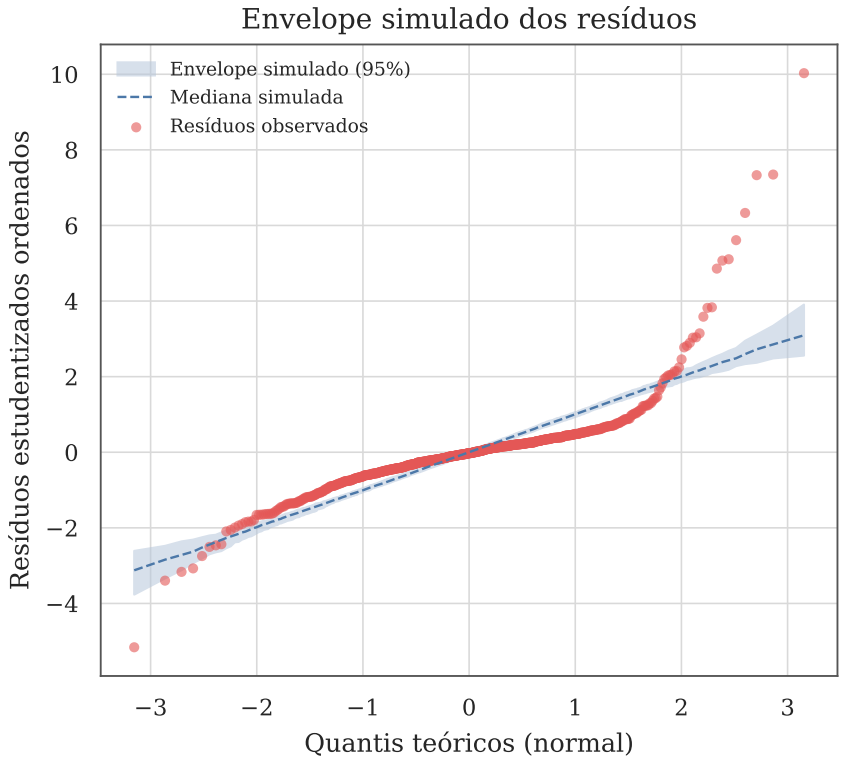


Figura 8. Gráfico de envelope simulado dos resíduos estudentizados do modelo final.

Tabela 14: Estatísticas de normalidade dos resíduos do modelo final.

Estatística de Shapiro-Wilk	p-valor	Assimetria dos resíduos	Curtose dos resíduos	% fora do envelope
0,777	< 0,001	2,36	15,98	90,3

A Tabela 14 resume a avaliação formal de normalidade. O teste de Shapiro-Wilk rejeita a hipótese de normalidade dos resíduos ($p < 0,001$), e as medidas de assimetria (2,36) e curtose (15,98) indicam uma distribuição fortemente assimétrica à direita e com caudas muito mais pesadas que as da distribuição normal. O gráfico de envelope simulado (Figura 8) corrobora essa conclusão de forma visual: a maior parte dos resíduos observados situa-se fora da banda de 95% esperada sob normalidade, sobretudo por estarem mais concentrados próximo de zero do que o previsto pelo modelo normal e por apresentarem valores extremos nas caudas muito além do envelope — configuração típica de distribuições leptocúrticas.

Em conjunto, os resultados desta seção e da anterior indicam que dois pressupostos clássicos do MRLM — homocedasticidade e normalidade dos resíduos — não são plenamente satisfeitos pelo modelo final. Essa violação está associada principalmente à forte assimetria de `Apps` e a um pequeno número de observações extremas, investigadas formalmente na próxima seção. Como o escopo deste trabalho é a comparação e o diagnóstico dos modelos já ajustados, e não a proposição de uma nova especificação, o modelo Stepwise (BIC) é mantido como modelo final; a violação identificada é registrada como limitação a ser considerada na leitura de testes de hipótese e intervalos.

12 Pontos atípicos, de alavanca e influentes

Esta seção identifica observações atípicas (*outliers*), de alavanca (*leverage*) e influentes no modelo final, utilizando três medidas complementares: resíduos estudentizados (externamente), alavancagem (h_{ii}, diagonal da matriz de projeção) e distância de Cook. Como referência, foram adotados os limites usuais |resíduo estudentizado| > 3 para pontos atípicos, $h_{ii} > 2p/n$ para pontos de alavanca e $D_i > 4/n$ para pontos influentes, em que p é o número de parâmetros do modelo (incluindo o intercepto) e n o número de observações.

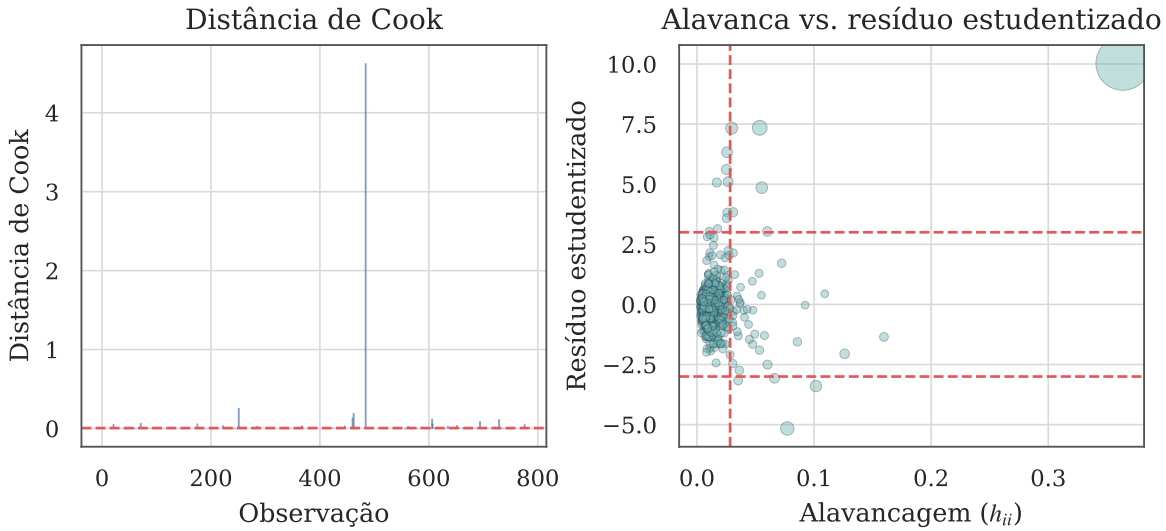


Figura 9. Distância de Cook e gráfico de influência (alavanca versus resíduo estudentizado) do modelo final.

Tabela 15: Observações que excedem simultaneamente os três critérios de alavanca, atipicidade e influência.

Observação	Instituição	Apps	Alavancagem	Resíduo estudentizado	Distância de Cook
484	Pública	48094	0,364	10,029	4,627
251	Privada	13865	0,054	7,347	0,260
462	Pública	21804	0,077	-5,160	0,196
460	Privada	13218	0,030	7,330	0,140
606	Pública	19873	0,055	4,858	0,122
729	Privada	7654	0,102	-3,397	0,117
607	Pública	15698	0,066	-3,073	0,060
776	Privada	10705	0,060	3,032	0,053
652	Pública	14596	0,031	3,834	0,042
635	Pública	14438	0,035	-3,165	0,033

Com os limites de referência adotados, 48 observações excedem o limite de alavancagem, 46 excedem o limite da distância de Cook e 18 são classificadas como atípicas pelo resíduo estudentizado. Esses números, relativamente altos para uma base com 777 observações, são esperados quando se aplicam limites de referência clássicos a uma amostra grande com resposta fortemente assimétrica; nem todas essas observações representam, necessariamente, problemas de ajuste isolados.

Uma leitura mais seletiva considera as observações que excedem simultaneamente os três critérios, listadas na Tabela 15: apenas 10 instituições atendem a essa condição mais restritiva, o que corresponde a cerca de 1,3% da amostra. Entre elas, destaca-se novamente a observação 484 — a instituição pública com 48.094 candidaturas já identificada na Tabela 5 —, cuja alavancagem (0,364) é mais de doze vezes o limite de referência ($2p/n = 0,028$), cuja distância de Cook (4,63) supera em larga margem tanto o limite de referência ($4/n = 0,005$) quanto o limite absoluto tradicional igual a 1, e cujo resíduo estudentizado (10,03) é, de longe, o mais extremo da base. Essa observação concentra, portanto, alavanca, atipicidade e influência de forma simultânea, sendo o ponto isolado de maior impacto potencial sobre as estimativas do modelo final.

Como a proposta deste trabalho é diagnosticar o modelo final já selecionado, e não reajustá-lo, nenhuma observação foi removida ou teve tratamento diferenciado nas seções anteriores. O registro dessas observações tem caráter diagnóstico: evidencia que uma parcela pequena, porém não desprezível, da amostra — sobretudo instituições públicas de grande porte com volume de candidaturas muito acima da média — tem peso desproporcional sobre o ajuste, o que é coerente com a heterocedasticidade e a não normalidade identificadas nas seções anteriores.

13 Previsões

Esta seção ilustra o uso prático do modelo final por meio de dois perfis institucionais plausíveis, construídos a partir das medianas observadas dos dez preditores do modelo, separadas por natureza da instituição (pública ou privada). Para cada perfil, são apresentados a previsão pontual, o intervalo de confiança de 95% para o valor médio esperado da resposta, $E(Y \mid \mathbf{X} = \mathbf{x}_0)$, e o intervalo de predição de 95% para uma nova observação individual.

Tabela 16: Perfis institucionais utilizados nas previsões, com base nas medianas por natureza da instituição.

Perfil	Accept	Top10perc	Expend	Outstate	Enroll	Room.Board	Top25perc	Private_Yes	PhD	Grad.Rate
Pública (mediana)	2.929,5	19,0	6.716,5	6.609,0	1.337,5	3.708,0	51,0	0,0	78,5	55,0
Privada (mediana)	859,0	25,0	8.954,0	11.200,0	328,0	4.400,0	55,0	1,0	73,0	69,0

Tabela 17: Previsão pontual, intervalo de confiança para a média e intervalo de predição (95%) para os dois perfis institucionais.

Perfil	Previsão pontual	IC 95% (inferior)	IC 95% (superior)	IP 95% (inferior)	IP 95% (superior)
Pública (mediana)	4.102,1	3.953,6	4.250,6	2.049,3	6.154,9
Privada (mediana)	1.053,0	957,1	1.148,9	-996,7	3.102,7

O perfil de instituição **pública** típica (mediana das públicas nos dez preditores do modelo) resulta em uma previsão pontual de aproximadamente **4.102** candidaturas, com

intervalo de confiança de 95% para o número médio esperado de candidaturas entre **3.953,6** e **4.250,6**, e intervalo de predição de 95% entre **2.049,3** e **6.154,9** para uma nova instituição com esse mesmo perfil. Já o perfil de instituição **privada** típica resulta em uma previsão pontual de aproximadamente **1.053** candidaturas, com intervalo de confiança de 95% entre **957,1** e **1.148,9**, e intervalo de predição de 95% entre **-996,7** e **3.102,7**.

Como esperado pela teoria da regressão, o intervalo de predição é substancialmente mais largo que o intervalo de confiança em ambos os perfis, pois incorpora tanto a incerteza sobre o valor médio quanto a variabilidade individual em torno desse valor. No perfil privado, o limite inferior do intervalo de predição é negativo, o que não tem significado prático, já que `Apps` não pode ser negativo: esse resultado é uma consequência esperada de ajustar um modelo linear não transformado a uma variável de contagem fortemente assimétrica e heterocedástica, como discutido nas seções de diagnóstico. Na prática, esse limite deve ser interpretado como equivalente a zero candidaturas, e o intervalo de predição deve ser lido com cautela adicional, sobretudo para instituições privadas de menor porte.

Ainda assim, os dois perfis reproduzem, de forma coerente, o padrão já descrito na análise exploratória (Tabela 6): instituições públicas recebem, em mediana, número de candidaturas várias vezes maior que instituições privadas, mesmo após o controle simultâneo por seletividade, custo, perfil acadêmico e investimento institucional promovido pelo modelo de regressão múltipla.

14 Conclusão

Este trabalho aplicou a metodologia de Regressão Linear Múltipla para modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos, utilizando a base `College`. A análise exploratória revelou forte assimetria à direita na variável resposta e diferenças marcantes entre instituições públicas e privadas, tanto em porte quanto em custo e investimento.

O modelo inicial, com os 16 preditores numéricos e a variável categórica `Private`, apresentou elevado poder explicativo ($R^2_{\text{ajustado}} = 0,928$), mas evidenciou multicolinearidade severa entre `Enroll` e `F.Undergrad` (VIF de 21,37 e 18,02, respectivamente). A comparação entre quatro especificações — Completo, Backward, Stepwise (AIC) e Stepwise (BIC) — mostrou que apenas o modelo Stepwise (BIC) elimina essa multicolinearidade severa, ao custo de uma perda praticamente desprezível de capacidade explicativa ($R^2_{\text{ajustado}} = 0,927$), sendo por isso adotado como modelo final com dez preditores: `Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `PhD`, `Expend`, `Grad.Rate` e `Private_Yes`.

A validação cruzada K-Fold confirmou a capacidade de generalização do modelo final, com R^2 médio de 0,911 nas partições de teste, próximo do R^2_{ajustado} obtido dentro da amostra de ajuste. A interpretação dos coeficientes indicou `Accept`, `Top10perc` e a condição de instituição privada como os fatores de maior efeito prático sobre `Apps`, ao passo que `Enroll`, `Top25perc` e `PhD` apresentaram coeficientes parciais de sinal oposto ao da correlação bivariada, ilustrando o efeito da correlação entre preditores sobre a leitura de coeficientes em modelos multivariados.

O diagnóstico do modelo indicou violação de dois pressupostos clássicos do MRLM: heterocedasticidade, confirmada pelo teste de Breusch-Pagan, e não normalidade dos resíduos, confirmada pelo teste de Shapiro-Wilk e pelo gráfico de envelope simulado. A investigação de observações influentes apontou um pequeno grupo de instituições — em especial a observação 484, com 48.094 candidaturas — que concentra simultaneamente alta alavancagem,

resíduo atípico e distância de Cook elevada, e que está diretamente associada às violações de homocedasticidade e normalidade identificadas. Por fim, as previsões para perfis institucionais públicos e privados típicos reproduziram, de forma quantitativa, a diferença de demanda entre os dois grupos já sugerida na análise exploratória, evidenciando a utilidade prática do modelo apesar das limitações diagnosticadas.

Em síntese, o número de candidaturas recebidas por uma instituição de ensino superior está fortemente associado a características ligadas ao processo de admissão, à seletividade acadêmica, ao custo, ao investimento institucional e à natureza pública ou privada da instituição. O modelo final oferece uma descrição parcimoniosa e razoavelmente estável dessas associações, mas suas limitações de heterocedasticidade e normalidade — decorrentes, em grande parte, da forte assimetria de `Apps` e de um pequeno número de observações extremas e influentes — indicam que extensões futuras, como a modelagem em escala transformada (por exemplo, logarítmica) ou o uso de erros-padrão robustos, poderiam aprimorar a precisão inferencial sem alterar as principais conclusões substantivas aqui obtidas.

Referências

[1] Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.

[2] James G, Witten D, Hastie T, Tibshirani R. 2021 *An Introduction to Statistical Learning: with Applications in R*. New York: Springer 2 edition.