

Universidade Federal
de Campina Grande

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Departamento de Ciência da Computação

Isadora Beatriz Lucena de Medeiros

Jennifer Raysa Medeiros Cavalcanti

Oscar Rodrigues da Silva Neto

MODELAGEM DO NÚMERO DE CANDIDATURAS EM UNIVERSIDADES DOS ESTADOS UNIDOS POR REGRESSÃO LINEAR MÚLTIPLA

Relatório apresentado à disciplina de *Estatística Aplicada*, período 2026.1.

Profa. Dra. Amanda Gomes
Prof. Dr. Jerfson Bruno
Prof. Dr. Gilberto Matos

Campina Grande – PB
2026

RESUMO

Este trabalho aplica a metodologia de Regressão Linear Múltipla (MRLM) ao conjunto de dados `college`, com o objetivo de modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos a partir de características institucionais, acadêmicas e financeiras. Inicialmente, foi realizada uma análise exploratória univariada e bivariada, incluindo estatísticas descritivas, visualizações gráficas, análise de correlação e verificação da presença de dados ausentes. Em seguida, foi ajustado um modelo inicial contendo todas as variáveis explicativas disponíveis, sendo investigada a presença de multicolinearidade e comparadas especificações alternativas para seleção do modelo final. Os pressupostos da regressão linear foram avaliados por meio da análise dos resíduos, gráfico de envelope simulado e identificação de observações atípicas, de alavanca e influentes. Por fim, foi analisada a contribuição da variável categórica `Private` por meio de variáveis indicadoras (dummies) e foram construídos intervalos de confiança para o valor médio esperado da resposta e intervalos de predição para novas observações, acompanhados de suas interpretações práticas.

Áreas temáticas: estatística aplicada, ciência de dados

Palavras-chave: regressão linear múltipla, análise exploratória, seleção de modelos, multicolinearidade, diagnóstico de resíduos, variáveis dummy

Sumário

1 Introdução 3

2 Metodologia 3

3 Descrição e qualidade dos dados 3

4 Análise exploratória univariada e bivariada 5
- 4.1 Estatísticas descritivas 5
- 4.2 Distribuição de Apps e valores extremos 5
- 4.3 Comparação entre instituições públicas e privadas 6
- 4.4 Estrutura bivariada inicial 7

5 Modelo inicial 9
- 5.1 Formulação do modelo 9
- 5.2 Coeficientes e ajuste global 10

6 Correlação e multicolinearidade 11
- 6.1 Fator de Inflação da Variância (VIF) 12

7 Seleção do modelo final 12
- 7.1 Seleção dos modelos 12
- 7.2 Modelo final selecionado 13

8 Validação cruzada K-Fold 14

9 Interpretação dos coeficientes 14

10 Diagnóstico do modelo 15

11 QQ Plot e normalidade dos resíduos 16

12 Pontos atípicos, de alavanca e influentes 17

13 Previsões 19

14 Conclusão 21

Referências 21

1 Introdução

Na base `College`, `Apps` registra quantas candidaturas cada instituição recebeu. A variação dessa contagem é analisada em conjunto com porte, custos, perfil acadêmico, qualificação docente e investimento, características que diferem amplamente entre as universidades observadas.

O objetivo é investigar retrospectivamente a associação entre essas características e o número de candidaturas por meio da Regressão Linear Múltipla (MRLM). O modelo completo servirá de referência para seleção, validação e diagnóstico [1]. O estudo não pretende antecipar a demanda: `Accept` e `Enroll`, mantidos por seu valor associativo, pertencem ao mesmo processo de admissão e podem não estar disponíveis antes de seu encerramento.

2 Metodologia

O estudo utiliza dados secundários provenientes da base `College`, disponibilizada no pacote `ISLR` e compilada a partir de informações publicadas pelo *U.S. News & World Report* [2]. A análise foi realizada com os registros originais da base, sem coleta direta ou alteração dos dados brutos.

Após a verificação da base, ajustaram-se os modelos por mínimos quadrados ordinários. O VIF orientou a análise da redundância entre preditores, enquanto eliminação retroativa, seleção *forward*, AIC, BIC e teste F parcial permitiram comparar as especificações candidatas [1,3,4]. A especificação escolhida foi então submetida à validação cruzada K-Fold com dez partições [2].

O diagnóstico reuniu resíduos versus ajustados, escala-localização, Breusch–Pagan, QQ-plot, Shapiro–Wilk, envelope simulado, resíduos estudentizados, alavancagem e distância de Cook [1,5,6]. Nos perfis institucionais, o alvo da inferência define o intervalo empregado: confiança para a média condicional e predição para uma nova instituição, com sua variabilidade individual [1].

3 Descrição e qualidade dos dados

A base reúne dados de 777 instituições de ensino superior dos Estados Unidos e contém 18 atributos. A resposta analisada é `Apps`, que corresponde ao número de candidaturas recebidas. Entre os preditores, `Private` é o único categórico e distingue universidades públicas (`No`) e privadas (`Yes`), totalizando 212 e 565 casos, respectivamente. Os demais atributos são numéricos e abrangem informações sobre admissão, quantidade de estudantes, custos, perfil acadêmico, corpo docente e investimentos. A Tabela 1 apresenta a descrição e a unidade de cada campo.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
Private	Categoria	Natureza da instituição: No = pública; Yes = privada.
Apps	Contagem	Candidaturas recebidas; variável resposta.
Accept	Contagem	Candidaturas aceitas.
Enroll	Contagem	Novos alunos matriculados.
Top10perc	%	Ingressantes no top 10% da turma do ensino médio.
Top25perc	%	Ingressantes no top 25% da turma do ensino médio.
F.Undergrad	Contagem	Graduandos em tempo integral.
P.Undergrad	Contagem	Graduandos em tempo parcial.
Outstate	US$	Mensalidade para estudantes de fora do estado.
Room.Board	US$	Custo de moradia e alimentação.
Books	US$	Custo estimado com livros.
Personal	US$	Gasto pessoal estimado.
PhD	%	Corpo docente com doutorado.
Terminal	%	Corpo docente com grau terminal da área.
S.F.Ratio	Razão	Número de estudantes por docente.
perc.alumni	%	Ex-alunos que realizam doações.
Expend	US$/aluno	Gasto institucional por aluno.
Grad.Rate	%	Taxa de graduação.

A Tabela 2 sintetiza as verificações de completude, duplicidade, faixas e relações lógicas entre as variáveis.

Tabela 2: Síntese das verificações de qualidade dos dados.

Verificação	Critério	Ocorrências
Valores ausentes	Nenhum	0
Linhas duplicadas	Nenhuma	0
Enroll > Accept	Nenhum caso esperado	0
Accept > Apps	Nenhum caso esperado	0
Top10perc > Top25perc	Nenhum caso esperado	0
Percentuais fora de [0, 100]	Requer conferência	2

Não houve necessidade de imputação ou correção prévia. As únicas ressalvas são `Grad.Rate = 118`, na observação 96, e `PhD = 103`, na observação 583; sem confirmação de sua origem, ambos foram preservados e registrados como limitação de qualidade (Tabela 3).

Tabela 3: Observações com percentuais superiores a 100.

Observação	Private	Apps	Accept	Enroll	PhD	Terminal	Grad.Rate
96	Privada	3847	3433	527	22	47	118
583	Pública	529	481	243	103	88	43

4 Análise exploratória univariada e bivariada

4.1 Estatísticas descritivas

As estatísticas da Tabela 4 mostram heterogeneidade entre as instituições e assimetria à direita nas principais medidas de demanda e porte. Em `Apps`, por exemplo, a média é quase o dobro da mediana, indicando que poucas instituições com demanda muito elevada deslocam a média para cima.

Tabela 4: Estatísticas descritivas das variáveis numéricas.

Variável	Média	DP	Mín.	Q1	Mediana	Q3	Máx.
Apps	3.001,6	3.870,2	81,0	776,0	1.558,0	3.624,0	48.094,0
Accept	2.018,8	2.451,1	72,0	604,0	1.110,0	2.424,0	26.330,0
Enroll	780,0	929,2	35,0	242,0	434,0	902,0	6.392,0
Top10perc	27,6	17,6	1,0	15,0	23,0	35,0	96,0
Top25perc	55,8	19,8	9,0	41,0	54,0	69,0	100,0
F.Undergrad	3.699,9	4.850,4	139,0	992,0	1.707,0	4.005,0	31.643,0
P.Undergrad	855,3	1.522,4	1,0	95,0	353,0	967,0	21.836,0
Outstate	10.440,7	4.023,0	2.340,0	7.320,0	9.990,0	12.925,0	21.700,0
Room.Board	4.357,5	1.096,7	1.780,0	3.597,0	4.200,0	5.050,0	8.124,0
Books	549,4	165,1	96,0	470,0	500,0	600,0	2.340,0
Personal	1.340,6	677,1	250,0	850,0	1.200,0	1.700,0	6.800,0
PhD	72,7	16,3	8,0	62,0	75,0	85,0	103,0
Terminal	79,7	14,7	24,0	71,0	82,0	92,0	100,0
S.F.Ratio	14,1	4,0	2,5	11,5	13,6	16,5	39,8
perc.alumni	22,7	12,4	0,0	13,0	21,0	31,0	64,0
Expend	9.660,2	5.221,8	3.186,0	6.751,0	8.377,0	10.830,0	56.233,0
Grad.Rate	65,5	17,2	10,0	53,0	65,0	78,0	118,0

4.2 Distribuição de Apps e valores extremos

`Apps` varia de 81 a 48.094 candidaturas, com média de 3.001,6, mediana de 1.558 e assimetria amostral de 3,72. A Figura 1 confirma a forte cauda à direita.

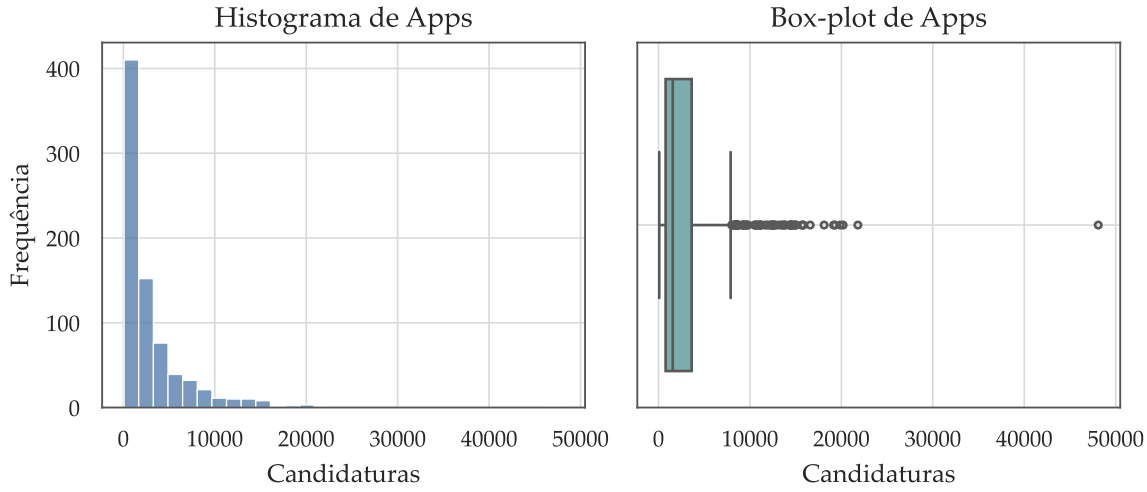


Figura 1. Histograma e box-plot do número de candidaturas recebidas.

Pela regra de $1{,}5\,AIQ$, 70 instituições, aproximadamente 9% da amostra, superam 7.896 candidaturas. Os cinco maiores valores constam na Tabela 5; eles caracterizam a heterogeneidade da base e não são tratados automaticamente como erros.

Tabela 5: Cinco observações com os maiores valores de Apps.

Observação	Private	Apps	Accept	Enroll	F.Undergrad	Grad.Rate
484	Pública	48094	26330	4520	21401	77
462	Pública	21804	18744	5874	26213	67
60	Privada	20192	13007	3810	14971	72
606	Pública	19873	8252	3215	19532	78
446	Pública	19315	10344	3450	28938	63

4.3 Comparação entre instituições públicas e privadas

As instituições públicas apresentam maior número típico de candidaturas: as medianas são 4.307 nas públicas e 1.133 nas privadas. A Tabela 6 amplia a comparação para medidas de admissão, porte, mensalidade e investimento.

Tabela 6: Média e desvio-padrão de variáveis selecionadas, por natureza da instituição.

Instituição	Variável	Média	DP
Pública	Apps	5.729,9	5.370,7
Privada	Apps	1.977,9	2.443,3
Pública	Accept	3.919,3	3.477,3
Privada	Accept	1.305,7	1.369,5
Pública	Enroll	1.640,9	1.261,6
Privada	Enroll	456,9	457,5
Pública	F.Undergrad	8.571,0	6.467,7
Privada	F.Undergrad	1.872,2	2.110,7

Tabela 6: Média e desvio-padrão de variáveis selecionadas, por natureza da instituição.

Instituição	Variável	Média	DP
Pública	Outstate	6.813,4	2.145,2
Privada	Outstate	11.801,7	3.707,5
Pública	Expend	7.458,3	2.695,5
Privada	Expend	10.486,4	5.682,6

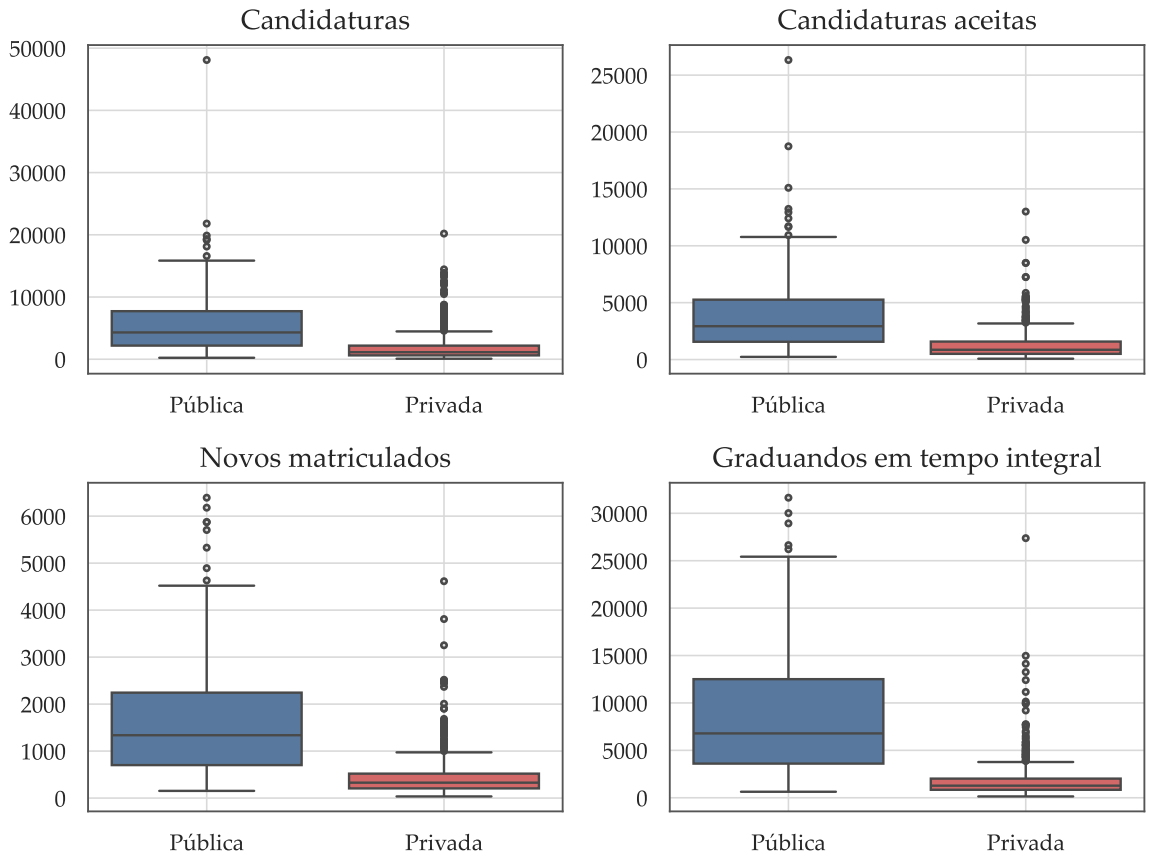


Figura 2. Box-plots de medidas de demanda e porte, por natureza da instituição.

Os box-plots da Figura 2 reforçam o maior porte e demanda das públicas e os maiores `Outstate` e `Expend` das privadas. A diferença bruta em `Apps` pode, portanto, refletir também porte, custos e investimento, sem interpretação causal.

4.4 Estrutura bivariada inicial

A Figura 3 resume as associações lineares iniciais. `Apps` apresenta relações positivas mais intensas com `Accept`, `Enroll` e `F.Undergrad`, variáveis ligadas ao processo de admissão e ao porte da instituição.

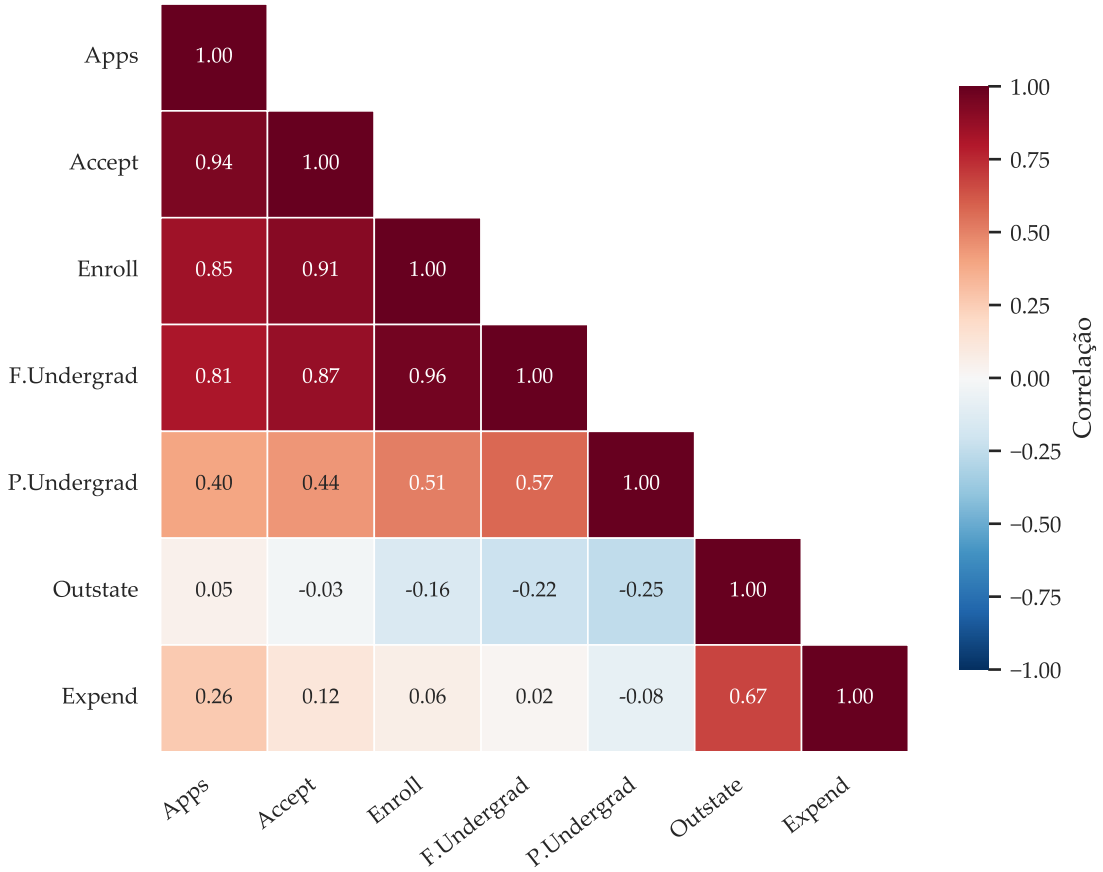


Figura 3. Matriz exploratória de correlações entre Apps e variáveis selecionadas.

A Figura 4 complementa o resumo ao mostrar a forma das relações, as distribuições marginais e os grupos público e privado. As tendências são predominantemente crescentes, mas a variabilidade de `Apps` aumenta nos níveis mais altos dos preditores.

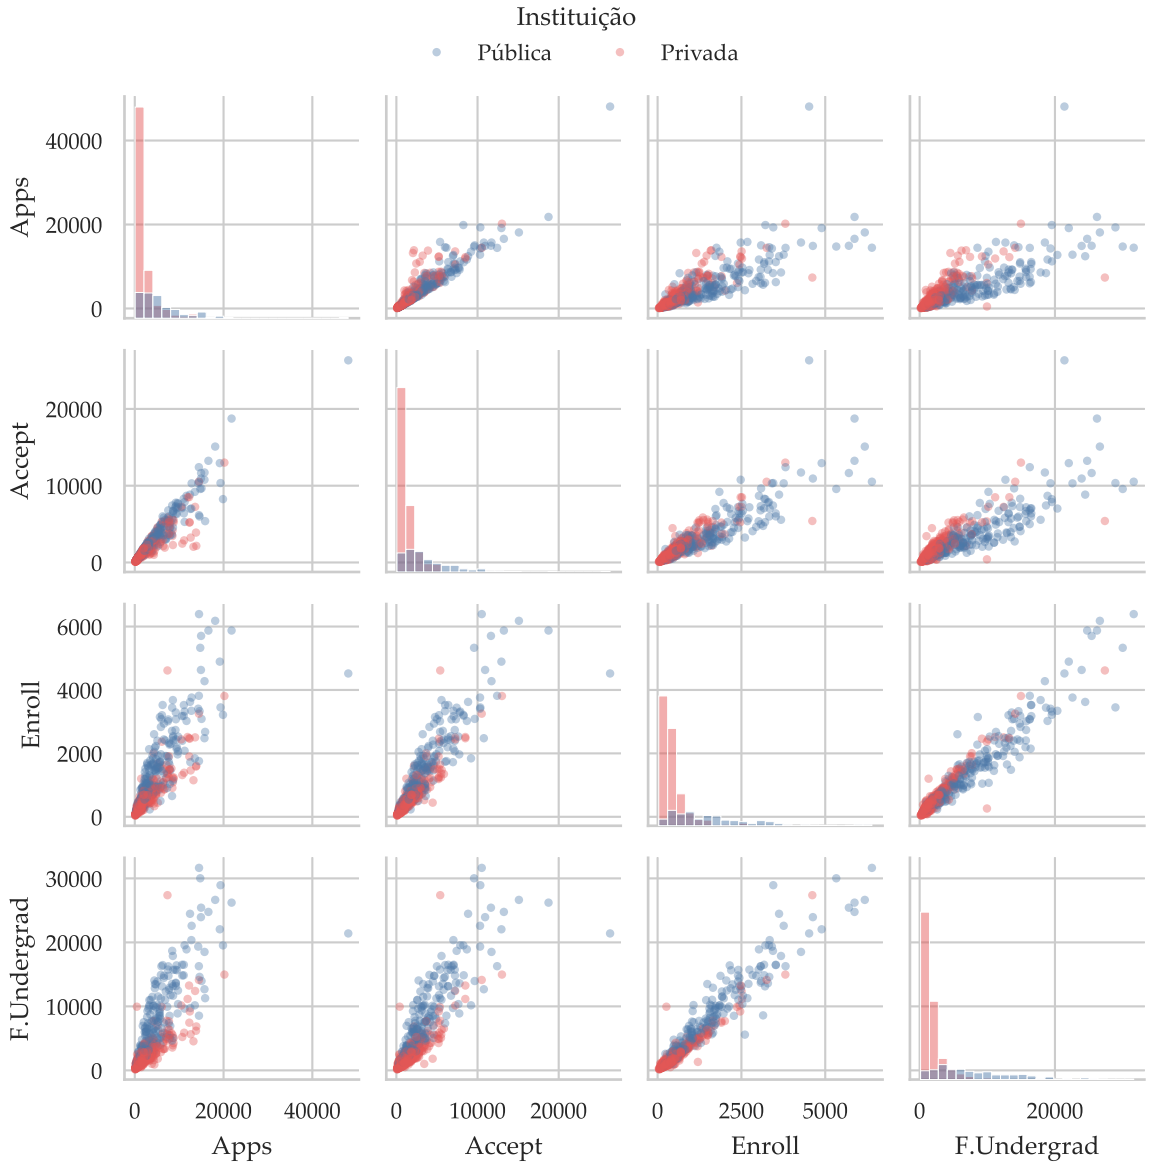


Figura 4. Matriz de dispersão de medidas de demanda e porte, por natureza da instituição.

Esses gráficos constituem apenas uma triagem; a avaliação formal permanece reservada à seção de correlação e multicolinearidade.

5 Modelo inicial

O modelo inicial inclui os 16 preditores numéricos e a variável categórica `Private`. Para sua incorporação, foi definida `Private_Yes = 1` para instituições privadas e 0 para públicas, tornando as instituições públicas a categoria de referência. O ajuste foi realizado por mínimos quadrados ordinários com as 777 observações, sem seleção ou remoção de variáveis.

5.1 Formulação do modelo

Seja x_{ij} o valor do j-ésimo preditor numérico para a instituição i. A forma geral do modelo completo é:

$$\text{Apps}_i = \beta_0 + \beta_1 \text{Private_Yes}_i + \sum_{j=2}^{17} \beta_j x_{ij} + \varepsilon_i.$$

Nessa expressão, cada β_j representa uma associação parcial com `Apps`, mantidos os demais preditores constantes, e ε_i reúne a variação não explicada pelo modelo.

5.2 Coeficientes e ajuste global

As estimativas dos coeficientes, erros-padrão, estatísticas de teste e intervalos de confiança são apresentadas na Tabela 7.

Tabela 7: Estimativas do modelo linear inicial com todos os preditores.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-445,084	408,329	-1,090	0,276	-1.246,672	356,503
Accept	1,586	0,041	38,924	< 0,001	1,506	1,666
Enroll	-0,881	0,186	-4,736	< 0,001	-1,246	-0,516
Top10perc	49,926	5,578	8,950	< 0,001	38,976	60,877
Top25perc	-14,234	4,479	-3,178	0,002	-23,027	-5,441
F.Undergrad	0,057	0,033	1,754	0,080	-0,007	0,122
P.Undergrad	0,044	0,032	1,383	0,167	-0,019	0,108
Outstate	-0,086	0,019	-4,506	< 0,001	-0,123	-0,048
Room.Board	0,151	0,048	3,127	0,002	0,056	0,246
Books	0,021	0,238	0,088	0,930	-0,447	0,489
Personal	0,031	0,063	0,493	0,622	-0,093	0,155
PhD	-8,678	4,638	-1,871	0,062	-17,784	0,427
Terminal	-3,331	5,095	-0,654	0,513	-13,333	6,671
S.F.Ratio	15,390	13,006	1,183	0,237	-10,143	40,922
perc.alumni	0,179	4,102	0,044	0,965	-7,875	8,232
Expend	0,078	0,012	6,308	< 0,001	0,054	0,102
Grad.Rate	8,668	2,949	2,939	0,003	2,879	14,457
Privada (Yes versus No)	-494,149	137,812	-3,586	< 0,001	-764,687	-223,611

O R^2 ajustado de 0,9276 indica que o modelo descreve 92,76% da variação amostral de `Apps`, e o teste global confirma sua contribuição explicativa ($F = 585{,}86$; $p < 0{,}001$). Nove preditores apresentam coeficientes significativos a 5% (Tabela 7).

Mantidos os demais preditores constantes, o coeficiente de `Private_Yes` associa instituições privadas a cerca de 494 candidaturas a menos que instituições públicas. Essa interpretação é preliminar: a proximidade entre variáveis de admissão e porte pode afetar sinais e erros-padrão, razão pela qual nenhum preditor é removido nesta etapa.

6 Correlação e multicolinearidade

Embora o modelo inicial apresente elevado poder explicativo, coeficientes individuais podem tornar-se instáveis quando existem preditores fortemente correlacionados entre si. Assim, antes da seleção do modelo final, investigou-se a presença de multicolinearidade por meio da matriz de correlação entre os preditores e do Fator de Inflação da Variância (VIF).

Inicialmente foi construída a matriz de correlação de Pearson para as variáveis numéricas. Em seguida, calculou-se o VIF para cada variável do modelo inicial, adotando como referência o valor 10 como indicativo de multicolinearidade severa.

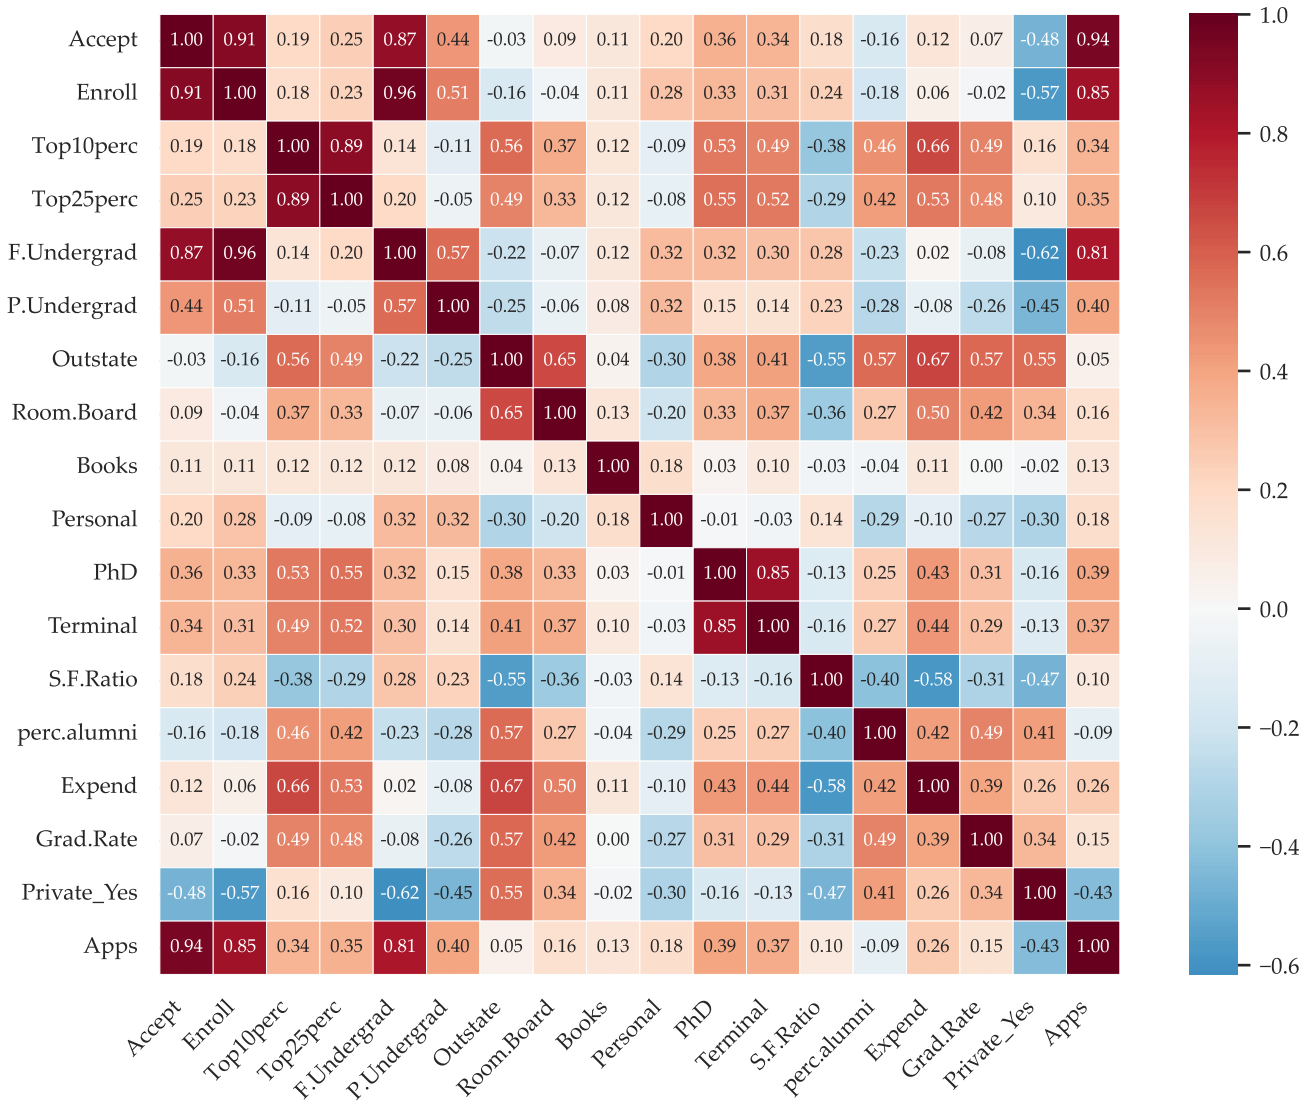


Figura 5. Matriz de correlação de Pearson entre as variáveis numéricas.

As maiores correlações envolvem admissão, porte e perfil acadêmico, sobretudo Enroll–F.Undergrad ($r = 0,96$), Top10perc–Top25perc ($r = 0,89$) e Apps–Accept ($r = 0,94$). Esses padrões motivam a avaliação formal da multicolinearidade pelo VIF.

6.1 Fator de Inflação da Variância (VIF)

Complementando a matriz de correlação, calculou-se o VIF de cada preditor do modelo inicial, adotando-se VIF > 5 como indício de multicolinearidade moderada e VIF > 10 como evidência de multicolinearidade severa [1].

Tabela 8: Fator de Inflação da Variância (VIF) para os preditores do modelo inicial.

Variável	VIF
Enroll	21,37
F.Undergrad	18,02
Accept	7,14
Top10perc	6,93
Top25perc	5,63
Outstate	4,21
PhD	4,10
Terminal	4,03
Expend	2,98
Private_Yes	2,70
Room.Board	2,01
S.F.Ratio	1,90
perc.alumni	1,85
Grad.Rate	1,84
P.Undergrad	1,71
Personal	1,31
Books	1,11

Os valores da Tabela 8 confirmam multicolinearidade severa em `Enroll` (VIF = 21,37) e `F.Undergrad` (VIF = 18,02), coerente com a Figura 5. A colinearidade concentra-se, assim, nas variáveis de porte e admissão e será considerada juntamente com AIC e BIC na seleção final.

7 Seleção do modelo final

7.1 Seleção dos modelos

Buscou-se uma especificação mais parcimoniosa por eliminação retroativa (*backward*) e seleção *forward* guiada por AIC e BIC, considerando também R^2_{aj} e VIF. A especificação escolhida foi posteriormente submetida à validação cruzada K-Fold.

Tabela 9: Comparação dos modelos obtidos pelos diferentes critérios de seleção.

Modelo	Variáveis	AIC	BIC	R^2	R^2_{ajustado}
Completo	17	13.020,429	13.104,227	0,929	0,928
Backward	11	13.012,670	13.068,536	0,929	0,928
Forward (AIC)	12	13.012,557	13.073,077	0,929	0,928
Forward (BIC)	10	13.016,008	13.067,218	0,928	0,927

Na Tabela 9, o Forward (AIC) apresenta o menor AIC, enquanto o Forward (BIC) apresenta o menor BIC. Neste último, o R^2_{ajustado} permanece próximo ao do modelo Completo, apesar da exclusão de `F.Undergrad`, principal fonte de multicolinearidade severa.

O teste F parcial entre esses modelos resultou em $F(7, 759) = 1{,}345$ e $p = 0{,}226$; portanto, não se rejeita que os sete coeficientes adicionais do Completo sejam conjuntamente nulos. A conclusão é condicional aos modelos comparados, selecionados com os mesmos dados [1].

7.2 Modelo final selecionado

Para decidir entre as especificações, a multicolinearidade de cada uma foi reavaliada por meio do maior VIF (Tabela 10).

Tabela 10: Maior valor do Fator de Inflação da Variância (VIF) em cada modelo avaliado.

Modelo	Maior VIF
Backward	21,05
Forward (AIC)	21,15
Forward (BIC)	7,58

Backward e Forward (AIC) preservam VIFs severos, enquanto o Forward (BIC) reduz o máximo para 7,58, ainda compatível com colinearidade moderada (Tabela 10). Em conjunto, o menor BIC, a parcimônia, a pequena perda de ajuste e o teste F sustentam sua escolha. O Completo mantém termos não significativos; Backward e Forward (AIC), embora competitivos em AIC, preservam `F.Undergrad` e a principal fonte de instabilidade. A limitação prospectiva de `Accept` e `Enroll` indicada na Introdução permanece válida.

Adota-se, portanto, o **Forward (BIC)** com os dez preditores apresentados nas tabelas anteriores. Sua formulação explícita é

$$\begin{aligned}\text{Apps}_i = \beta_0 &+ \beta_1 \text{Accept}_i + \beta_2 \text{Enroll}_i + \beta_3 \text{Top10perc}_i + \beta_4 \text{Top25perc}_i \\ &+ \beta_5 \text{Outstate}_i + \beta_6 \text{Room.Board}_i + \beta_7 \text{PhD}_i + \beta_8 \text{Expend}_i \\ &+ \beta_9 \text{Grad.Rate}_i + \beta_{10} \text{Private_Yes}_i + \varepsilon_i.\end{aligned}$$

8 Validação cruzada K-Fold

Para descrever o desempenho da especificação final fora da amostra de ajuste, realizou-se validação cruzada K-Fold com $K = 10$ partições. Em cada iteração, o modelo foi reajustado com nove partições e avaliado na restante, calculando-se RMSE, MAE e R^2 na partição de teste. Os preditores, porém, já haviam sido selecionados com a base completa: o procedimento avalia a especificação final fixada, não todo o processo de seleção de variáveis.

Tabela 11: Métricas de validação cruzada K-Fold (K = 10) para o modelo final.

Partição	RMSE	MAE	R^2
1	1.086,600	755,613	0,893
2	1.273,076	729,900	0,895
3	1.531,861	745,749	0,830
4	900,713	564,193	0,936
5	1.641,291	703,870	0,931
6	722,485	511,692	0,948
7	749,837	495,484	0,898
8	711,020	499,995	0,938
9	1.016,393	636,830	0,921
10	1.231,426	653,658	0,916
Média	1.086,470	629,698	0,911
Desvio-padrão	331,364	104,638	0,034

O desempenho médio nas partições de teste (Tabela 11) é próximo do obtido dentro da amostra de ajuste. A partição 5, que contém a observação extrema 484 (Tabela 5), tem o maior RMSE, e a partição 3, o menor R^2. Assim, o desempenho é relativamente estável nas divisões adotadas, mas sensível a observações extremas.

9 Interpretação dos coeficientes

A Tabela 12 apresenta as estimativas dos coeficientes do modelo final (Forward BIC), com os respectivos erros-padrão, estatísticas de teste e intervalos de confiança de 95%.

Tabela 12: Estimativas do modelo final (Forward BIC).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-100,517	265,476	-0,379	0,705	-621,663	420,630
Accept	1,584	0,040	39,500	< 0,001	1,505	1,663
Top10perc	49,139	5,516	8,908	< 0,001	38,310	59,968
Expend	0,073	0,011	6,370	< 0,001	0,050	0,095
Outstate	-0,095	0,018	-5,176	< 0,001	-0,131	-0,059
Enroll	-0,562	0,111	-5,069	< 0,001	-0,780	-0,344
Room.Board	0,164	0,047	3,508	< 0,001	0,072	0,255
Top25perc	-13,865	4,418	-3,139	0,002	-22,537	-5,193

Tabela 12: Estimativas do modelo final (Forward BIC).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Privada (Yes versus No)	-575,071	132,528	-4,339	< 0,001	-835,232	-314,909
PhD	-10,016	3,119	-3,211	0,001	-16,139	-3,893
Grad.Rate	7,333	2,821	2,599	0,010	1,795	12,871

Todos os dez preditores são significativos a 5%, embora o BIC, por si só, não imponha significância individual.

Na unidade própria de `Accept`, cada candidatura aceita a mais associa-se, em média, a +1,58 candidatura recebida; para `Top10perc`, o acréscimo é de 49 por ponto percentual, mantidos os demais preditores constantes. As escalas distintas impedem comparar diretamente essas magnitudes. `Room.Board`, `Expend` e `Grad.Rate` têm associações parciais positivas, e `Outstate`, negativa. Instituições privadas estão associadas a cerca de 575 candidaturas a menos que as públicas nas mesmas condições, em linha com a comparação descritiva da Tabela 6.

`Enroll`, `Top25perc` e `PhD` têm coeficiente parcial negativo apesar de correlação bivariada positiva com `Apps` (Figura 5). Seus sinais condicionais refletem a estrutura conjunta dos preditores e não relações causais isoladas.

10 Diagnóstico do modelo

Esta seção avalia a adequação do modelo final aos pressupostos clássicos da regressão linear: linearidade, homocedasticidade (variância constante dos erros) e independência dos resíduos. A normalidade dos resíduos é tratada separadamente na próxima seção. Como a base é transversal e contém uma observação por instituição, a independência é assumida a partir da estrutura dos dados; a ordem das linhas, por si só, não permite testá-la.

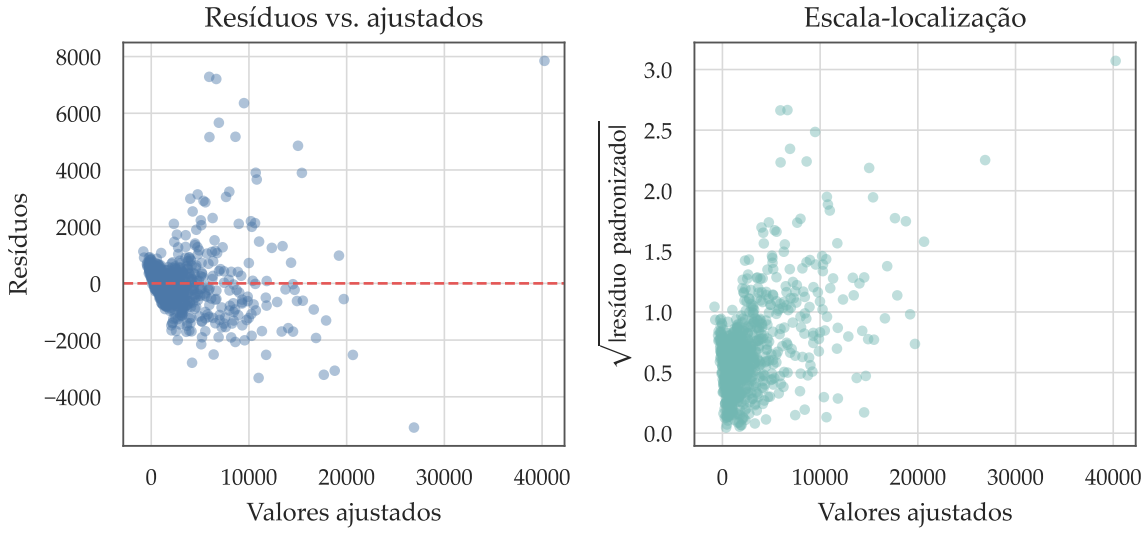


Figura 6. Resíduos versus valores ajustados e gráfico de escala-localização do modelo final.

Tabela 13: Teste de Breusch-Pagan para heterocedasticidade.

Estatística LM	p-valor (LM)	Estatística F	p-valor (F)
235,426	< 0,001	33,299	< 0,001

A Figura 6 evidencia um padrão de leque: a dispersão dos resíduos cresce com o valor ajustado de `Apps`, indicando variância não constante, como confirma o teste de Breusch-Pagan (Tabela 13), que rejeita a homocedasticidade a qualquer nível usual de significância. O gráfico não sugere curvatura dominante, mas a forte assimetria de `Apps` (assimetria amostral de 3,72; Figura 1) acompanha maior variabilidade absoluta nos níveis mais altos da resposta.

11 QQ Plot e normalidade dos resíduos

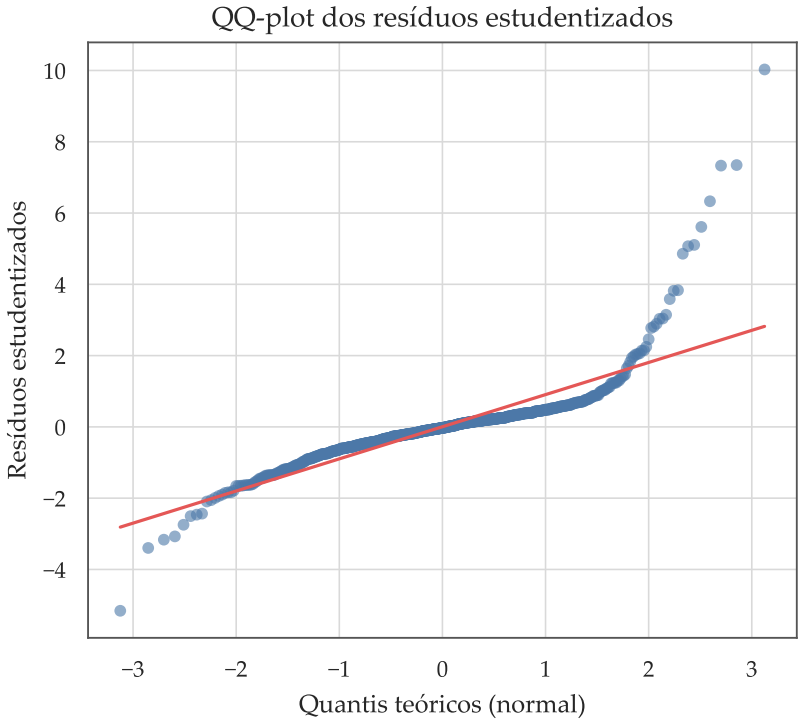


Figura 7. QQ-plot dos resíduos estudentizados do modelo final.

O QQ-plot (Figura 7) afasta-se da reta nas duas caudas, sobretudo na superior, com destaque para instituições de candidaturas atipicamente elevadas, como a observação 484.

Diante desse afastamento, o comportamento esperado sob erros normais foi reproduzido em 100 réplicas, mantendo-se a matriz de preditores de `College`. Em cada posição dos resíduos ordenados, os percentis 2,5% e 97,5% dessas réplicas formam a banda de referência do envelope.

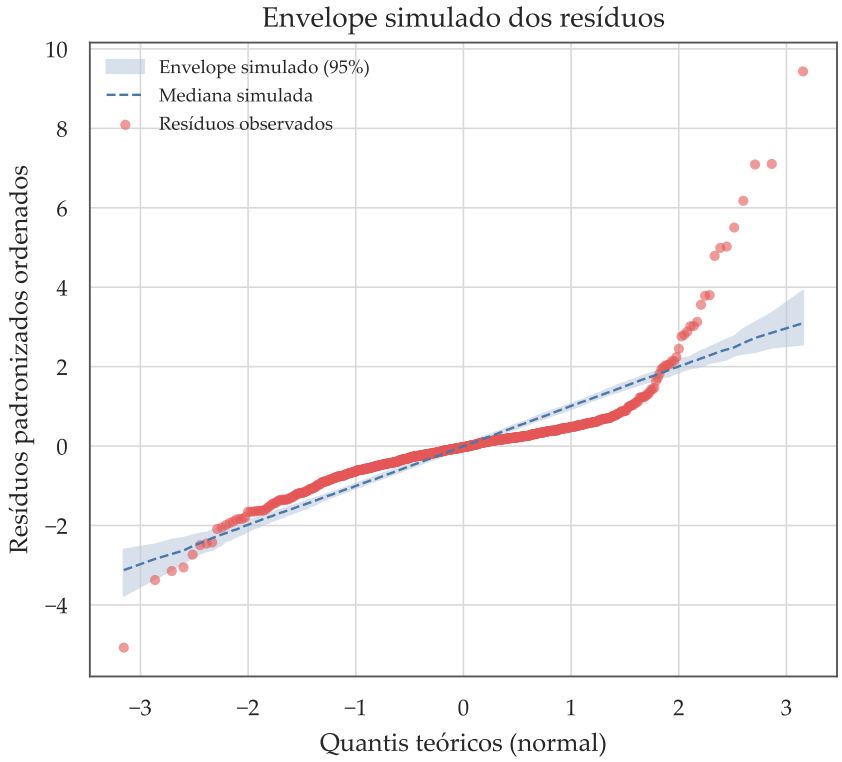


Figura 8. Gráfico de envelope simulado dos resíduos padronizados do modelo final.

Tabela 14: Estatísticas de normalidade dos resíduos do modelo final.

Estatística de Shapiro-Wilk	p-valor	Assimetria dos resíduos	Curtose dos resíduos	% fora do envelope
0,777	< 0,001	2,36	15,98	90,5

Segundo a Tabela 14, rejeita-se a normalidade ($p < 0,001$); assimetria, curtose e envelope (Figura 8) confirmam caudas pesadas e ampla saída da banda de 95%.

Em conjunto, os diagnósticos indicam violações de homocedasticidade e normalidade, associadas à assimetria de `Apps` e a observações extremas. Elas limitam erros-padrão, testes e intervalos clássicos, que exigem cautela. Erros-padrão robustos, transformação da resposta e modelos para contagens permanecem extensões não implementadas; os pontos influentes são examinados a seguir.

12 Pontos atípicos, de alavanca e influentes

Esta seção identifica observações atípicas (*outliers*), de alavanca (*leverage*) e influentes no modelo final, utilizando três medidas complementares: resíduos estudentizados (externamente), alavancagem (h_{ii}, diagonal da matriz de projeção) e distância de Cook. Como referência, foram adotados os limites usuais |resíduo estudentizado| > 3 para pontos atípicos, $h_{ii} > 2p/n$ para pontos de alavanca e $D_i > 4/n$ para pontos influentes, em que p é o número de parâmetros do modelo (incluindo o intercepto) e n o número de observações [5,6].

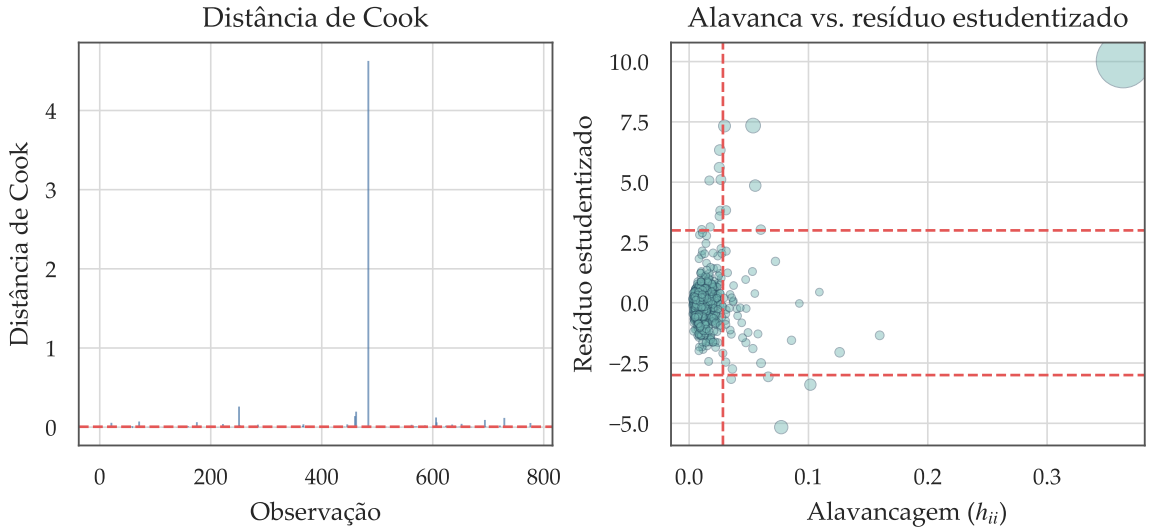


Figura 9. Distância de Cook e gráfico de influência (alavanca versus resíduo estudentizado) do modelo final.

Tabela 15: Observações que excedem simultaneamente os três critérios de alavanca, atipicidade e influência.

Observação	Instituição	Apps	Alavancagem	Resíduo estudentizado	Distância de Cook
484	Pública	48094	0,364	10,029	4,627
251	Privada	13865	0,054	7,347	0,260
462	Pública	21804	0,077	-5,160	0,196
460	Privada	13218	0,030	7,330	0,140
606	Pública	19873	0,055	4,858	0,122
729	Privada	7654	0,102	-3,397	0,117
607	Pública	15698	0,066	-3,073	0,060
776	Privada	10705	0,060	3,032	0,053
652	Pública	14596	0,031	3,834	0,042
635	Pública	14438	0,035	-3,165	0,033

A Figura 9 mostra a distribuição da distância de Cook e sua relação com alavancagem e resíduo estudentizado. Pelos limites adotados, 48 observações excedem a alavancagem, 46 a distância de Cook e 18 o resíduo estudentizado; as categorias não representam necessariamente problemas isolados de ajuste.

Uma leitura mais seletiva, que exige os três critérios simultaneamente (Tabela 15), reduz a lista a 10 instituições (1,3% da amostra). A observação 484, já destacada na Tabela 5, apresenta o maior impacto potencial. Todas permanecem no modelo final; o reajuste sem esses dez casos serve apenas como sensibilidade, sem classificá-los como erros.

Comparação resumida da análise de sensibilidade.

Medida	Modelo final	Sem os 10 casos
R^2 ajustado	0,927	0,933
Coeficiente de Accept	1,584	1,479
Coeficiente de Top10perc	49,139	33,640
Coeficiente de Private_Yes	-575,071	-543,574

Todos os sinais foram preservados e o R^2 ajustado aumentou ligeiramente. `Accept` e `Private_Yes` variaram 6,6% e 5,5%, enquanto `Top10perc` diminuiu 31,5%. As direções gerais permanecem, mas algumas magnitudes são sensíveis aos casos influentes, mantidos por não haver evidência de erro.

13 Previsões

Esta seção ilustra retrospectivamente o uso do modelo final por meio de dois perfis institucionais plausíveis, construídos a partir das medianas dos dez preditores do modelo, separadas por natureza da instituição. Para cada perfil, apresentam-se a previsão pontual, o intervalo de confiança de 95% para $E(Y \mid \mathbf{X} = \mathbf{x}_0)$ e o intervalo de predição de 95% para uma nova observação individual. A limitação prospectiva indicada na Introdução permanece.

Tabela 16: Perfis institucionais utilizados nas previsões, com base nas medianas por natureza da instituição.

Variável	Pública	Privada
Accept	2.929,5	859,0
Top10perc	19,0	25,0
Expend	6.716,5	8.954,0
Outstate	6.609,0	11.200,0
Enroll	1.337,5	328,0
Room.Board	3.708,0	4.400,0
Top25perc	51,0	55,0
Private_Yes	0,0	1,0
PhD	78,5	73,0
Grad.Rate	55,0	69,0

A Tabela 16 apresenta as características simultaneamente utilizadas em cada perfil.

Tabela 17: Previsão pontual, intervalo de confiança para a média e intervalo de predição (95%) para os dois perfis institucionais.

Perfil	Previsão pontual	IC 95% (inferior)	IC 95% (superior)	IP 95% (inferior)	IP 95% (superior)
Pública (mediana)	4.102,1	3.953,6	4.250,6	2.049,3	6.154,9
Privada (mediana)	1.053,0	957,1	1.148,9	-996,7	3.102,7

Os resultados da Tabela 17 usam a mesma estimativa pontual, mas respondem a perguntas distintas: uma sobre a média condicional e outra sobre uma nova instituição. Por incluir a dispersão individual, o intervalo de predição é mais largo [1]. Seu limite inferior negativo no perfil privado não equivale a zero e evidencia a limitação linear para contagens. Como indicado no diagnóstico, a cobertura dos intervalos clássicos requer cautela.

Os dois perfis reproduzem o padrão descritivo da Tabela 6, com previsão maior para o perfil público. A diferença combina a natureza da instituição e os demais valores específicos utilizados em cada perfil; portanto, não representa exclusivamente a associação de `Private`.

14 Conclusão

Este trabalho investigou retrospectivamente as associações entre características institucionais e `Apps` na base `College`. A exploração revelou forte assimetria da resposta e diferenças de porte, custo e investimento entre instituições públicas e privadas.

Entre as especificações comparadas, o Forward (BIC) foi selecionado por reduzir a multicolinearidade severa com pequena perda de ajuste. A validação cruzada sugere estabilidade da especificação fixada, e os coeficientes descrevem associações parciais, não relações causais.

Os diagnósticos de heterocedasticidade, não normalidade e influência restringem a inferência e a previsão; a sensibilidade preservou os sinais, mas apontou variação em algumas magnitudes. Assim, o modelo oferece uma descrição parcimoniosa das associações de `Apps` com admissão, seletividade, custo, investimento e natureza institucional, condicionada à amostra e às limitações discutidas. Extensões robustas, transformações ou modelos para contagens ficam fora do escopo deste trabalho.

Referências

[1] Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.

[2] James G, Witten D, Hastie T, Tibshirani R. 2021 *An Introduction to Statistical Learning: with Applications in R*. New York: Springer 2 edition.

[3] Akaike H. 1974 A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control* **19**, 716–723.

[4] Schwarz G. 1978 Estimating the Dimension of a Model. *The Annals of Statistics* **6**, 461–464.

[5] Cook RD. 1977 Detection of Influential Observation in Linear Regression. *Technometrics* **19**, 15–18.

[6] Cook RD, Weisberg S. 1982 *Residuals and Influence in Regression*. New York: Chapman and Hall.