

Universidade Federal
de Campina Grande

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Departamento de Ciência da Computação

Isadora Beatriz Lucena de Medeiros

Jennifer Raysa Medeiros Cavalcanti

Oscar Rodrigues da Silva Neto

MODELAGEM DO NÚMERO DE CANDIDATURAS EM UNIVERSIDADES DOS ESTADOS UNIDOS POR REGRESSÃO LINEAR MÚLTIPLA

Relatório apresentado à disciplina de *Estatística Aplicada*, período 2026.1.

Profa. Dra. Amanda Gomes
Prof. Dr. Jerfson Bruno
Prof. Dr. Gilberto Matos

Campina Grande – PB
2026

RESUMO

Este trabalho aplica a metodologia de Regressão Linear Múltipla (MRLM) ao conjunto de dados `college`, com o objetivo de modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos a partir de características institucionais, acadêmicas e financeiras. Inicialmente, foi realizada uma análise exploratória univariada e bivariada, incluindo estatísticas descritivas, visualizações gráficas, análise de correlação e verificação da presença de dados ausentes. Em seguida, foi ajustado um modelo inicial contendo todas as variáveis explicativas disponíveis, sendo investigada a presença de multicolinearidade e comparadas especificações alternativas para seleção do modelo final. Os pressupostos da regressão linear foram avaliados por meio da análise dos resíduos, gráfico de envelope simulado e identificação de observações atípicas, de alavanca e influentes. Por fim, foi analisada a contribuição da variável categórica `Private` por meio de variáveis indicadoras (dummies) e foram construídos intervalos de confiança para o valor médio esperado da resposta e intervalos de predição para novas observações, acompanhados de suas interpretações práticas.

Áreas temáticas: estatística aplicada, ciência de dados

Palavras-chave: regressão linear múltipla, análise exploratória, seleção de modelos, multicolinearidade, diagnóstico de resíduos, variáveis dummy

Sumário

1 Introdução 3

2 Metodologia 3

3 Descrição e qualidade dos dados 3

4 Análise exploratória univariada e bivariada 4

4.1 Estatísticas descritivas 4

4.2 Distribuição de Apps e valores extremos 5

4.3 Comparação entre instituições públicas e privadas 6

4.4 Estrutura bivariada inicial 7

5 Modelo inicial 9

5.1 Formulação do modelo 9

5.2 Coeficientes e ajuste global 10

6 Correlação e multicolinearidade 11

7 Seleção do modelo final 11

8 Validação cruzada K-Fold 11

9 Interpretação dos coeficientes 11

10 Diagnóstico do modelo 11

11 QQ Plot e normalidade dos resíduos 11

12 Pontos atípicos, de alavanca e influentes 11

13 Previsões 11

14 Conclusão 11

Referências 11

1 Introdução

O número de candidaturas recebidas por uma instituição de ensino superior pode ser considerado um indicador de sua demanda e de sua atratividade entre potenciais estudantes. Esse volume pode estar associado a características como porte institucional, custos, perfil acadêmico dos ingressantes, qualificação do corpo docente e investimentos realizados pela universidade.

O objetivo deste estudo é investigar a associação entre essas características e o número de candidaturas recebidas por meio da Regressão Linear Múltipla (MRLM). Inicialmente, será ajustado um modelo contendo todas as variáveis explicativas disponíveis, que servirá de referência para as etapas posteriores de seleção, validação e diagnóstico [1].

2 Metodologia

O estudo utiliza dados secundários provenientes da base `College`, disponibilizada no pacote `ISLR` e compilada a partir de informações publicadas pelo *U.S. News & World Report* [2]. A análise foi realizada com os registros originais da base, sem coleta direta ou alteração dos dados brutos.

3 Descrição e qualidade dos dados

A base reúne dados de 777 instituições de ensino superior dos Estados Unidos e contém 18 atributos. A resposta analisada é `Apps`, que corresponde ao número de candidaturas recebidas. Entre os preditores, `Private` é o único categórico e distingue universidades públicas (`No`) e privadas (`Yes`), totalizando 212 e 565 casos, respectivamente. Os demais atributos são numéricos e abrangem informações sobre admissão, quantidade de estudantes, custos, perfil acadêmico, corpo docente e investimentos. A Tabela 1 apresenta a descrição e a unidade de cada campo.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
Private	Categoria	Natureza da instituição: No = pública; Yes = privada.
Apps	Contagem	Candidaturas recebidas; variável resposta.
Accept	Contagem	Candidaturas aceitas.
Enroll	Contagem	Novos alunos matriculados.
Top10perc	%	Ingressantes no top 10% da turma do ensino médio.
Top25perc	%	Ingressantes no top 25% da turma do ensino médio.
F.Undergrad	Contagem	Graduandos em tempo integral.
P.Undergrad	Contagem	Graduandos em tempo parcial.
Outstate	US$	Mensalidade para estudantes de fora do estado.
Room.Board	US$	Custo de moradia e alimentação.
Books	US$	Custo estimado com livros.
Personal	US$	Gasto pessoal estimado.
PhD	%	Corpo docente com doutorado.
Terminal	%	Corpo docente com grau terminal da área.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
S.F.Ratio	Razão	Número de estudantes por docente.
perc.alumni	%	Ex-alunos que realizam doações.
Expend	US$/aluno	Gasto institucional por aluno.
Grad.Rate	%	Taxa de graduação.

A Tabela 2 sintetiza as verificações de completude, duplicidade, faixas e relações lógicas entre as variáveis.

Tabela 2: Síntese das verificações de qualidade dos dados.

Verificação	Critério	Ocorrências
Valores ausentes	Nenhum	0
Linhas duplicadas	Nenhuma	0
Enroll > Accept	Nenhum caso esperado	0
Accept > Apps	Nenhum caso esperado	0
Top10perc > Top25perc	Nenhum caso esperado	0
Percentuais fora de [0, 100]	Requer conferência	2

Os resultados permitem utilizar todas as observações sem imputação ou correção prévia. As únicas ressalvas são `Grad.Rate = 118`, na observação 96, e `PhD = 103`, na observação 583; sem informação que confirme sua origem, ambos foram preservados para posterior análise de sensibilidade.

Tabela 3: Observações com percentuais superiores a 100.

Observação	Private	Apps	Accept	Enroll	PhD	Terminal	Grad.Rate
96	Privada	3847	3433	527	22	47	118
583	Pública	529	481	243	103	88	43

4 Análise exploratória univariada e bivariada

4.1 Estatísticas descritivas

As estatísticas da Tabela 4 mostram heterogeneidade entre as instituições e assimetria à direita nas principais medidas de demanda e porte. Em `Apps`, por exemplo, a média é quase o dobro da mediana, indicando que poucas instituições com demanda muito elevada deslocam a média para cima.

Tabela 4: Estatísticas descritivas das variáveis numéricas.

Variável	Média	DP	Mín.	Q1	Mediana	Q3	Máx.
Apps	3.001,6	3.870,2	81,0	776,0	1.558,0	3.624,0	48.094,0
Accept	2.018,8	2.451,1	72,0	604,0	1.110,0	2.424,0	26.330,0
Enroll	780,0	929,2	35,0	242,0	434,0	902,0	6.392,0
Top10perc	27,6	17,6	1,0	15,0	23,0	35,0	96,0
Top25perc	55,8	19,8	9,0	41,0	54,0	69,0	100,0
F.Undergrad	3.699,9	4.850,4	139,0	992,0	1.707,0	4.005,0	31.643,0
P.Undergrad	855,3	1.522,4	1,0	95,0	353,0	967,0	21.836,0
Outstate	10.440,7	4.023,0	2.340,0	7.320,0	9.990,0	12.925,0	21.700,0
Room.Board	4.357,5	1.096,7	1.780,0	3.597,0	4.200,0	5.050,0	8.124,0
Books	549,4	165,1	96,0	470,0	500,0	600,0	2.340,0
Personal	1.340,6	677,1	250,0	850,0	1.200,0	1.700,0	6.800,0
PhD	72,7	16,3	8,0	62,0	75,0	85,0	103,0
Terminal	79,7	14,7	24,0	71,0	82,0	92,0	100,0
S.F.Ratio	14,1	4,0	2,5	11,5	13,6	16,5	39,8
perc.alumni	22,7	12,4	0,0	13,0	21,0	31,0	64,0
Expend	9.660,2	5.221,8	3.186,0	6.751,0	8.377,0	10.830,0	56.233,0
Grad.Rate	65,5	17,2	10,0	53,0	65,0	78,0	118,0

4.2 Distribuição de Apps e valores extremos

`Apps` varia de 81 a 48.094 candidaturas, com média de 3.001,6, mediana de 1.558 e assimetria amostral de 3,72. A Figura 1 confirma a forte cauda à direita.

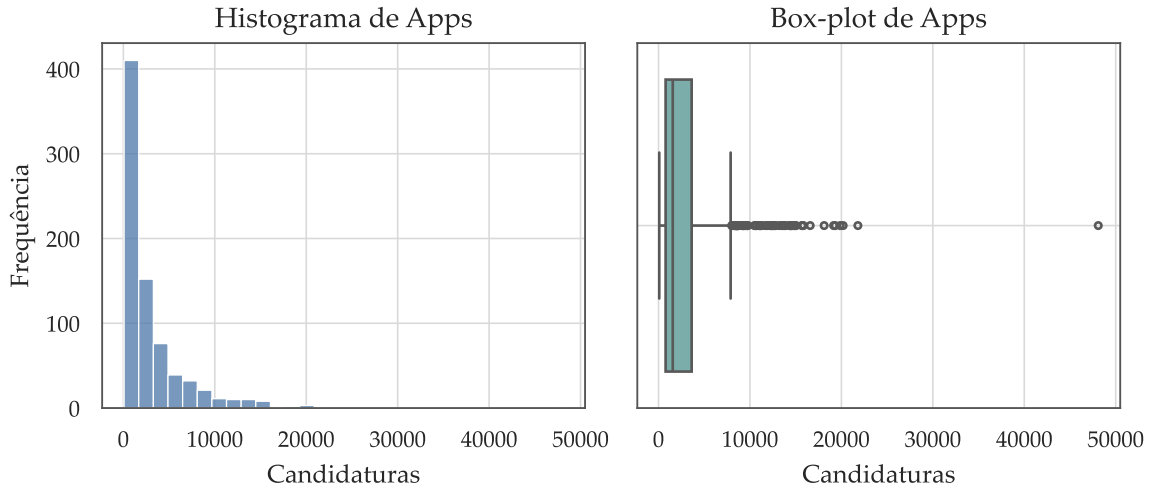


Figura 1. Histograma e box-plot do número de candidaturas recebidas.

Pela regra de $1{,}5\,AIQ$, 70 instituições, aproximadamente 9% da amostra, superam 7.896 candidaturas. Os cinco maiores valores constam na Tabela 5; eles caracterizam a heterogeneidade da base e não são tratados automaticamente como erros.

Tabela 5: Cinco observações com os maiores valores de Apps.

Observação	Private	Apps	Accept	Enroll	F.Undergrad	Grad.Rate
484	Pública	48094	26330	4520	21401	77
462	Pública	21804	18744	5874	26213	67
60	Privada	20192	13007	3810	14971	72
606	Pública	19873	8252	3215	19532	78
446	Pública	19315	10344	3450	28938	63

4.3 Comparação entre instituições públicas e privadas

As instituições públicas apresentam maior número típico de candidaturas: as medianas são 4.307 nas públicas e 1.133 nas privadas. A Tabela 6 amplia a comparação para medidas de admissão, porte, mensalidade e investimento.

Tabela 6: Média e desvio-padrão de variáveis selecionadas, por natureza da instituição.

Instituição	Variável	Média	DP
Pública	Apps	5.729,9	5.370,7
Privada	Apps	1.977,9	2.443,3
Pública	Accept	3.919,3	3.477,3
Privada	Accept	1.305,7	1.369,5
Pública	Enroll	1.640,9	1.261,6
Privada	Enroll	456,9	457,5
Pública	F.Undergrad	8.571,0	6.467,7
Privada	F.Undergrad	1.872,2	2.110,7
Pública	Outstate	6.813,4	2.145,2
Privada	Outstate	11.801,7	3.707,5
Pública	Expend	7.458,3	2.695,5
Privada	Expend	10.486,4	5.682,6

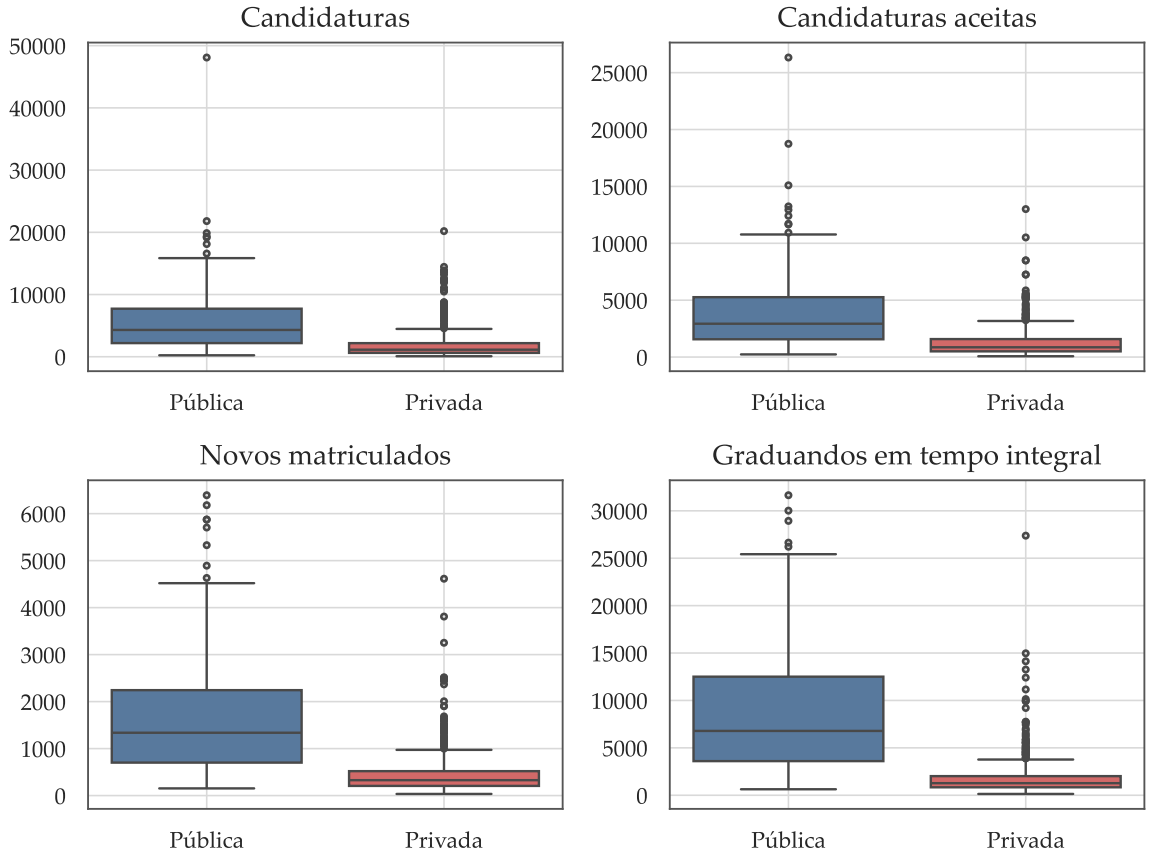


Figura 2. Box-plots de medidas de demanda e porte, por natureza da instituição.

As públicas apresentam maiores médias de demanda e porte, enquanto as privadas possuem maiores médias de `Outstate` e `Expend`. Esse contraste sugere perfis institucionais distintos e indica que a diferença bruta em `Apps` também pode refletir porte, custos e investimento; trata-se, portanto, de comparação descritiva, sem interpretação causal.

4.4 Estrutura bivariada inicial

A Figura 3 resume as associações lineares iniciais. `Apps` apresenta relações positivas mais intensas com `Accept`, `Enroll` e `F.Undergrad`, variáveis ligadas ao processo de admissão e ao porte da instituição.

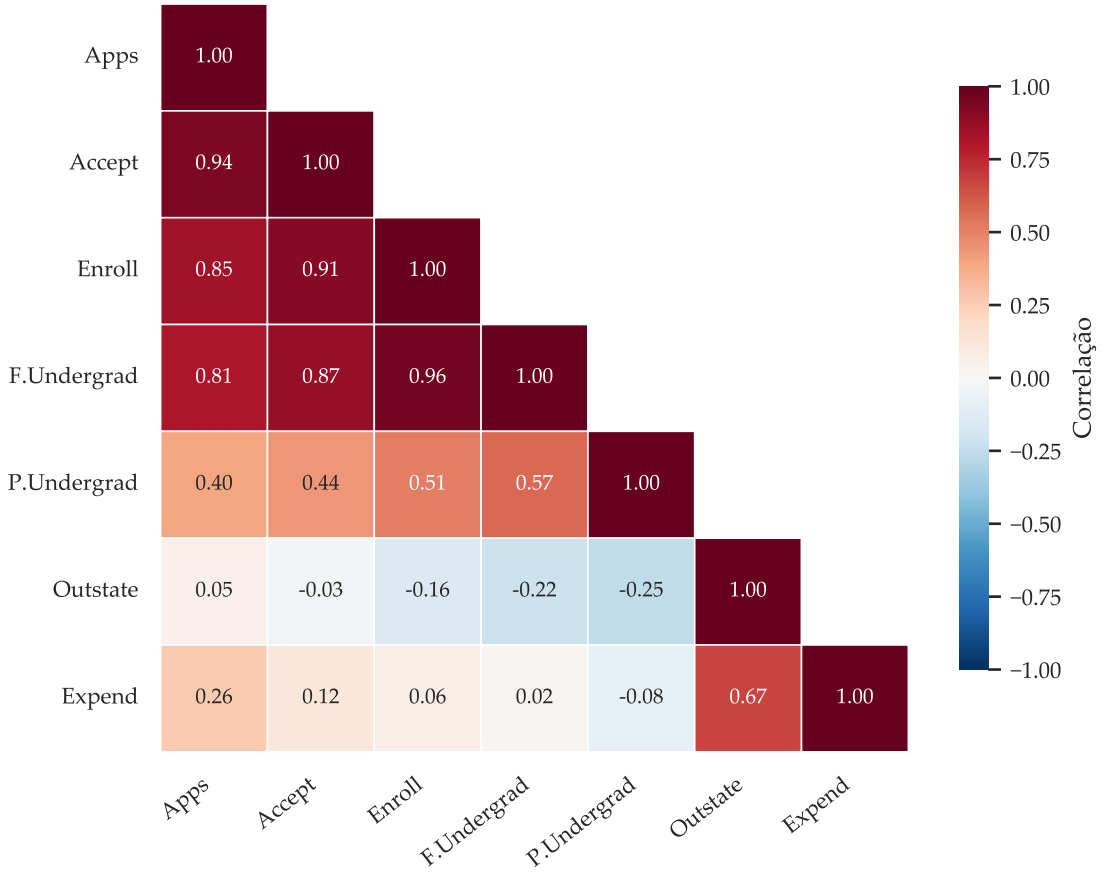


Figura 3. Matriz exploratória de correlações entre Apps e variáveis selecionadas.

A Figura 4 complementa o resumo ao mostrar a forma das relações, as distribuições marginais e os grupos público e privado. As tendências são predominantemente crescentes, mas a variabilidade de `Apps` aumenta nos níveis mais altos dos preditores.

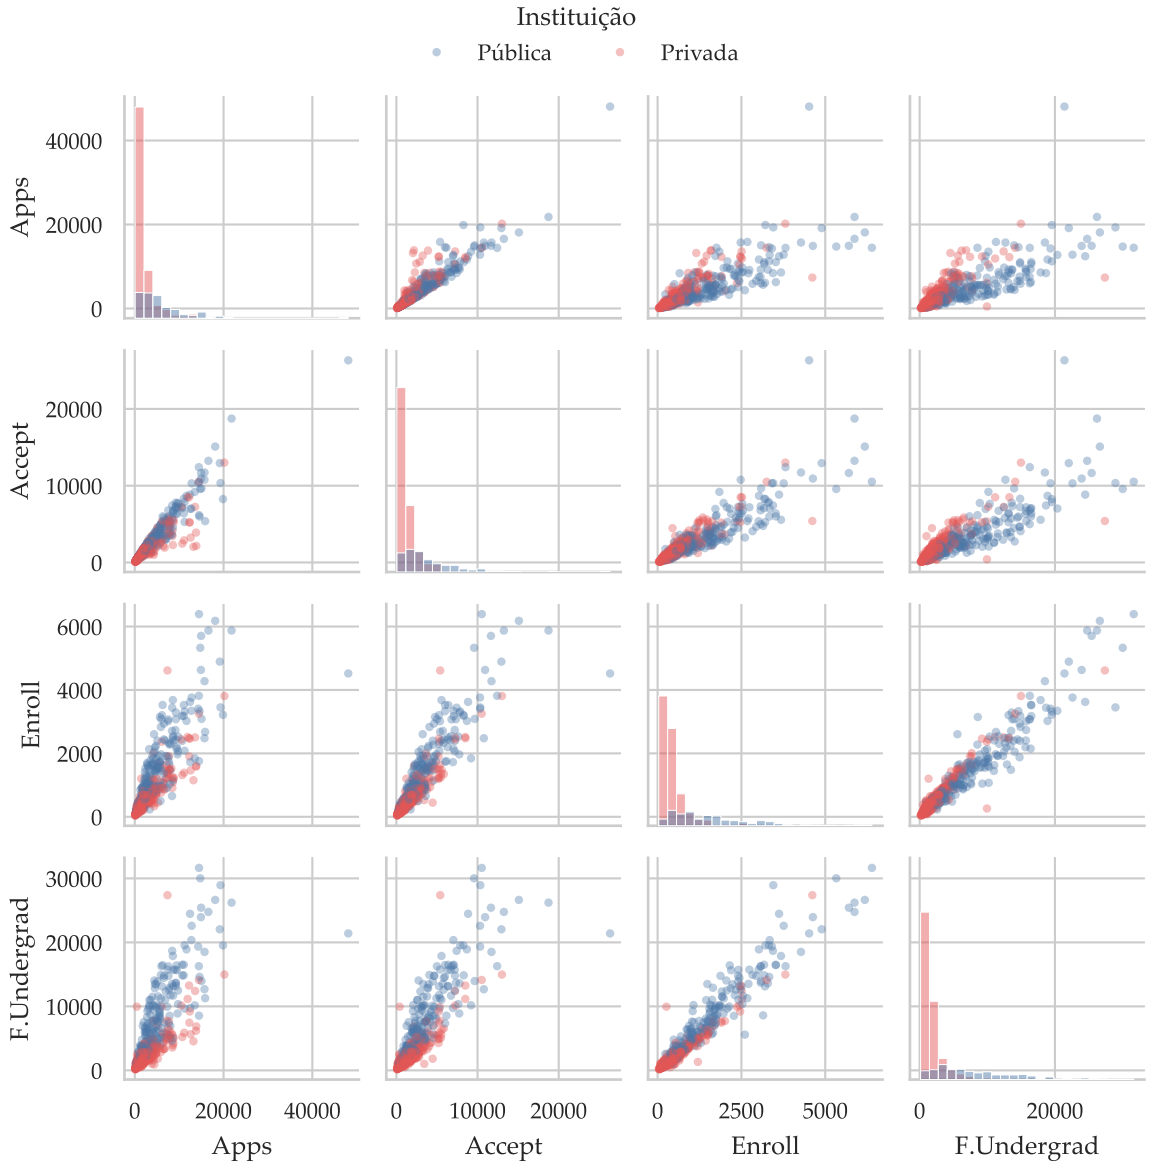


Figura 4. Matriz de dispersão de medidas de demanda e porte, por natureza da instituição.

Esses gráficos constituem apenas uma triagem; a avaliação formal permanece reservada à seção de correlação e multicolinearidade.

5 Modelo inicial

O modelo inicial inclui os 16 preditores numéricos e a variável categórica `Private`. Para sua incorporação, foi definida `Private_Yes = 1` para instituições privadas e 0 para públicas, tornando as instituições públicas a categoria de referência. O ajuste foi realizado por mínimos quadrados ordinários com as 777 observações, sem seleção ou remoção de variáveis.

5.1 Formulação do modelo

Seja x_{ij} o valor do j-ésimo preditor numérico para a instituição i. A forma geral do modelo completo é:

$$\text{Apps}_i = \beta_0 + \beta_1 \text{Private_Yes}_i + \sum_{j=2}^{17} \beta_j x_{ij} + \varepsilon_i.$$

Nessa expressão, cada β_j representa uma associação parcial com `Apps`, mantidos os demais preditores constantes, e ε_i reúne a variação não explicada pelo modelo.

5.2 Coeficientes e ajuste global

As estimativas dos coeficientes, erros-padrão, estatísticas de teste e intervalos de confiança são apresentadas na Tabela 7.

Tabela 7: Estimativas do modelo linear inicial com todos os preditores.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-445,084	408,329	-1,090	0,276	-1.246,672	356,503
Accept	1,586	0,041	38,924	< 0,001	1,506	1,666
Enroll	-0,881	0,186	-4,736	< 0,001	-1,246	-0,516
Top10perc	49,926	5,578	8,950	< 0,001	38,976	60,877
Top25perc	-14,234	4,479	-3,178	0,002	-23,027	-5,441
F.Undergrad	0,057	0,033	1,754	0,080	-0,007	0,122
P.Undergrad	0,044	0,032	1,383	0,167	-0,019	0,108
Outstate	-0,086	0,019	-4,506	< 0,001	-0,123	-0,048
Room.Board	0,151	0,048	3,127	0,002	0,056	0,246
Books	0,021	0,238	0,088	0,930	-0,447	0,489
Personal	0,031	0,063	0,493	0,622	-0,093	0,155
PhD	-8,678	4,638	-1,871	0,062	-17,784	0,427
Terminal	-3,331	5,095	-0,654	0,513	-13,333	6,671
S.F.Ratio	15,390	13,006	1,183	0,237	-10,143	40,922
perc.alumni	0,179	4,102	0,044	0,965	-7,875	8,232
Expend	0,078	0,012	6,308	< 0,001	0,054	0,102
Grad.Rate	8,668	2,949	2,939	0,003	2,879	14,457
Privada (Yes versus No)	-494,149	137,812	-3,586	< 0,001	-764,687	-223,611

O R^2 ajustado de 0,9276 indica que o conjunto de preditores descreve 92,76% da variação amostral de `Apps`; o teste global confirma que o modelo possui contribuição explicativa ($F = 585{,}86$; $p < 0{,}001$). Ao nível de 5%, `Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `Expend`, `Grad.Rate` e `Private_Yes` apresentam coeficientes significativos.

Mantidos os demais preditores constantes, o coeficiente de `Private_Yes` associa instituições privadas a cerca de 494 candidaturas a menos que instituições públicas. Essa interpretação é preliminar: a proximidade entre variáveis de admissão e porte pode afetar sinais e erros-padrão, razão pela qual nenhum preditor é removido nesta etapa.

6 Correlação e multicolinearidade

Esta seção avaliará a correlação e a multicolinearidade entre os preditores do modelo.

7 Seleção do modelo final

Esta seção comparará modelos candidatos e justificará a escolha da especificação final.

8 Validação cruzada K-Fold

Esta seção avaliará o desempenho preditivo e a estabilidade do modelo selecionado.

9 Interpretação dos coeficientes

Esta seção interpretará os coeficientes do modelo final no contexto das características institucionais.

10 Diagnóstico do modelo

Esta seção verificará a adequação do modelo selecionado aos pressupostos da regressão linear.

11 QQ Plot e normalidade dos resíduos

Esta seção avaliará graficamente a normalidade dos resíduos do modelo.

12 Pontos atípicos, de alavanca e influentes

Esta seção investigará observações atípicas, de alavanca e influentes.

13 Previsões

Esta seção apresentará previsões e respectivos intervalos para perfis plausíveis de instituições.

14 Conclusão

Esta seção sintetizará os principais resultados e retomará a pergunta de pesquisa.

Referências

[1] Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.

[2] James G, Witten D, Hastie T, Tibshirani R. 2021 *An Introduction to Statistical Learning: with Applications in R*. New York: Springer 2 edition.