

Universidade Federal
de Campina Grande

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Departamento de Ciência da Computação

Isadora Beatriz Lucena de Medeiros

Jennifer Raysa Medeiros Cavalcanti

Oscar Rodrigues da Silva Neto

MODELAGEM DO NÚMERO DE CANDIDATURAS EM UNIVERSIDADES DOS ESTADOS UNIDOS POR REGRESSÃO LINEAR MÚLTIPLA

Relatório apresentado à disciplina de *Estatística Aplicada*, período 2026.1.

Profa. Dra. Amanda Gomes
Prof. Dr. Jerfson Bruno
Prof. Dr. Gilberto Matos

Campina Grande – PB
2026

RESUMO

Este trabalho aplica a metodologia de Regressão Linear Múltipla (MRLM) ao conjunto de dados `college`, com o objetivo de modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos a partir de características institucionais, acadêmicas e financeiras. Inicialmente, foi realizada uma análise exploratória univariada e bivariada, incluindo estatísticas descritivas, visualizações gráficas, análise de correlação e verificação da presença de dados ausentes. Em seguida, foi ajustado um modelo inicial contendo todas as variáveis explicativas disponíveis, sendo investigada a presença de multicolinearidade e comparadas especificações alternativas para seleção do modelo final. Os pressupostos da regressão linear foram avaliados por meio da análise dos resíduos, gráfico de envelope simulado e identificação de observações atípicas, de alavanca e influentes. Por fim, foi analisada a contribuição da variável categórica `Private` por meio de variáveis indicadoras (dummies) e foram construídos intervalos de confiança para o valor médio esperado da resposta e intervalos de predição para novas observações, acompanhados de suas interpretações práticas.

Áreas temáticas: estatística aplicada, ciência de dados

Palavras-chave: regressão linear múltipla, análise exploratória, seleção de modelos, multicolinearidade, diagnóstico de resíduos, variáveis dummy

Sumário

1 Introdução 3

2 Metodologia 3

3 Descrição e qualidade dos dados 3

4 Análise exploratória univariada e bivariada 4

4.1 Estatísticas descritivas 4

4.2 Distribuição de Apps e valores extremos 5

4.3 Comparação entre instituições públicas e privadas 6

4.4 Estrutura bivariada inicial 7

5 Modelo inicial 9

5.1 Formulação do modelo 9

5.2 Coeficientes e ajuste global 10

6 Correlação e multicolinearidade 11

7 Seleção do modelo final 12

7.1 Seleção dos modelos 12

7.2 Modelo final selecionado 13

8 Validação cruzada K-Fold 14

9 Interpretação dos coeficientes 14

10 Diagnóstico do modelo 15

11 QQ Plot e normalidade dos resíduos 17

12 Pontos atípicos, de alavanca e influentes 18

13 Previsões 20

14 Conclusão 21

Referências 21

1 Introdução

O número de candidaturas recebidas por uma instituição de ensino superior pode ser considerado um indicador de sua demanda e de sua atratividade entre potenciais estudantes. Esse volume pode estar associado a características como porte institucional, custos, perfil acadêmico dos ingressantes, qualificação do corpo docente e investimentos realizados pela universidade.

O objetivo deste estudo é investigar a associação entre essas características e o número de candidaturas recebidas por meio da Regressão Linear Múltipla (MRLM). Inicialmente, será ajustado um modelo contendo todas as variáveis explicativas disponíveis, que servirá de referência para as etapas posteriores de seleção, validação e diagnóstico [1].

2 Metodologia

O estudo utiliza dados secundários provenientes da base `College`, disponibilizada no pacote `ISLR` e compilada a partir de informações publicadas pelo *U.S. News & World Report* [2]. A análise foi realizada com os registros originais da base, sem coleta direta ou alteração dos dados brutos.

3 Descrição e qualidade dos dados

A base reúne dados de 777 instituições de ensino superior dos Estados Unidos e contém 18 atributos. A resposta analisada é `Apps`, que corresponde ao número de candidaturas recebidas. Entre os preditores, `Private` é o único categórico e distingue universidades públicas (`No`) e privadas (`Yes`), totalizando 212 e 565 casos, respectivamente. Os demais atributos são numéricos e abrangem informações sobre admissão, quantidade de estudantes, custos, perfil acadêmico, corpo docente e investimentos. A Tabela 1 apresenta a descrição e a unidade de cada campo.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
Private	Categoria	Natureza da instituição: No = pública; Yes = privada.
Apps	Contagem	Candidaturas recebidas; variável resposta.
Accept	Contagem	Candidaturas aceitas.
Enroll	Contagem	Novos alunos matriculados.
Top10perc	%	Ingressantes no top 10% da turma do ensino médio.
Top25perc	%	Ingressantes no top 25% da turma do ensino médio.
F.Undergrad	Contagem	Graduandos em tempo integral.
P.Undergrad	Contagem	Graduandos em tempo parcial.
Outstate	US$	Mensalidade para estudantes de fora do estado.
Room.Board	US$	Custo de moradia e alimentação.
Books	US$	Custo estimado com livros.
Personal	US$	Gasto pessoal estimado.
PhD	%	Corpo docente com doutorado.
Terminal	%	Corpo docente com grau terminal da área.

Tabela 1: Descrição das variáveis da base College.

Variável	Unidade/tipo	Descrição
S.F.Ratio	Razão	Número de estudantes por docente.
perc.alumni	%	Ex-alunos que realizam doações.
Expend	US$/aluno	Gasto institucional por aluno.
Grad.Rate	%	Taxa de graduação.

A Tabela 2 sintetiza as verificações de completude, duplicidade, faixas e relações lógicas entre as variáveis.

Tabela 2: Síntese das verificações de qualidade dos dados.

Verificação	Critério	Ocorrências
Valores ausentes	Nenhum	0
Linhas duplicadas	Nenhuma	0
Enroll > Accept	Nenhum caso esperado	0
Accept > Apps	Nenhum caso esperado	0
Top10perc > Top25perc	Nenhum caso esperado	0
Percentuais fora de [0, 100]	Requer conferência	2

Os resultados permitem utilizar todas as observações sem imputação ou correção prévia. As únicas ressalvas são `Grad.Rate = 118`, na observação 96, e `PhD = 103`, na observação 583; sem informação que confirme sua origem, ambos foram preservados para posterior análise de sensibilidade.

Tabela 3: Observações com percentuais superiores a 100.

Observação	Private	Apps	Accept	Enroll	PhD	Terminal	Grad.Rate
96	Privada	3847	3433	527	22	47	118
583	Pública	529	481	243	103	88	43

4 Análise exploratória univariada e bivariada

4.1 Estatísticas descritivas

As estatísticas da Tabela 4 mostram heterogeneidade entre as instituições e assimetria à direita nas principais medidas de demanda e porte. Em `Apps`, por exemplo, a média é quase o dobro da mediana, indicando que poucas instituições com demanda muito elevada deslocam a média para cima.

Tabela 4: Estatísticas descritivas das variáveis numéricas.

Variável	Média	DP	Mín.	Q1	Mediana	Q3	Máx.
Apps	3.001,6	3.870,2	81,0	776,0	1.558,0	3.624,0	48.094,0
Accept	2.018,8	2.451,1	72,0	604,0	1.110,0	2.424,0	26.330,0
Enroll	780,0	929,2	35,0	242,0	434,0	902,0	6.392,0
Top10perc	27,6	17,6	1,0	15,0	23,0	35,0	96,0
Top25perc	55,8	19,8	9,0	41,0	54,0	69,0	100,0
F.Undergrad	3.699,9	4.850,4	139,0	992,0	1.707,0	4.005,0	31.643,0
P.Undergrad	855,3	1.522,4	1,0	95,0	353,0	967,0	21.836,0
Outstate	10.440,7	4.023,0	2.340,0	7.320,0	9.990,0	12.925,0	21.700,0
Room.Board	4.357,5	1.096,7	1.780,0	3.597,0	4.200,0	5.050,0	8.124,0
Books	549,4	165,1	96,0	470,0	500,0	600,0	2.340,0
Personal	1.340,6	677,1	250,0	850,0	1.200,0	1.700,0	6.800,0
PhD	72,7	16,3	8,0	62,0	75,0	85,0	103,0
Terminal	79,7	14,7	24,0	71,0	82,0	92,0	100,0
S.F.Ratio	14,1	4,0	2,5	11,5	13,6	16,5	39,8
perc.alumni	22,7	12,4	0,0	13,0	21,0	31,0	64,0
Expend	9.660,2	5.221,8	3.186,0	6.751,0	8.377,0	10.830,0	56.233,0
Grad.Rate	65,5	17,2	10,0	53,0	65,0	78,0	118,0

4.2 Distribuição de Apps e valores extremos

`Apps` varia de 81 a 48.094 candidaturas, com média de 3.001,6, mediana de 1.558 e assimetria amostral de 3,72. A Figura 1 confirma a forte cauda à direita.

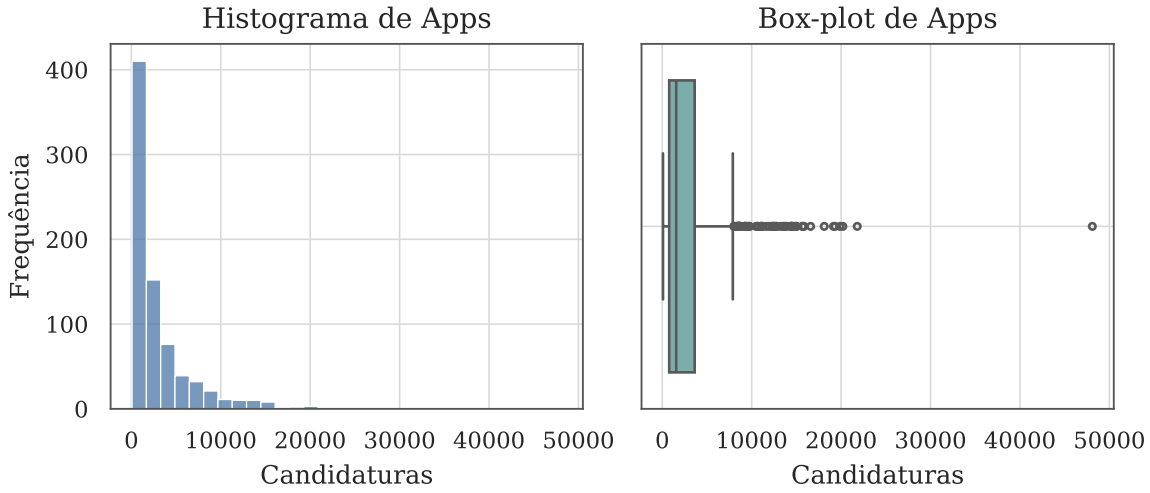


Figura 1. Histograma e box-plot do número de candidaturas recebidas.

Pela regra de $1{,}5\,AIQ$, 70 instituições, aproximadamente 9% da amostra, superam 7.896 candidaturas. Os cinco maiores valores constam na Tabela 5; eles caracterizam a heterogeneidade da base e não são tratados automaticamente como erros.

Tabela 5: Cinco observações com os maiores valores de Apps.

Observação	Private	Apps	Accept	Enroll	F.Undergrad	Grad.Rate
484	Pública	48094	26330	4520	21401	77
462	Pública	21804	18744	5874	26213	67
60	Privada	20192	13007	3810	14971	72
606	Pública	19873	8252	3215	19532	78
446	Pública	19315	10344	3450	28938	63

4.3 Comparação entre instituições públicas e privadas

As instituições públicas apresentam maior número típico de candidaturas: as medianas são 4.307 nas públicas e 1.133 nas privadas. A Tabela 6 amplia a comparação para medidas de admissão, porte, mensalidade e investimento.

Tabela 6: Média e desvio-padrão de variáveis selecionadas, por natureza da instituição.

Instituição	Variável	Média	DP
Pública	Apps	5.729,9	5.370,7
Privada	Apps	1.977,9	2.443,3
Pública	Accept	3.919,3	3.477,3
Privada	Accept	1.305,7	1.369,5
Pública	Enroll	1.640,9	1.261,6
Privada	Enroll	456,9	457,5
Pública	F.Undergrad	8.571,0	6.467,7
Privada	F.Undergrad	1.872,2	2.110,7
Pública	Outstate	6.813,4	2.145,2
Privada	Outstate	11.801,7	3.707,5
Pública	Expend	7.458,3	2.695,5
Privada	Expend	10.486,4	5.682,6

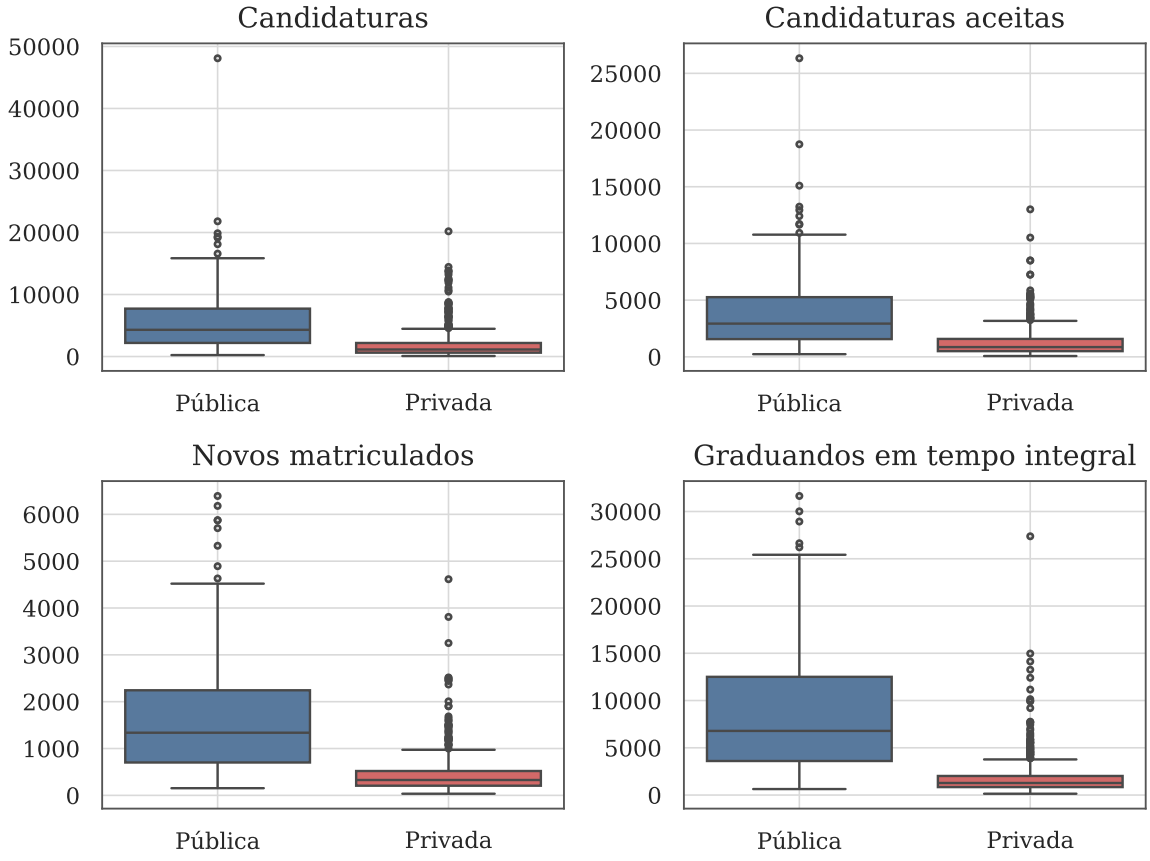


Figura 2. Box-plots de medidas de demanda e porte, por natureza da instituição.

As públicas apresentam maiores médias de demanda e porte, enquanto as privadas possuem maiores médias de `Outstate` e `Expend`. Esse contraste sugere perfis institucionais distintos e indica que a diferença bruta em `Apps` também pode refletir porte, custos e investimento; trata-se, portanto, de comparação descritiva, sem interpretação causal.

4.4 Estrutura bivariada inicial

A Figura 3 resume as associações lineares iniciais. `Apps` apresenta relações positivas mais intensas com `Accept`, `Enroll` e `F.Undergrad`, variáveis ligadas ao processo de admissão e ao porte da instituição.

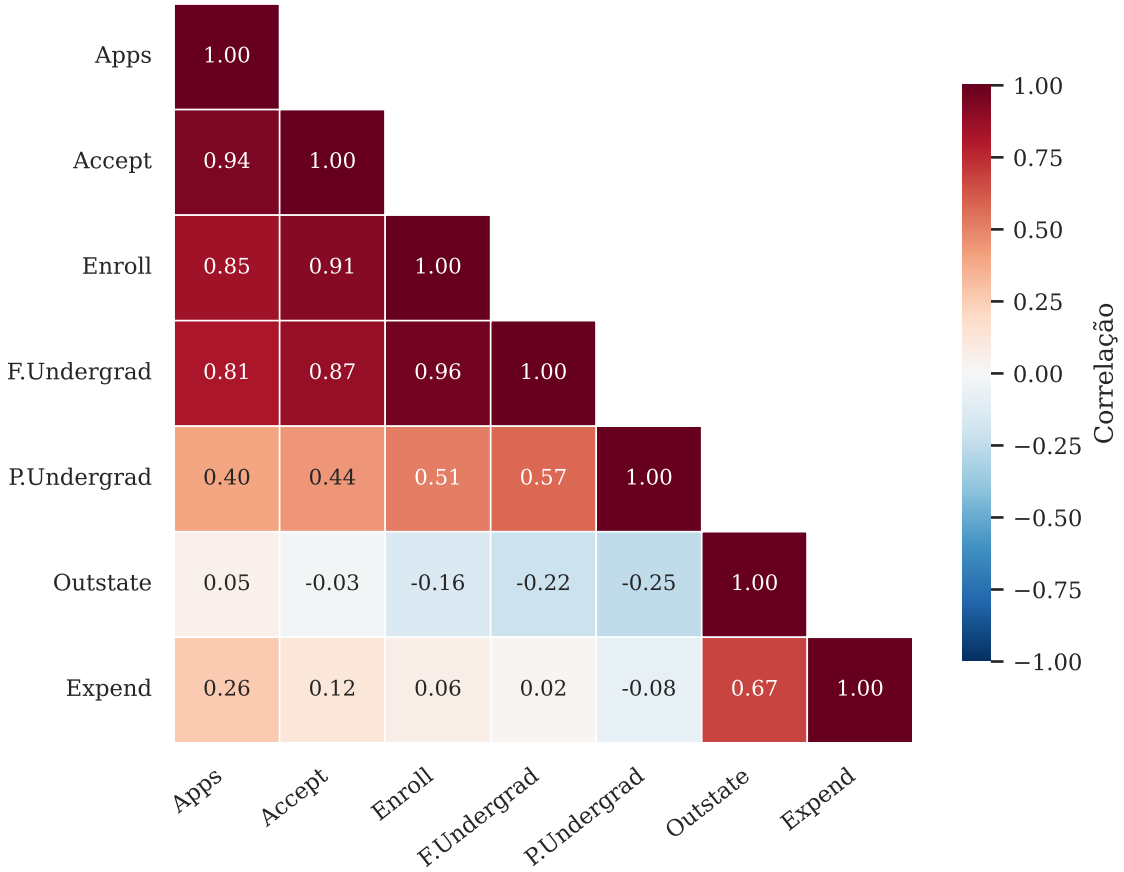


Figura 3. Matriz exploratória de correlações entre Apps e variáveis selecionadas.

A Figura 4 complementa o resumo ao mostrar a forma das relações, as distribuições marginais e os grupos público e privado. As tendências são predominantemente crescentes, mas a variabilidade de `Apps` aumenta nos níveis mais altos dos preditores.

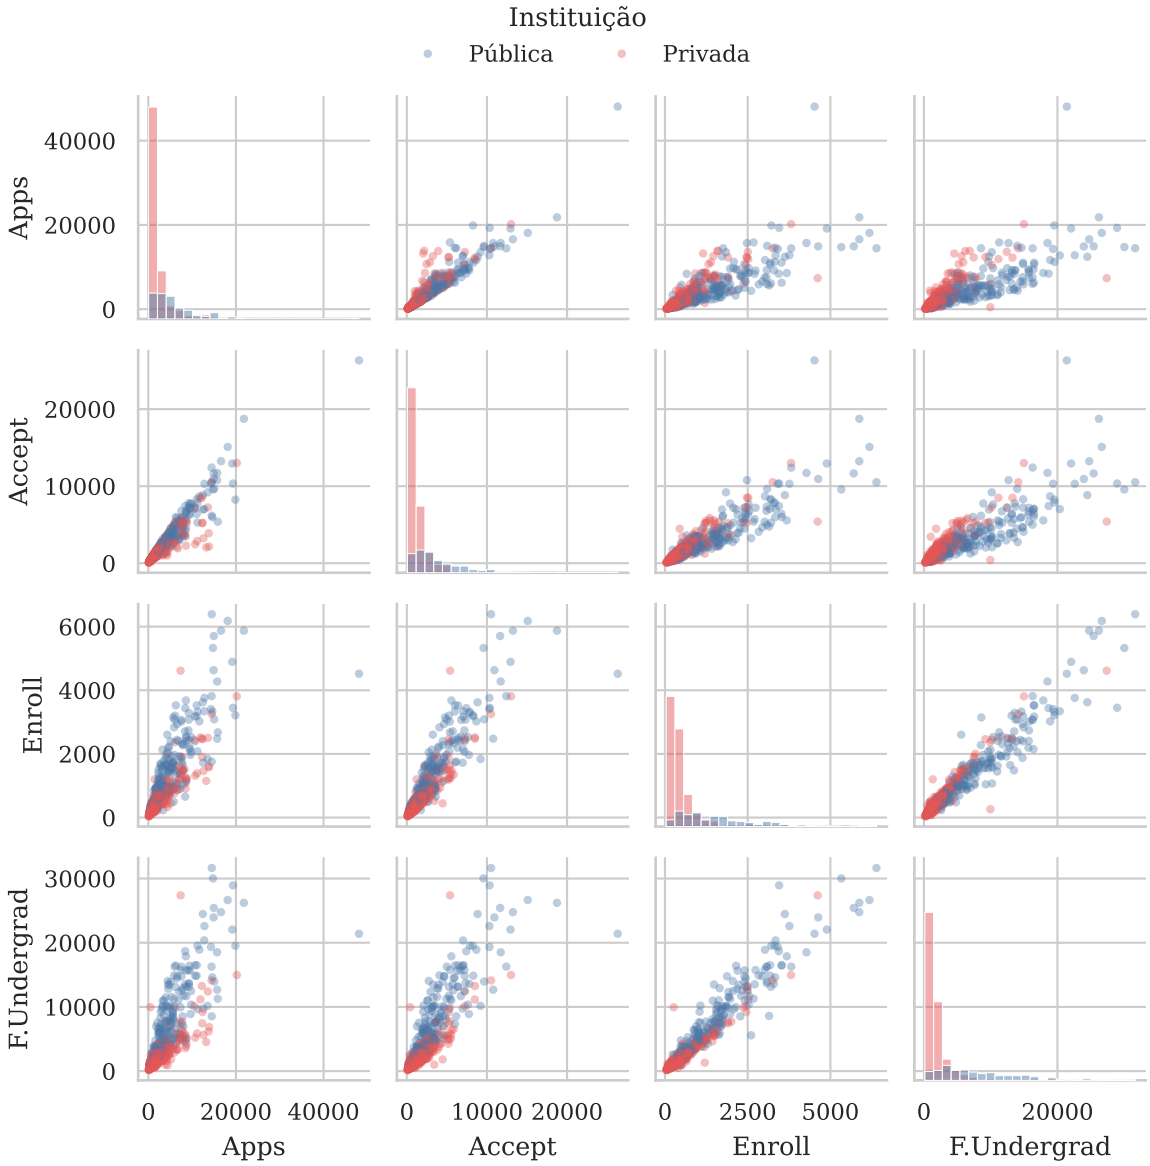


Figura 4. Matriz de dispersão de medidas de demanda e porte, por natureza da instituição.

Esses gráficos constituem apenas uma triagem; a avaliação formal permanece reservada à seção de correlação e multicolinearidade.

5 Modelo inicial

O modelo inicial inclui os 16 preditores numéricos e a variável categórica `Private`. Para sua incorporação, foi definida `Private_Yes = 1` para instituições privadas e 0 para públicas, tornando as instituições públicas a categoria de referência. O ajuste foi realizado por mínimos quadrados ordinários com as 777 observações, sem seleção ou remoção de variáveis.

5.1 Formulação do modelo

Seja x_{ij} o valor do j-ésimo preditor numérico para a instituição i. A forma geral do modelo completo é:

$$\text{Apps}_i = \beta_0 + \beta_1 \text{Private_Yes}_i + \sum_{j=2}^{17} \beta_j x_{ij} + \varepsilon_i.$$

Nessa expressão, cada β_j representa uma associação parcial com `Apps`, mantidos os demais preditores constantes, e ε_i reúne a variação não explicada pelo modelo.

5.2 Coeficientes e ajuste global

As estimativas dos coeficientes, erros-padrão, estatísticas de teste e intervalos de confiança são apresentadas na Tabela 7.

Tabela 7: Estimativas do modelo linear inicial com todos os preditores.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-445,084	408,329	-1,090	0,276	-1.246,672	356,503
Accept	1,586	0,041	38,924	< 0,001	1,506	1,666
Enroll	-0,881	0,186	-4,736	< 0,001	-1,246	-0,516
Top10perc	49,926	5,578	8,950	< 0,001	38,976	60,877
Top25perc	-14,234	4,479	-3,178	0,002	-23,027	-5,441
F.Undergrad	0,057	0,033	1,754	0,080	-0,007	0,122
P.Undergrad	0,044	0,032	1,383	0,167	-0,019	0,108
Outstate	-0,086	0,019	-4,506	< 0,001	-0,123	-0,048
Room.Board	0,151	0,048	3,127	0,002	0,056	0,246
Books	0,021	0,238	0,088	0,930	-0,447	0,489
Personal	0,031	0,063	0,493	0,622	-0,093	0,155
PhD	-8,678	4,638	-1,871	0,062	-17,784	0,427
Terminal	-3,331	5,095	-0,654	0,513	-13,333	6,671
S.F.Ratio	15,390	13,006	1,183	0,237	-10,143	40,922
perc.alumni	0,179	4,102	0,044	0,965	-7,875	8,232
Expend	0,078	0,012	6,308	< 0,001	0,054	0,102
Grad.Rate	8,668	2,949	2,939	0,003	2,879	14,457
Privada (Yes versus No)	-494,149	137,812	-3,586	< 0,001	-764,687	-223,611

O R^2 ajustado de 0,9276 indica que o conjunto de preditores descreve 92,76% da variação amostral de `Apps`; o teste global confirma que o modelo possui contribuição explicativa ($F = 585{,}86$; $p < 0{,}001$). Ao nível de 5%, `Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `Expend`, `Grad.Rate` e `Private_Yes` apresentam coeficientes significativos.

Mantidos os demais preditores constantes, o coeficiente de `Private_Yes` associa instituições privadas a cerca de 494 candidaturas a menos que instituições públicas. Essa interpretação é preliminar: a proximidade entre variáveis de admissão e porte pode afetar sinais e erros-padrão, razão pela qual nenhum preditor é removido nesta etapa.

6 Correlação e multicolinearidade

Embora o modelo inicial apresente elevado poder explicativo, coeficientes individuais podem tornar-se instáveis quando existem preditores fortemente correlacionados entre si. Assim, antes da seleção do modelo final, investigou-se a presença de multicolinearidade por meio da matriz de correlação entre os preditores e do Fator de Inflação da Variância (VIF).

Inicialmente foi construída a matriz de correlação de Pearson para as variáveis numéricas. Em seguida, calculou-se o VIF para cada variável do modelo inicial, adotando como referência o valor 10 como indicativo de multicolinearidade severa.

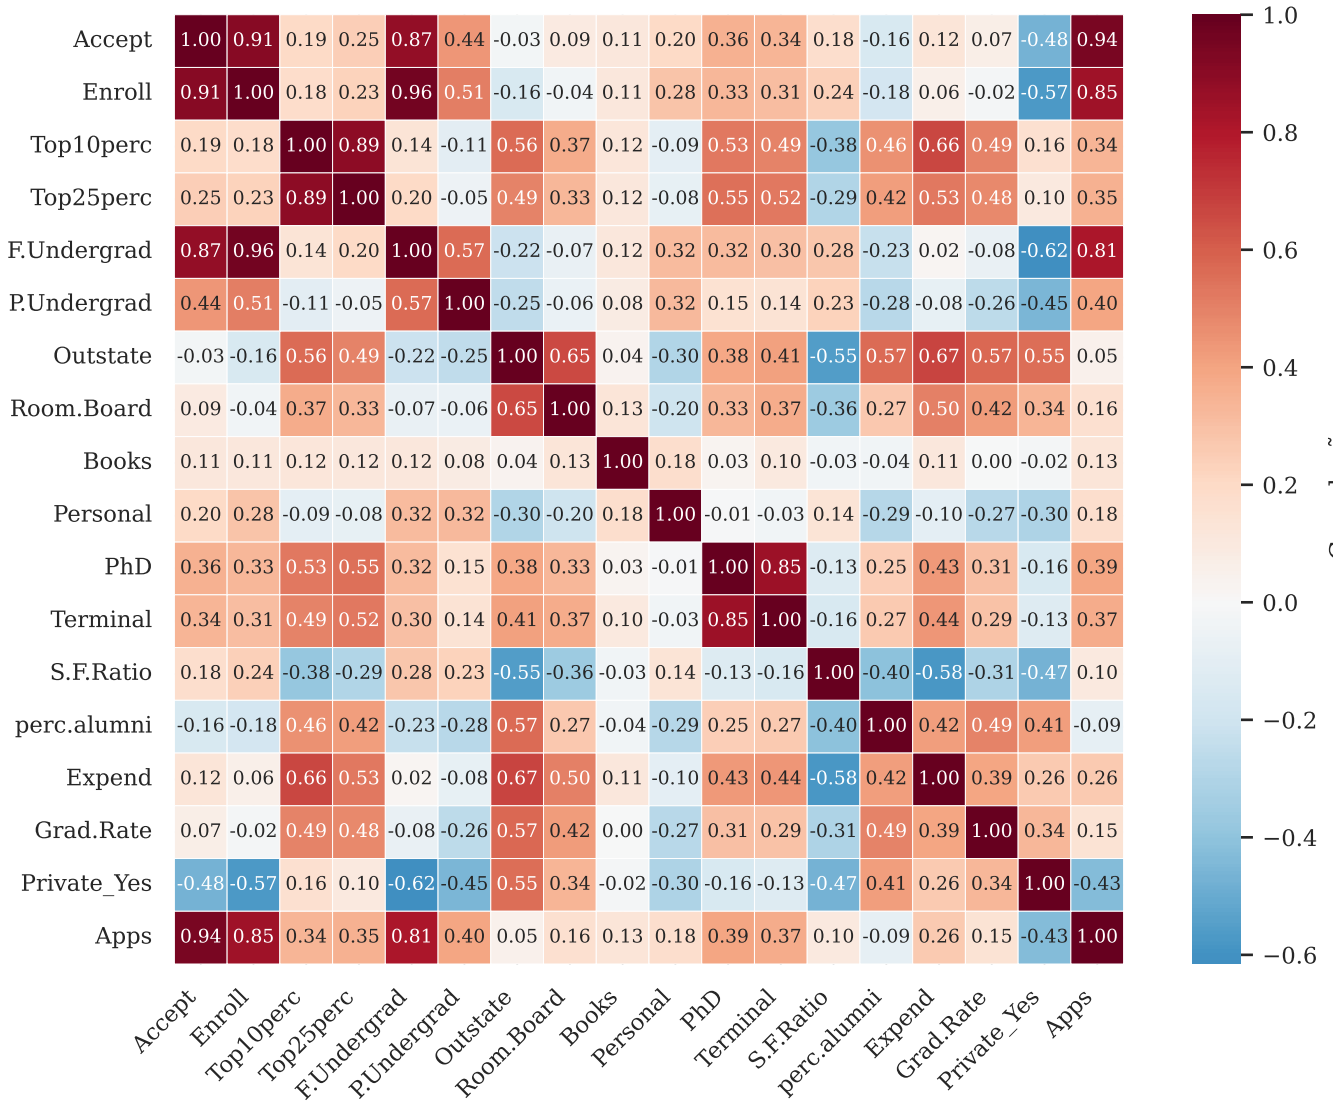


Figura 5. Matriz de correlação de Pearson entre as variáveis numéricas.

Observam-se correlações elevadas entre variáveis de admissão, porte institucional e perfil acadêmico, com destaque para Accept–Enroll ($r = 0,91$), Enroll–F.Undergrad ($r = 0,96$), Accept–F.Undergrad ($r = 0,87$), Top10perc–Top25perc ($r = 0,89$) e PhD–Terminal ($r = 0,85$). A forte correlação entre Apps e Accept ($r = 0,94$) é esperada, pois instituições que recebem mais candidaturas tendem a aceitar mais estudantes. Esses padrões motivam a avaliação formal da multicolinearidade por meio do VIF.

Fator de Inflação da Variância (VIF)

Complementando a matriz de correlação, calculou-se o VIF de cada preditor do modelo inicial, adotando-se VIF > 5 como indício de multicolinearidade moderada e VIF > 10 como evidência de multicolinearidade severa.

Tabela 8: Fator de Inflação da Variância (VIF) para os preditores do modelo inicial.

Variável	VIF
Enroll	21,37
F.Undergrad	18,02
Accept	7,14
Top10perc	6,93
Top25perc	5,63
Outstate	4,21
PhD	4,10
Terminal	4,03
Expend	2,98
Private_Yes	2,70
Room.Board	2,01
S.F.Ratio	1,90
perc.alumni	1,85
Grad.Rate	1,84
P.Undergrad	1,71
Personal	1,31
Books	1,11

A Tabela 8 confirma multicolinearidade severa em `Enroll` (VIF = 21,37) e `F.Undergrad` (VIF = 18,02), coerente com a forte correlação entre essas variáveis e com `Accept` observada na Figura 5. `Accept`, `Top10perc` e `Top25perc` apresentam VIFs moderados (entre 5 e 7); os demais preditores ficam abaixo de 5. A principal fonte de colinearidade está, portanto, associada às variáveis de porte institucional e de admissão, o que orienta a seleção do modelo final a considerar, além de AIC e BIC, também a redução da multicolinearidade.

7 Seleção do modelo final

7.1 Seleção dos modelos

O modelo inicial, apesar do elevado poder explicativo, reúne um número grande de preditores e apresenta multicolinearidade elevada. Buscou-se, assim, uma especificação mais parcimoniosa por meio de critérios de seleção — AIC, BIC, R^2_{aj} e eliminação retroativa (backward) —, com desempenho preditivo avaliado posteriormente por validação cruzada K-Fold.

Tabela 9: Comparação dos modelos obtidos pelos diferentes critérios de seleção.

Modelo	Variáveis	AIC	BIC	R^2	R^2_{ajustado}
Completo	17	13.020,429	13.104,227	0,929	0,928
Backward	11	13.012,670	13.068,536	0,929	0,928
AIC	12	13.012,557	13.073,077	0,929	0,928
BIC	10	13.016,008	13.067,218	0,928	0,927

A Tabela 9 mostra que o modelo Completo (17 preditores) tem o maior AIC ($13.020,429$); Backward (11 preditores) e Stepwise (AIC) (12 preditores) obtêm os menores AIC, em torno de $13.012,6$; e o Stepwise (BIC) (10 preditores) tem o menor BIC ($13.067,218$) e $R^2_{\text{ajustado}} = 0,927$ — apenas $0,1$ p.p. abaixo do modelo Completo ($0,928$) —, com a vantagem de eliminar `F.Undergrad`, principal fonte de multicolinearidade severa (VIF $= 18,02$).

7.2 Modelo final selecionado

Para decidir entre as especificações, a multicolinearidade de cada uma foi reavaliada por meio do maior VIF (Tabela 10).

Tabela 10: Maior valor do Fator de Inflação da Variância (VIF) em cada modelo avaliado.

Modelo	Maior VIF
Backward	21,05
Stepwise (AIC)	21,15
Stepwise (BIC)	7,58

Backward e Stepwise (AIC) mantêm simultaneamente `Enroll` e `F.Undergrad`, preservando VIFs de cerca de 21 e 17; no Stepwise (BIC), a exclusão de `F.Undergrad` reduz o maior VIF (`Enroll`) para aproximadamente **7,6**, abaixo do limite de referência igual a 10. O modelo **Stepwise (BIC)** — com 10 preditores (`Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `PhD`, `Expend`, `Grad.Rate` e `Private_Yes`) — foi por isso escolhido como modelo final, pelo melhor equilíbrio entre qualidade do ajuste, parcimônia e estabilidade dos coeficientes.

A escolha apoia-se em três fatores: (i) é o mais parcimonioso, com perda desprezível de R^2_{ajustado} (**0,927** contra **0,928** nos demais); (ii) é o único que elimina a multicolinearidade severa, com todos os VIFs abaixo de 10; e (iii) apesar do AIC levemente superior ao de Backward e Stepwise (AIC) (diferença inferior a quatro unidades), apresenta o menor BIC entre as quatro especificações — critério que penaliza mais fortemente o excesso de parâmetros e favorece modelos mais simples sem comprometer o ajuste.

Os demais modelos não foram selecionados pelos seguintes motivos: o **Completo** mantém as 17 variáveis originais, incluindo preditores sem significância estatística (`Books`, `Personal`, `Terminal`, `perc.alumni`, `F.Undergrad` e `P.Undergrad`) e a colinearidade severa entre `Enroll` e `F.Undergrad`; o **Backward** remove os preditores não significativos, mas preserva `F.Undergrad`; e o **Stepwise (AIC)**, apesar do menor AIC entre os quatro, mantém `F.Undergrad` e `P.Undergrad`, sem eliminar a principal fonte de instabilidade dos coeficientes.

Vale registrar uma limitação comum às quatro especificações: `Accept` e `Enroll` são etapas posteriores ao recebimento das candidaturas, não características institucionais prévias, o que restringe uma leitura estritamente causal do modelo — mas, por ser comum a todas as especificações, não influenciou a seleção entre elas.

Assim, o modelo **Stepwise (BIC)** é adotado como modelo final e utilizado nas próximas etapas da análise: validação cruzada, interpretação dos coeficientes, diagnóstico dos pressupostos e previsões.

8 Validação cruzada K-Fold

Para avaliar a capacidade preditiva do modelo final fora da amostra de ajuste, realizou-se validação cruzada K-Fold com $K = 10$ partições. Em cada iteração, o modelo foi reajustado com nove partições e avaliado na restante, calculando-se RMSE, MAE e R^2 na partição de teste.

Tabela 11: Métricas de validação cruzada K-Fold (K = 10) para o modelo final.

Partição	RMSE	MAE	R^2
1	1.086,600	755,613	0,893
2	1.273,076	729,900	0,895
3	1.531,861	745,749	0,830
4	900,713	564,193	0,936
5	1.641,291	703,870	0,931
6	722,485	511,692	0,948
7	749,837	495,484	0,898
8	711,020	499,995	0,938
9	1.016,393	636,830	0,921
10	1.231,426	653,658	0,916
Média	1.086,470	629,698	0,911
Desvio-padrão	331,364	104,638	0,034

O desempenho médio nas partições de teste (Tabela 11) é próximo do obtido dentro da amostra de ajuste ($R^2_{\text{ajustado}} = 0,927$; RMSE $\approx 1.042,99$), indicando boa capacidade de generalização e ausência de sobreajuste severo. A maior variabilidade ocorre na partição 5 (maior RMSE), que contém no conjunto de teste a observação 484 — a instituição com o maior número de candidaturas da base, já identificada na Tabela 5 —, e na partição 3 (menor R^2), refletindo a sensibilidade do modelo a observações extremas, retomada na seção de diagnóstico.

9 Interpretação dos coeficientes

A Tabela 12 apresenta as estimativas dos coeficientes do modelo final (Stepwise BIC), com os respectivos erros-padrão, estatísticas de teste e intervalos de confiança de 95%.

Tabela 12: Estimativas do modelo final (Stepwise BIC).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	-100,517	265,476	-0,379	0,705	-621,663	420,630
Accept	1,584	0,040	39,500	< 0,001	1,505	1,663
Top10perc	49,139	5,516	8,908	< 0,001	38,310	59,968
Expend	0,073	0,011	6,370	< 0,001	0,050	0,095
Outstate	-0,095	0,018	-5,176	< 0,001	-0,131	-0,059
Enroll	-0,562	0,111	-5,069	< 0,001	-0,780	-0,344
Room.Board	0,164	0,047	3,508	< 0,001	0,072	0,255
Top25perc	-13,865	4,418	-3,139	0,002	-22,537	-5,193
Privada (Yes versus No)	-575,071	132,528	-4,339	< 0,001	-835,232	-314,909
PhD	-10,016	3,119	-3,211	0,001	-16,139	-3,893
Grad.Rate	7,333	2,821	2,599	0,010	1,795	12,871

Todos os dez preditores são significativos a 5%, resultado esperado do critério BIC. O R^2_{ajustado} de 0,927 mantém praticamente a capacidade explicativa do modelo completo, com sete preditores a menos.

`Accept` tem o maior efeito prático: cada candidatura aceita a mais associa-se, em média, a +1,58 candidatura recebida (mantidos os demais preditores constantes), refletindo a forte relação `Apps`–`Accept` já vista na correlação ($r = 0,94$). `Top10perc` também tem efeito expressivo (+49 candidaturas por ponto percentual), consistente com maior seletividade atraindo mais candidatos. `Room.Board`, `Expend` e `Grad.Rate` têm coeficientes positivos, associando maior investimento institucional e taxa de graduação a maior atratividade.

`Outstate` é negativo — mensalidades mais altas associam-se a menos candidaturas, efeito de custo esperado. `Private_Yes` confirma o resultado do modelo inicial: instituições privadas recebem, em média, cerca de 575 candidaturas a menos que as públicas com as demais características equivalentes, coerente com a diferença de porte já discutida na Tabela 6.

`Enroll`, `Top25perc` e `PhD` têm coeficiente parcial negativo apesar de correlação bivariada positiva com `Apps` (Figura 5). Isso decorre da forte correlação com `Accept`, `Top10perc` e `Terminal`, respectivamente: como essas variáveis já capturam grande parte da seletividade e da demanda, os coeficientes remanescentes representam apenas o efeito marginal residual, e não devem ser lidos como relações de causa e efeito isoladas.

10 Diagnóstico do modelo

Esta seção avalia a adequação do modelo final aos pressupostos clássicos da regressão linear: linearidade, homocedasticidade (variância constante dos erros) e independência dos resíduos. A normalidade dos resíduos é tratada separadamente na próxima seção.

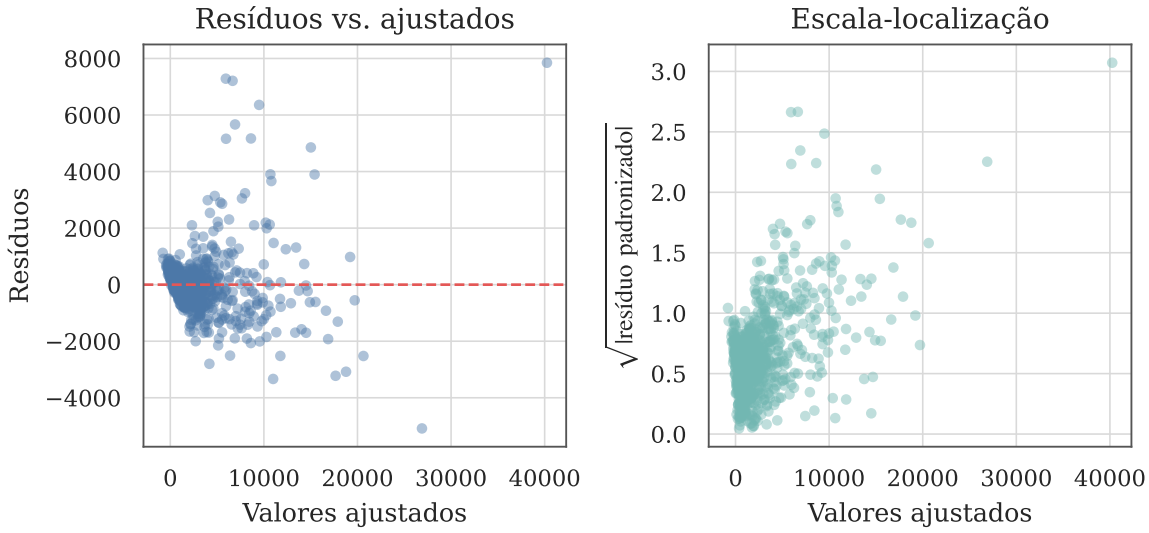


Figura 6. Resíduos versus valores ajustados e gráfico de escala-localização do modelo final.

Tabela 13: Teste de Breusch-Pagan para heterocedasticidade.

Estatística LM	p-valor (LM)	Estatística F	p-valor (F)
235,426	< 0,001	33,299	< 0,001

A Figura 6 evidencia um padrão de leque: a dispersão dos resíduos cresce com o valor ajustado de `Apps`, indicando variância não constante — confirmado pelo teste de Breusch-Pagan (Tabela 13), que rejeita a homocedasticidade a qualquer nível usual de significância. O resultado é esperado dada a forte assimetria de `Apps` (assimetria amostral de 3,72; Figura 1): instituições com mais candidaturas tendem a apresentar também maior variabilidade absoluta. A heterocedasticidade não viesa as estimativas pontuais dos coeficientes, mas reduz a eficiência dos erros-padrão clássicos, o que deve ser considerado na leitura dos intervalos construídos na seção de previsões.

11 QQ Plot e normalidade dos resíduos

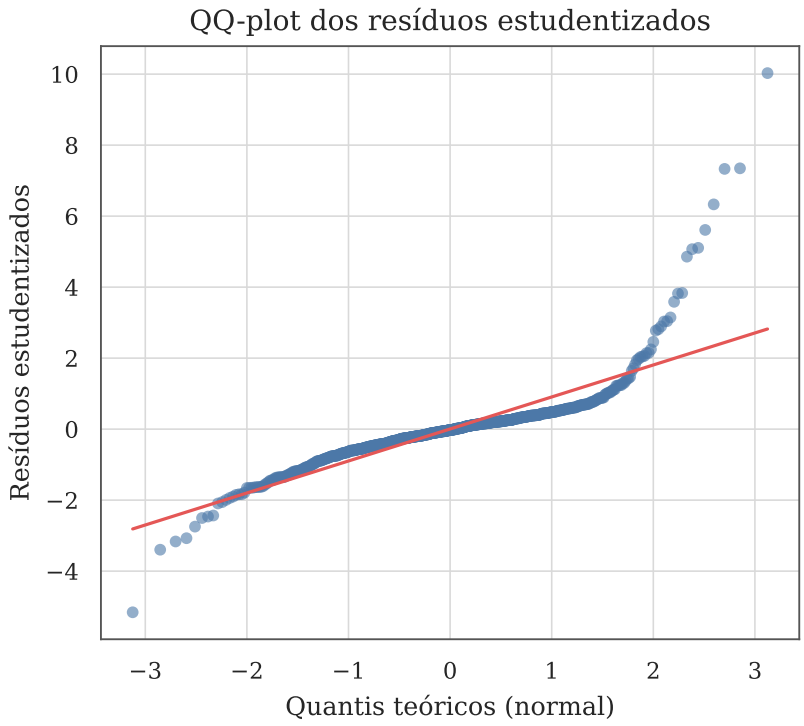


Figura 7. QQ-plot dos resíduos estudentizados do modelo final.

O QQ-plot mostra afastamento sistemático da reta normal nas duas caudas, sobretudo na superior, onde os resíduos assumem valores muito mais extremos que o esperado sob normalidade — reflexo de instituições com candidaturas atipicamente elevadas, como a observação 484.

Para complementar a avaliação visual, construiu-se um envelope simulado: a partir do modelo ajustado, geraram-se 100 réplicas da resposta sob a hipótese de erros normais com a mesma matriz de preditores, obtendo-se, para cada posição ordenada dos resíduos, uma banda de referência entre os percentis 2,5% e 97,5% das réplicas.

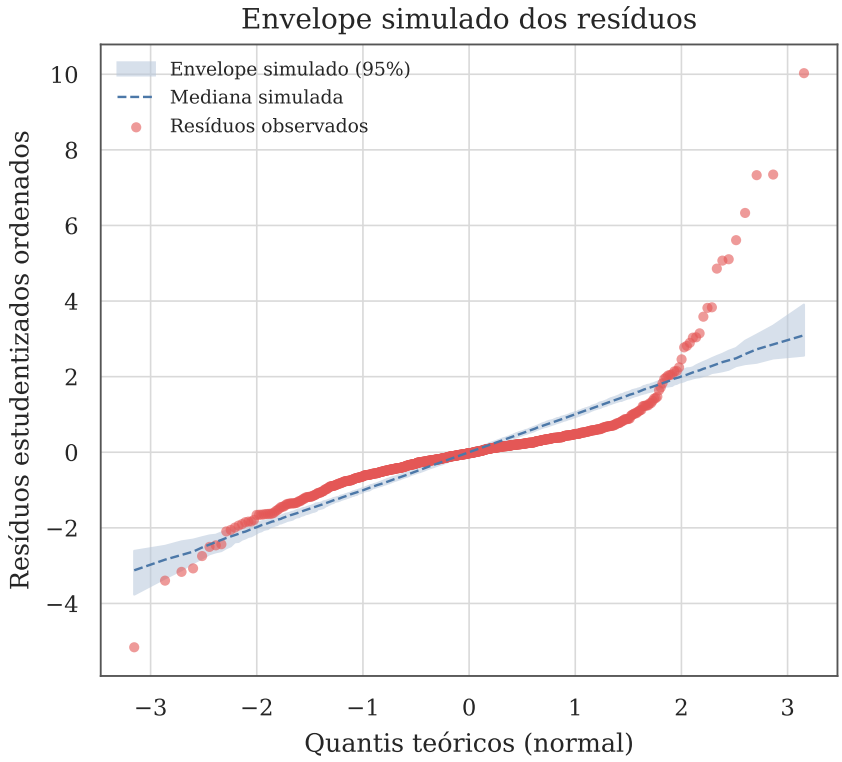


Figura 8. Gráfico de envelope simulado dos resíduos estudentizados do modelo final.

Tabela 14: Estatísticas de normalidade dos resíduos do modelo final.

Estatística de Shapiro-Wilk	p-valor	Assimetria dos resíduos	Curtose dos resíduos	% fora do envelope
0,777	< 0,001	2,36	15,98	90,3

A Tabela 14 resume a avaliação formal: o teste de Shapiro-Wilk rejeita a normalidade dos resíduos ($p < 0,001$), e a assimetria e a curtose confirmam uma distribuição fortemente assimétrica à direita e de caudas pesadas. O envelope simulado (Figura 8) corrobora essa conclusão visualmente: a maior parte dos resíduos observados fica fora da banda de 95%, mais concentrados próximo de zero e com caudas muito além do esperado sob normalidade — padrão típico de distribuições leptocúrticas.

Os resultados desta seção e da anterior indicam que homocedasticidade e normalidade não são plenamente satisfeitas, sobretudo pela forte assimetria de `Apps` e por um pequeno número de observações extremas, investigadas na próxima seção. Como o objetivo é diagnosticar — não reajustar — o modelo já selecionado, o Stepwise (BIC) é mantido como final, registrando-se essa violação como limitação a considerar na leitura de testes e intervalos.

12 Pontos atípicos, de alavanca e influentes

Esta seção identifica observações atípicas (*outliers*), de alavanca (*leverage*) e influentes no modelo final, utilizando três medidas complementares: resíduos estudentizados (externamente), alavancagem (h_{ii}, diagonal da matriz de projeção) e distância de Cook. Como

referência, foram adotados os limites usuais |resíduo estudentizado| > 3 para pontos atípicos, $h_{ii} > 2p/n$ para pontos de alavanca e $D_i > 4/n$ para pontos influentes, em que p é o número de parâmetros do modelo (incluindo o intercepto) e n o número de observações.

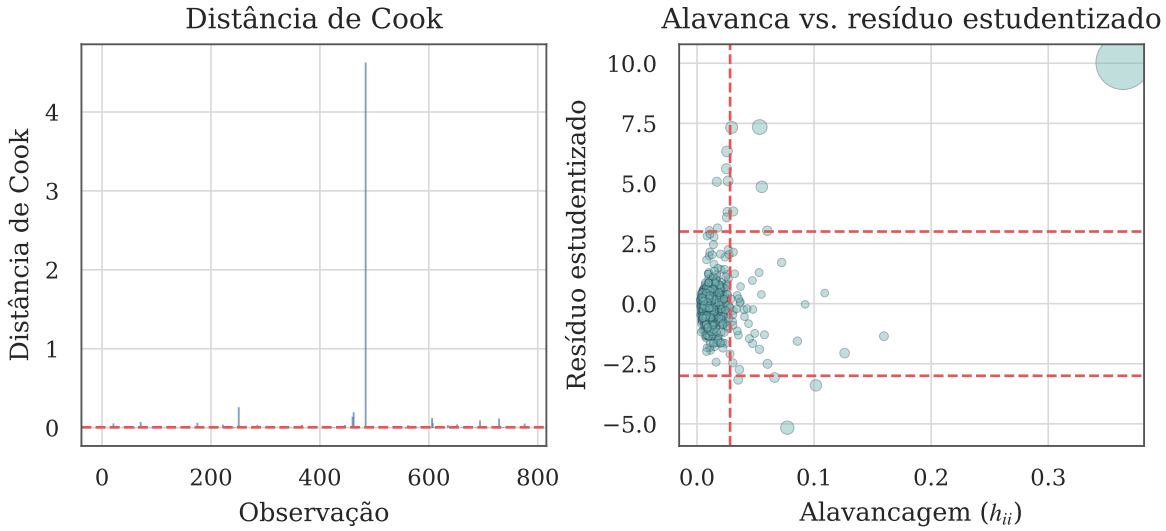


Figura 9. Distância de Cook e gráfico de influência (alavanca versus resíduo estudentizado) do modelo final.

Tabela 15: Observações que excedem simultaneamente os três critérios de alavanca, atipicidade e influência.

Observação	Instituição	Apps	Alavancagem	Resíduo estudentizado	Distância de Cook
484	Pública	48094	0,364	10,029	4,627
251	Privada	13865	0,054	7,347	0,260
462	Pública	21804	0,077	-5,160	0,196
460	Privada	13218	0,030	7,330	0,140
606	Pública	19873	0,055	4,858	0,122
729	Privada	7654	0,102	-3,397	0,117
607	Pública	15698	0,066	-3,073	0,060
776	Privada	10705	0,060	3,032	0,053
652	Pública	14596	0,031	3,834	0,042
635	Pública	14438	0,035	-3,165	0,033

Com os limites de referência adotados, 48 observações excedem o limite de alavancagem, 46 o de Cook e 18 são atípicas pelo resíduo estudentizado — números altos, mas esperados ao aplicar limites clássicos a uma amostra grande e assimétrica; nem todas representam, necessariamente, problemas isolados de ajuste.

Uma leitura mais seletiva, que exige os três critérios simultaneamente (Tabela 15), reduz a lista a 10 instituições (cerca de 1,3% da amostra). A observação 484 — a mesma instituição pública com 48.094 candidaturas já identificada na Tabela 5 — destaca-se amplamente em todos os critérios, sendo o ponto isolado de maior impacto potencial sobre as estimativas do modelo final.

Como o objetivo é diagnosticar, não reajustar, o modelo já selecionado, nenhuma observação foi removida ou tratada de forma diferenciada. O registro tem caráter diagnóstico:

uma pequena parcela da amostra — sobretudo instituições públicas de grande porte — tem peso desproporcional sobre o ajuste, o que é coerente com a heterocedasticidade e a não normalidade já identificadas.

13 Previsões

Esta seção ilustra o uso prático do modelo final por meio de dois perfis institucionais plausíveis, construídos a partir das medianas dos dez preditores do modelo, separadas por natureza da instituição. Para cada perfil, apresentam-se a previsão pontual, o intervalo de confiança de 95% para $E(Y \mid \mathbf{X} = \mathbf{x}_0)$ e o intervalo de predição de 95% para uma nova observação individual.

Tabela 16: Perfis institucionais utilizados nas previsões, com base nas medianas por natureza da instituição.

Perfil	Accept	Top10perc	Expend	Outstate	Enroll	Room.Board	Top25perc	Private_Yes	PhD	Grad.Rate
Pública (mediana)	2.929,5	19,0	6.716,5	6.609,0	1.337,5	3.708,0	51,0	0,0	78,5	55,0
Privada (mediana)	859,0	25,0	8.954,0	11.200,0	328,0	4.400,0	55,0	1,0	73,0	69,0

Tabela 17: Previsão pontual, intervalo de confiança para a média e intervalo de predição (95%) para os dois perfis institucionais.

Perfil	Previsão pontual	IC 95% (inferior)	IC 95% (superior)	IP 95% (inferior)	IP 95% (superior)
Pública (mediana)	4.102,1	3.953,6	4.250,6	2.049,3	6.154,9
Privada (mediana)	1.053,0	957,1	1.148,9	-996,7	3.102,7

A Tabela 17 apresenta a previsão pontual e os intervalos de 95% para os dois perfis. Como esperado, o intervalo de predição é bem mais largo que o de confiança em ambos os casos, pois soma a incerteza sobre a média à variabilidade individual em torno dela. No perfil privado, o limite inferior do intervalo de predição é negativo — sem significado prático, já que `Apps` não pode ser negativo —, consequência esperada de ajustar um modelo linear não transformado a uma resposta assimétrica e heterocedástica (seções de diagnóstico); na prática, esse limite equivale a zero candidaturas, e o intervalo deve ser lido com cautela adicional.

Ainda assim, os dois perfis reproduzem o padrão já descrito na Tabela 6: instituições públicas recebem, em mediana, número de candidaturas várias vezes maior que privadas, mesmo após o controle simultâneo por seletividade, custo, perfil acadêmico e investimento institucional.

14 Conclusão

Este trabalho aplicou a Regressão Linear Múltipla para modelar o número de candidaturas (`Apps`) recebidas por instituições de ensino superior dos Estados Unidos, com base na base `College`. A análise exploratória revelou forte assimetria à direita na variável resposta e diferenças marcantes entre instituições públicas e privadas em porte, custo e investimento.

O modelo inicial, com 16 preditores numéricos e `Private`, teve elevado poder explicativo ($R^2_{\text{ajustado}} = 0,928$), mas evidenciou multicolinearidade severa entre `Enroll` e `F.Undergrad`. Entre as quatro especificações comparadas, apenas o Stepwise (BIC) elimina essa multicolinearidade, com perda desprezível de ajuste ($R^2_{\text{ajustado}} = 0,927$), sendo adotado como modelo final com dez preditores: `Accept`, `Enroll`, `Top10perc`, `Top25perc`, `Outstate`, `Room.Board`, `PhD`, `Expend`, `Grad.Rate` e `Private_Yes`. A validação cruzada confirmou boa generalização (R^2 médio de 0,911), e a interpretação dos coeficientes apontou `Accept`, `Top10perc` e a condição de instituição privada como os fatores de maior efeito prático, além de ilustrar como a correlação entre preditores pode inverter o sinal de coeficientes parciais (`Enroll`, `Top25perc`, `PhD`).

O diagnóstico revelou violação de homocedasticidade (Breusch-Pagan) e de normalidade dos resíduos (Shapiro-Wilk e envelope simulado), associada a um pequeno grupo de observações influentes — sobretudo a observação 484 —, que concentra alta alavancagem, resíduo atípico e distância de Cook elevada. Ainda assim, as previsões para perfis públicos e privados típicos reproduziram, de forma quantitativa, a diferença de demanda já sugerida na análise exploratória, evidenciando a utilidade prática do modelo apesar das limitações diagnosticadas.

Em síntese, o número de candidaturas está fortemente associado ao processo de admissão, à seletividade acadêmica, ao custo, ao investimento institucional e à natureza pública ou privada da instituição. O modelo final oferece uma descrição parcimoniosa e razoavelmente estável dessas associações; suas limitações de heterocedasticidade e normalidade, decorrentes da forte assimetria de `Apps` e de observações extremas, sugerem que extensões futuras — como modelagem em escala logarítmica ou erros-padrão robustos — poderiam aprimorar a precisão inferencial sem alterar as conclusões substantivas aqui obtidas.

Referências

[1] Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.

[2] James G, Witten D, Hastie T, Tibshirani R. 2021 *An Introduction to Statistical Learning: with Applications in R*. New York: Springer 2 edition.