

Universidade Federal
de Campina Grande

UNIVERSIDADE FEDERAL DE CAMPINA GRANDE

Departamento de Ciência da Computação

Isadora Beatriz Lucena de Medeiros

Jennifer Raysa Medeiros Cavalcanti

Oscar Rodrigues da Silva Neto

MODELAGEM DO COMPRIMENTO DA SÉPALA EM FLORES DO GÊNERO IRIS

Relatório apresentado à disciplina de *Estatística Aplicada*, período 2026.1.

Profa. Dra. Amanda Gomes

Prof. Dr. Jerfson Bruno

Prof. Dr. Gilberto Matos

Campina Grande – PB

2026

RESUMO

Este trabalho aplica a metodologia de regressão linear múltipla ao clássico conjunto de dados `iris`, coletado por Anderson e popularizado por Fisher, com o objetivo de modelar o comprimento da sépala a partir das demais variáveis morfológicas e da espécie da flor. Realizamos uma análise exploratória uni e bivariada, incluindo correlações, box-plots e verificação de dados ausentes, e ajustamos um modelo inicial com as variáveis explicativas contínuas disponíveis. Após identificar multicolinearidade severa entre o comprimento e a largura da pétala, comparamos modelos candidatos e selecionamos uma especificação mais parcimoniosa. Os pressupostos foram avaliados por análise de resíduos, gráfico de envelope simulado e identificação de pontos atípicos, de alavanca e influentes. Por fim, examinamos a inclusão da espécie por variáveis dummy e apresentamos intervalos de confiança para o valor médio esperado da resposta e intervalos de predição para novas observações, acompanhados de suas interpretações práticas.

Áreas temáticas: estatística aplicada, modelagem preditiva

Palavras-chave: regressão linear múltipla, multicolinearidade, seleção de modelos, variáveis dummy

Sumário

1 Introdução **3**

2 Metodologia **3**
2.1 Modelo de regressão linear múltipla . . . 3
2.2 Diagnóstico do modelo . . . 3
2.3 Variáveis dummy e categoria de referência . . . 3
2.4 Inferência preditiva . . . 3

3 Resultados **3**
3.1 Descrição da base de dados . . . 3
3.2 Análise exploratória . . . 4
3.2.1 Análise de correlação . . . 5
3.2.2 Multicolinearidade: o VIF . . . 6
3.3 Seleção do modelo final . . . 7
3.3.1 Seleção automática (eliminação retroativa por AIC) . . . 7
3.4 Diagnóstico do modelo selecionado . . . 7
3.4.1 Identificação de pontos atípicos, de alavanca e influentes . . . 9
3.4.2 Impacto da remoção dos pontos influentes . . . 10
3.5 Interpretações do modelo selecionado . . . 10
3.5.1 Coeficientes padronizados . . . 10
3.6 Regressão com variáveis dummy (a espécie como explicativa) . . . 10
3.6.1 Modelo sem Petal.Length, com a espécie . . . 11
3.6.2 Alterando a categoria de referência . . . 11
3.7 Comparação geral dos modelos . . . 11

4 Previsões **12**
4.1 Intervalo de confiança para o valor médio esperado . . . 12
4.2 Intervalo de predição para uma nova observação . . . 12

5 Conclusão **12**

Referências **14**

6 Orientações do trabalho **14**

1 Introdução

A relação entre as dimensões florais e a espécie constitui um dos exemplos mais estudados de discriminação morfológica em Botânica, desde os trabalhos pioneiros de Anderson [1] e Fisher [2] com flores do gênero *Iris*. O conjunto de dados resultante reúne 150 observações de três espécies (*setosa*, *versicolor* e *virginica*) e quatro medidas morfológicas: comprimento e largura da sépala, além de comprimento e largura da pétala.

Embora a literatura sobre esse conjunto de dados enfatize sobretudo problemas de classificação, ele também permite ilustrar um problema de regressão: a previsão de uma dimensão floral a partir das demais características morfológicas. Neste relatório, o comprimento da sépala (`Sepal.Length`) é tratado como variável resposta. A forte associação entre algumas medidas explicativas reproduz um desafio frequente em estudos aplicados e torna a base adequada para discutir multicolinearidade, seleção de modelos e inferência preditiva.

Especificamente, descrevemos a base de dados e conduzimos uma análise exploratória uni e bivariada; ajustamos um modelo inicial com as variáveis contínuas disponíveis; selecionamos um modelo mais parcimonioso e sem multicolinearidade relevante; verificamos os pressupostos da regressão linear múltipla; avaliamos pontos atípicos, de alavanca e influentes; examinamos a inclusão da espécie como explicativa; e apresentamos intervalos de confiança e de predição para dois conjuntos hipotéticos de valores das variáveis explicativas.

2 Metodologia

2.1 Modelo de regressão linear múltipla

Seja y_i o comprimento da sépala da i-ésima flor. O modelo inicial inclui como explicativas a largura da sépala (`Sepal.Width`), o comprimento da pétala (`Petal.Length`) e a largura da pétala (`Petal.Width`), sob as suposições usuais da regressão linear múltipla: erros de média nula, variância constante, independência e normalidade [3].

A multicolinearidade foi avaliada pelo fator de inflação da variância (VIF), adotando-se valores superiores a 10 como indício de multicolinearidade severa [3]. A escolha do modelo selecionado considerou os critérios de informação AIC [4] e BIC [5], testes F entre modelos aninhados e a necessidade de preservar uma interpretação estável dos coeficientes.

2.2 Diagnóstico do modelo

A adequação do modelo selecionado foi avaliada por meio dos gráficos de resíduos versus valores ajustados, quantil-quantil, escala-localização e resíduos versus alavancagem, além de um gráfico de envelope simulado [6]. As observações foram classificadas como atípicas quando apresentaram resíduo estudentizado em valor absoluto superior a 2, como pontos de alavanca quando $h_{ii} > 2p/n$ e como influentes quando a distância de Cook excedeu $4/n$ [3,7]. O impacto desses pontos foi examinado pelo reajuste do modelo após sua remoção.

2.3 Variáveis dummy e categoria de referência

Como `Species` possui três níveis, sua inclusão no modelo requer duas variáveis indicadoras, com uma das espécies definida como categoria de referência. Essa parametrização permite comparar as espécies mantendo constantes as demais explicativas. Também verificamos que a troca da categoria de referência modifica a interpretação do intercepto e dos coeficientes das indicadoras, mas não altera os valores ajustados nem a qualidade global do modelo.

2.4 Inferência preditiva

Para valores especificados das variáveis explicativas, distinguimos dois tipos de inferência [3]: o intervalo de confiança para o valor médio esperado da resposta, que estima a média de todas as flores com aquelas características, e o intervalo de predição para uma nova observação individual. O segundo é necessariamente mais amplo, pois incorpora tanto a incerteza sobre a média quanto a variabilidade natural de uma flor em torno dessa média.

3 Resultados

3.1 Descrição da base de dados

Os dados foram obtidos de 150 flores, com 50 observações de cada espécie. A Tabela 1 apresenta as cinco variáveis da base, seus significados e suas unidades de medida.

Tabela 1: Variáveis da base de dados iris.

Variável	Descrição	Unidade
Sepal.Length	Comprimento da sépala	cm
Sepal.Width	Largura da sépala	cm
Petal.Length	Comprimento da pétala	cm
Petal.Width	Largura da pétala	cm
Species	Espécie da flor (setosa, versicolor, virginica)	categórica

A base contém $n = 150$ observações e não apresenta valores ausentes.

3.2 Análise exploratória

A Tabela 2 apresenta a média e o desvio-padrão das quatro variáveis morfológicas, separadamente para cada espécie.

Tabela 2: Média e desvio-padrão (dp) das variáveis morfológicas, por espécie.

Espécie	Comp. Sépala (média)	Comp. Sépala (dp)	Larg. Sépala (média)	Larg. Sépala (dp)	Comp. Pétala (média)	Comp. Pétala (dp)	Larg. Pétala (média)	Larg. Pétala (dp)
setosa	5.01	0.35	3.43	0.38	1.46	0.17	0.25	0.11
versicolor	5.94	0.52	2.77	0.31	4.26	0.47	1.33	0.2
virginica	6.59	0.64	2.97	0.32	5.55	0.55	2.03	0.27

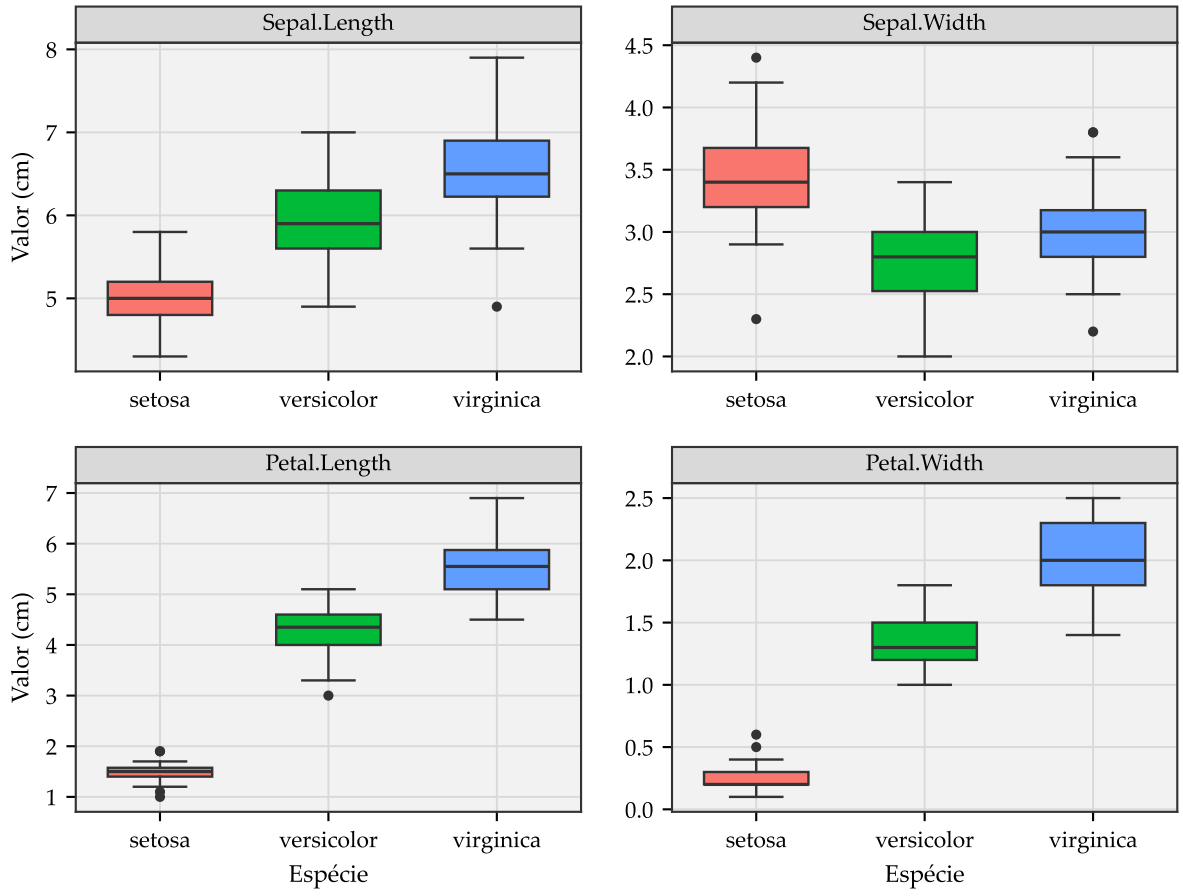


Figura 1. Box-plots das variáveis morfológicas, por espécie.

A Figura 1 evidencia separação quase completa entre as espécies no comprimento e na largura da pétala, enquanto as variáveis da sépala apresentam maior sobreposição. A pétala é, portanto, a região morfológica que melhor distingue visualmente as três espécies.

3.2.1 Análise de correlação

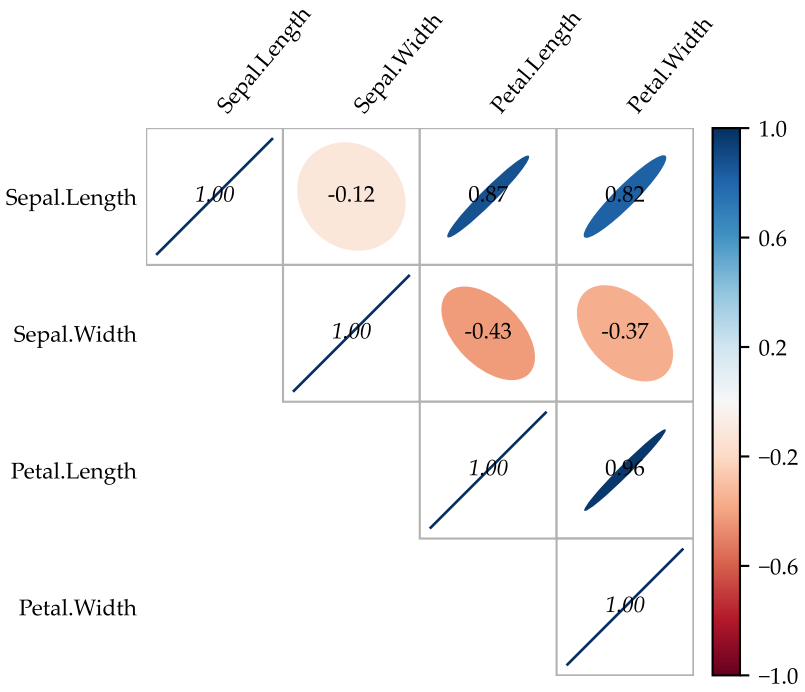


Figura 2. Matriz de correlação de Pearson entre as variáveis morfológicas.

A matriz de correlações da Figura 2 mostra forte associação positiva do comprimento da sépala com o comprimento da pétala ($r \approx 0{,}87$) e com a largura da pétala ($r \approx 0{,}82$). O comprimento e a largura da pétala também são fortemente correlacionados entre si ($r \approx 0{,}96$), constituindo um indício preliminar de multicolinearidade, a ser formalmente verificado pelo VIF. Em contraste, a associação entre comprimento e largura da sépala é fraca e negativa ($r \approx -0{,}12$).

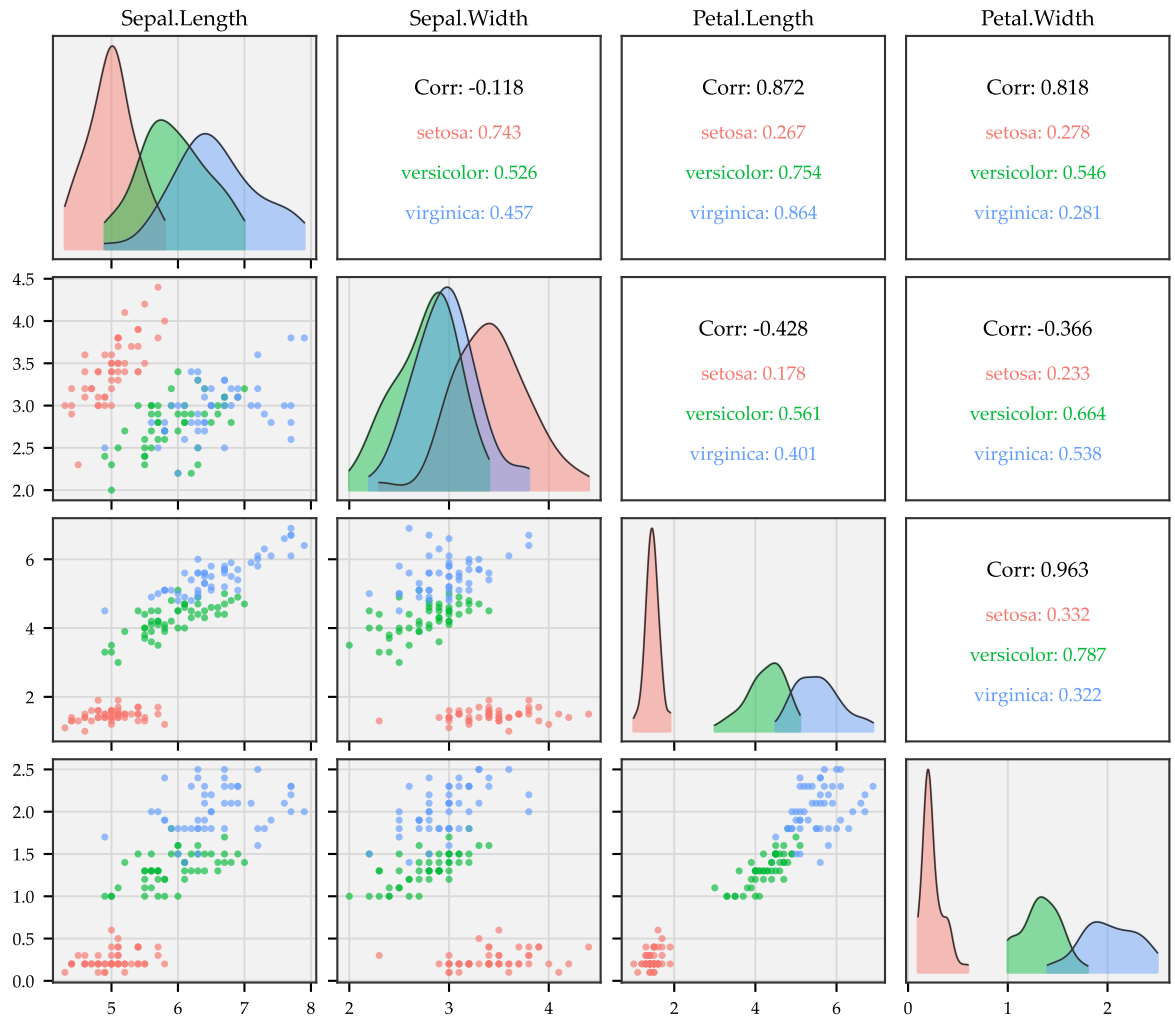


Figura 3. Matriz de dispersão para pares das variáveis morfológicas, por espécie.

A matriz de dispersão da Figura 3 confirma que *setosa* forma um agrupamento bem distinto das demais espécies em praticamente todas as variáveis, enquanto *versicolor* e *virginica* apresentam maior sobreposição, sobretudo nas medidas da sépala. Não foram observados valores incompatíveis com os intervalos plausíveis das variáveis, como medidas negativas ou discrepantes por ordem de grandeza, não havendo indícios de erros de digitação na base.

3.2.2 Multicolinearidade: o VIF

Tabela 3: Estimativas do modelo inicial (sem a espécie).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	1.856	0.2508	7.401	0	1.3604	2.3516
Sepal.Width	0.6508	0.0666	9.7654	0	0.5191	0.7826
Petal.Length	0.7091	0.0567	12.5025	0	0.597	0.8212
Petal.Width	-0.5565	0.1275	-4.3629	0	-0.8086	-0.3044

Tabela 4: Fator de inflação de variância (VIF) de cada variável explicativa no modelo inicial.

	VIF
Sepal.Width	1.27
Petal.Length	15.10
Petal.Width	14.23

O modelo inicial apresenta ajuste elevado (R^2 ajustado $= 0.8557$). Entretanto, os VIF de `Petal.Length` e `Petal.Width`, ambos superiores a 14, confirmam multicolinearidade severa entre essas variáveis. Embora o ajuste global permaneça bom, a redundância de informação infla os erros-padrão e torna instáveis as interpretações individuais. O sinal negativo de `Petal.Width`, apesar de sua correlação positiva com a resposta, é outro indício dessa instabilidade e exige correção antes da validação do modelo.

3.3 Seleção do modelo final

Tabela 5: Comparação dos modelos candidatos: ajuste, AIC e BIC.

Modelo	Rš ajustado	AIC	BIC
modelo1 (completo)	0.86	82.64	94.69
modelo2 (sem Petal.Width)	0.84	99.03	108.06
modelo3 (sem Petal.Length)	0.7	189.82	198.85

A Tabela 5 compara as alternativas de remoção de uma das variáveis da pétala. O modelo2, sem `Petal.Width`, apresenta AIC e BIC substancialmente menores que o modelo3, sem `Petal.Length`, sendo a alternativa preferível entre os dois modelos reduzidos. Esse resultado é coerente com a análise exploratória, pois `Petal.Length` apresenta associação ligeiramente mais forte com `Sepal.Length` e preserva maior capacidade explicativa.

Tabela 6: Teste F comparando o modelo2 ao modelo completo (modelo1).

Modelo	GL Res.	SQ Res.	GL	SQ	Estatística F	p-valor
modelo2	147	16.3288	0			
modelo1	146	14.4454	1	1.8834	19.0352	0

O teste F rejeita a hipótese de que o modelo reduzido sem `Petal.Width` apresenta ajuste idêntico ao modelo completo ($p < 0{,}001$). Assim, a variável possui contribuição estatística quando considerada no modelo completo, embora sua presença simultânea com `Petal.Length` produza a multicolinearidade severa identificada anteriormente. A escolha do modelo reduzido representa, portanto, um compromisso entre pequena perda de ajuste e maior estabilidade interpretativa.

3.3.1 Seleção automática (eliminação retroativa por AIC)

A seleção por eliminação retroativa foi conduzida removendo, em cada etapa, a variável cuja exclusão produziria a maior redução no AIC. O procedimento foi encerrado quando nenhuma remoção adicional melhorou o critério, seguindo a mesma lógica do procedimento *stepwise* empregado no PDF de referência.

O critério puramente preditivo não recomenda a remoção de nenhuma variável, pois o modelo completo já constitui o ótimo local segundo o AIC, apesar da colinearidade. Como o objetivo também inclui a interpretação dos efeitos individuais, adotamos o modelo2 nas etapas seguintes: a retirada de `Petal.Width` reduz a multicolinearidade e mantém a maior parte do poder explicativo do modelo completo.

3.4 Diagnóstico do modelo selecionado

Tabela 7: Estimativas dos coeficientes do modelo2 (modelo selecionado).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	2.2491	0.248	9.0702	0	1.7591	2.7392
Sepal.Width	0.5955	0.0693	8.5899	0	0.4585	0.7325
Petal.Length	0.4719	0.0171	27.5692	0	0.4381	0.5057

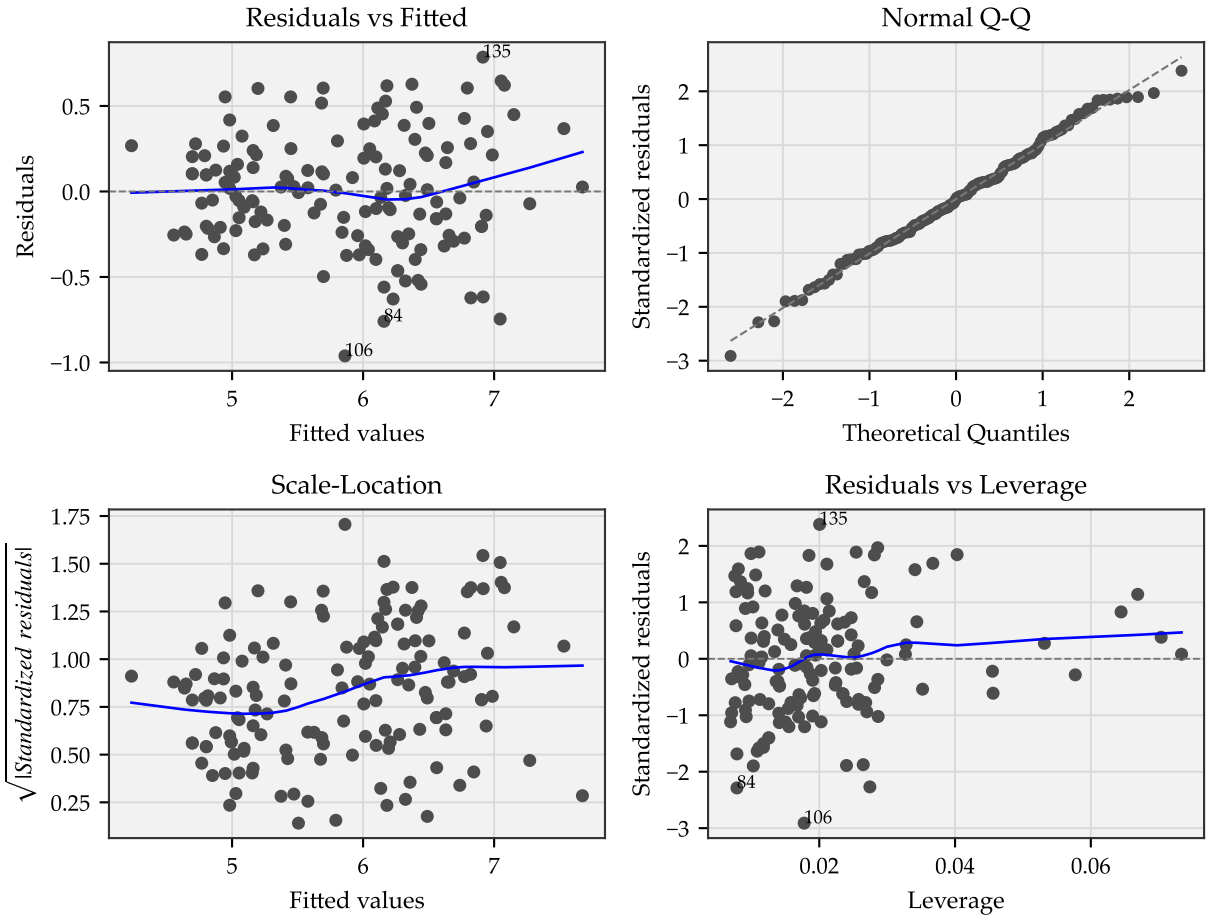


Figura 4. Análise de resíduos do modelo2.

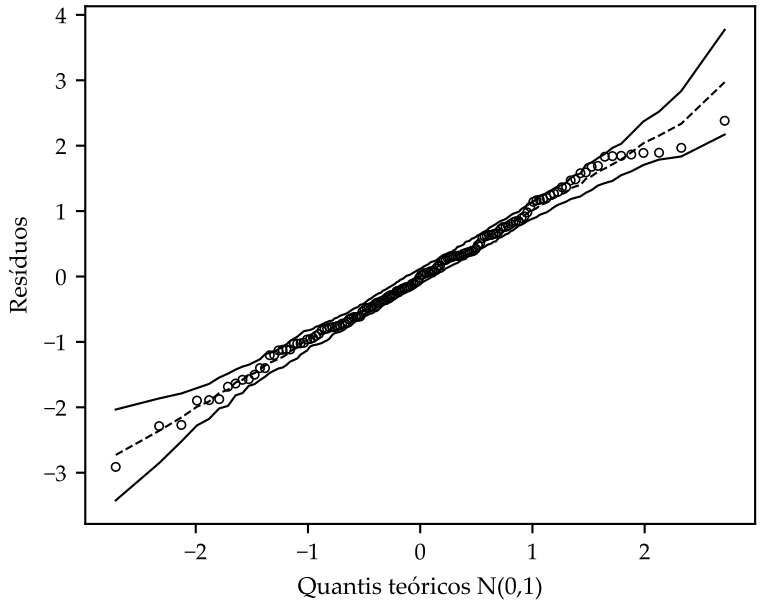


Figura 5. Gráfico de envelope simulado do modelo2.

As Figuras 4 e 5 não indicam padrões sistemáticos relevantes nos resíduos. A dispersão em torno de zero permanece aproximadamente constante, o gráfico quantil-quantil não apresenta desvios graves e a grande maioria dos pontos permanece dentro da banda do envelope simulado. Esses resultados dão suporte às suposições de linearidade, variância constante e normalidade dos erros.

3.4.1 Identificação de pontos atípicos, de alavanca e influentes

Tabela 8: Observações atípicas, de alavanca e/ou influentes segundo o modelo2.

Observação	Espécie	Resíduo estud.	Alavancagem	Dist. de Cook	Atípico	Alavanca	Influente
106	virginica	-2.9112	0.0178	0.0511	Sim	Não	Sim
100	virginica	-2.2694	0.0275	0.0485	Sim	Não	Sim
14	setosa	1.8452	0.0403	0.0477	Não	Sim	Sim
135	virginica	2.381	0.02	0.0387	Sim	Não	Sim
118	virginica	1.9674	0.0286	0.038	Não	Não	Sim
62	versicolor	1.6906	0.0367	0.0363	Não	Não	Sim
87	versicolor	1.8404	0.0281	0.0327	Não	Não	Sim
136	virginica	-1.8753	0.0265	0.0319	Não	Não	Sim
131	virginica	1.1417	0.0669	0.0312	Não	Sim	Sim
122	virginica	1.889	0.0254	0.031	Não	Não	Sim
68	versicolor	1.5786	0.0341	0.0293	Não	Não	Sim
148	virginica	-1.89	0.024	0.0293	Não	Não	Sim
41	setosa	0.8303	0.0645	0.0158	Não	Sim	Não
84	versicolor	-2.2874	0.0079	0.0138	Sim	Não	Não
32	setosa	-0.6102	0.0456	0.0059	Não	Sim	Não
15	setosa	0.3817	0.0704	0.0037	Não	Sim	Não
60	versicolor	-0.2841	0.0577	0.0016	Não	Sim	Não
33	setosa	0.2743	0.0532	0.0014	Não	Sim	Não
109	virginica	-0.2203	0.0455	0.0008	Não	Sim	Não
117	virginica	0.081	0.0734	0.0002	Não	Sim	Não

Com $n = 150$ observações e $p = 3$ parâmetros, o limiar de alavanca é $2p/n \approx 0{,}04$, enquanto o limiar de influência pela distância de Cook é $4/n \approx 0{,}027$. A Tabela 8 reúne todas as observações que ultrapassam pelo menos um dos critérios adotados.

3.4.2 Impacto da remoção dos pontos influentes

Tabela 9: Comparação das estimativas antes e depois da remoção dos pontos influentes.

Termo	modelo2 (completo)	modelo2 (refinado)	Diferença (%)
Intercepto	2.249	2.079	-7.56
Sepal.Width	0.596	0.645	8.22
Petal.Length	0.472	0.473	0.21

As variações nas estimativas após a remoção dos pontos influentes são modestas. Como seus valores permanecem dentro dos intervalos plausíveis das variáveis e não há evidência de erro de medição, essas observações parecem refletir a variabilidade natural da amostra. Optamos, portanto, por manter todas as observações no modelo selecionado, evitando descartar informação sem justificativa substantiva.

3.5 Interpretações do modelo selecionado

O modelo2 explica uma parcela substancial da variação observada no comprimento da sépala (R^2 ajustado $=$ 0.838). Mantendo-se a outra variável constante, cada centímetro adicional na largura da sépala está associado a um aumento médio de 0.596 cm no comprimento da sépala; para cada centímetro adicional no comprimento da pétala, o aumento médio esperado é de 0.472 cm. Os dois efeitos são positivos e coerentes com a análise exploratória, ao contrário do sinal instável observado no modelo inicial.

3.5.1 Coeficientes padronizados

Tabela 10: Coeficientes padronizados do modelo selecionado.

Variável	Coeficiente padronizado
Sepal.Width	0.3135
Petal.Length	1.0061

Após colocar as variáveis na mesma escala, os coeficientes padronizados mostram que `Petal.Length` possui contribuição relativa consideravelmente maior que `Sepal.Width` para explicar o comprimento da sépala. Essa comparação complementa a interpretação dos coeficientes originais, cujas magnitudes dependem das unidades de medida.

3.6 Regressão com variáveis dummy (a espécie como explicativa)

Até esta etapa, o modelo selecionado contém apenas medidas morfológicas contínuas. Para examinar o papel da espécie, construímos duas variáveis indicadoras e adotamos *setosa* como categoria de referência. Assim, os coeficientes de *versicolor* e *virginica* representam diferenças em relação a *setosa*, mantidas constantes as demais variáveis do modelo.

Tabela 11: Exemplo da codificação dummy da variável Species, com setosa como referência.

Species	versicolor	virginica
setosa	0	0
setosa	0	0
setosa	0	0
setosa	0	0
setosa	0	0
setosa	0	0

Tabela 12: Estimativas do modelo com Sepal.Width, Petal.Length e Species.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	2.3904	0.2623	9.1143	0	1.872	2.9088
Espécie: versicolor	-0.9558	0.2152	-4.4415	0	-1.3811	-0.5305
Espécie: virginica	-1.3941	0.2857	-4.8803	0	-1.9587	-0.8295
Sepal.Width	0.4322	0.0814	5.3105	0	0.2714	0.5931
Petal.Length	0.7756	0.0642	12.0729	0	0.6487	0.9026

Com a inclusão simultânea da espécie e de `Petal.Length`, os coeficientes de *versicolor* e *virginica* tornam-se negativos. Essa interpretação condicional é contraintuitiva quando comparada aos box-plots, mas decorre da forte associação entre espécie e comprimento da pétala: as variáveis carregam informação parcialmente redundante e competem para explicar a mesma parcela da variabilidade, produzindo coeficientes instáveis.

3.6.1 Modelo sem Petal.Length, com a espécie

Tabela 13: Estimativas do modelo com Sepal.Width e Species (sem Petal.Length).

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	2.2514	0.3698	6.0889	0	1.5206	2.9822
Espécie: versicolor	1.4587	0.1121	13.012	0	1.2372	1.6803
Espécie: virginica	1.9468	0.1	19.4653	0	1.7492	2.1445
Sepal.Width	0.8036	0.1063	7.5566	0	0.5934	1.0137

Após retirar `Petal.Length`, os coeficientes das espécies tornam-se positivos e concordam com a análise exploratória. Mantendo `Sepal.Width` constante, flores *virginica* apresentam, em média, sépalas mais compridas que flores *setosa*; para *versicolor*, a diferença segue a mesma direção, mas com menor magnitude. O ajuste inferior ao do modelo2 evidencia o compromisso entre poder explicativo e clareza de interpretação quando uma variável contínua está fortemente associada a uma variável categórica.

3.6.2 Alterando a categoria de referência

Para demonstrar o papel da categoria de referência, o mesmo modelo foi reparametrizado tomando *virginica* como base de comparação:

Tabela 14: Estimativas do modelo com virginica como categoria de referência.

Termo	Estimativa	Erro padrão	Estatística t	p-valor	Limite inferior	Limite superior
Intercepto	4.1982	0.3223	13.0274	0	3.5613	4.8351
Espécie: setosa	-1.9468	0.1	-19.4653	0	-2.1445	-1.7492
Espécie: versicolor	-0.4881	0.0902	-5.4088	0	-0.6664	-0.3097
Sepal.Width	0.8036	0.1063	7.5566	0	0.5934	1.0137

A troca da categoria de referência não modifica os valores ajustados, os resíduos nem a qualidade global do modelo. Apenas a parametrização é alterada: o intercepto passa a representar *virginica*, e os coeficientes das demais espécies expressam diferenças médias em relação a essa categoria.

3.7 Comparação geral dos modelos

Tabela 15: Comparação das medidas de ajuste entre todos os modelos considerados.

Modelo	n	Rš ajustado	AIC
modelo1 (completo, sem espécie)	150	0.86	82.64
modelo2 (sem Petal.Width)	150	0.84	99.03
modelo3 (sem Petal.Length)	150	0.7	189.82
modelo4 (com espécie e Petal.Length)	150	0.86	79.57
modelo5 (com espécie, sem Petal.Length)	150	0.72	181.94

A comparação geral mostra que o modelo2 oferece o melhor equilíbrio entre ajuste, parcimônia e estabilidade dos coeficientes. Por esse motivo, ele é mantido como modelo selecionado e utilizado na etapa de previsões.

4 Previsões

Utilizando o modelo2, calculamos previsões para dois conjuntos hipotéticos de valores das variáveis explicativas. O primeiro, $\mathbf{x}_1$, representa uma flor com largura de sépala de 2,8 cm e comprimento de pétala de 1,5 cm; o segundo, $\mathbf{x}_2$, representa uma flor com largura de sépala de 3,2 cm e comprimento de pétala de 5,0 cm.

4.1 Intervalo de confiança para o valor médio esperado

Tabela 16: Intervalos de confiança de 95% para o comprimento médio esperado da sépala, para os dois conjuntos hipotéticos.

Larg. Sépala (cm)	Comp. Pétala (cm)	Estimativa (cm)	Limite inferior	Limite superior
2.8	1.5	4.62	4.51	4.74
3.2	5	6.51	6.44	6.59

Interpretação prática: para todas as flores com largura de sépala de 2,8 cm e comprimento de pétala de 1,5 cm, estimamos, com 95% de confiança, que o comprimento **médio** da sépala esteja entre os limites apresentados na primeira linha da tabela. A segunda linha possui a mesma interpretação para flores com largura de sépala de 3,2 cm e comprimento de pétala de 5,0 cm.

4.2 Intervalo de predição para uma nova observação

Tabela 17: Intervalos de predição de 95% para uma nova observação do comprimento da sépala, para os dois conjuntos hipotéticos.

Larg. Sépala (cm)	Comp. Pétala (cm)	Estimativa (cm)	Limite inferior	Limite superior
2.8	1.5	4.62	3.96	5.29
3.2	5	6.51	5.85	7.18

Interpretação prática: para **uma única nova flor** com largura de sépala de 2,8 cm e comprimento de pétala de 1,5 cm, prevemos, com 95% de confiança, que o comprimento de sua sépala estará entre os limites apresentados na primeira linha da tabela. Esse intervalo é mais amplo que o intervalo de confiança para a média, pois acrescenta à incerteza da estimação a variabilidade natural entre flores individuais. O mesmo raciocínio se aplica ao segundo conjunto hipotético.

5 Conclusão

As variáveis morfológicas das flores de *Iris* mostram-se fortemente associadas entre si e nitidamente agrupadas por espécie, especialmente nas medidas da pétala. O modelo inicial, com as três variáveis contínuas disponíveis, apresentou ajuste elevado, mas revelou multicolinearidade severa entre o comprimento e a largura da pétala, evidenciada pelos valores de VIF e pela instabilidade do coeficiente de `Petal.Width`.

O modelo selecionado, com largura da sépala e comprimento da pétala como explicativas, preserva grande parte do poder explicativo do modelo completo e elimina a multicolinearidade relevante. A análise de resíduos e o gráfico de envelope simulado sustentam as suposições do modelo, enquanto o reajuste sem os pontos influentes mostra que sua remoção não altera substantivamente as estimativas. Por isso, todas as observações foram mantidas.

A inclusão da espécie ilustra como uma variável categórica fortemente associada a uma medida contínua também pode produzir interpretações instáveis. A mudança da categoria de referência altera somente a forma de expressar os coeficientes, sem modificar as previsões. Finalmente, os intervalos calculados evidenciam a distinção entre estimar o comprimento médio esperado da sépala e prever o comprimento de uma nova flor: o intervalo de predição é necessariamente mais amplo porque incorpora a variabilidade individual.

Referências

[1] Anderson E. 1935 The Irises of the Gaspe Peninsula. *Bulletin of the American Iris Society* **59**, 2–5.

[2] Fisher RA. 1936 The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics* **7**, 179–188.

[3] Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.

[4] Akaike H. 1974 A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control* **19**, 716–723.

[5] Schwarz G. 1978 Estimating the Dimension of a Model. *The Annals of Statistics* **6**, 461–464.

[6] Cook RD, Weisberg S. 1982 *Residuals and Influence in Regression*. New York: Chapman and Hall.

[7] Cook RD. 1977 Detection of Influential Observation in Linear Regression. *Technometrics* **19**, 15–18.

6 Orientações do trabalho

Esta seção resume, em formato de checklist, como cada uma das etapas solicitadas nas orientações do trabalho foi contemplada neste relatório. As atividades foram adaptadas ao conjunto de dados `iris`, utilizado aqui como exemplo.

Tabela 18: Checklist de aderência às orientações do trabalho.

Item	Seção do relatório
1. Problema, características dos dados e objetivo da análise	Introdução
2. Descrição da base (n, variáveis, significado, unidade)	Descrição da base de dados (Tabela 1)
3. Análise exploratória (dados ausentes, outliers, objetivos)	Análise exploratória
4. Análises uni/bivariadas: correlação, multicolinearidade, box-plot	Análise de correlação; Multicolinearidade: o VIF
5. Modelo inicial com todas as variáveis explicativas	Multicolinearidade: o VIF (Tabela 3)
6. Seleção do melhor modelo por critério estatístico	Seleção do modelo final (AIC, BIC, teste F, stepwise)
7. Verificação e resolução de violações de pressupostos	Diagnóstico do modelo selecionado; Impacto da remoção
8a. IC para o valor médio esperado da resposta, com interpretação	Previsões: Intervalo de confiança
8b. Previsão pontual e intervalo de predição, com interpretação	Previsões: Intervalo de predição